

OPĆENITO

- generički izraz za objekte - uzorak
- RU redukcija \rightarrow iz mnogo u 1 (1 od razreda wi)
- RU ima svojstvo generalizacije

3 vrste raspoznavanja (S. Watanabe)

- { 1) Raspoznavanje temeljeno na primjenima
- superviziv{ 2) Raspoznavanje temeljeno na strukturi (složenih) uzoraka
- 3) Grupiranje (učenje bez učitelja)

1) na temelju nekog uzorka moći za novi odluciti da li pripada razredu wi

I. faza učenja - traži se oblik decizijske funkcije koja će uz najmanju pogrešku (ili bez nje) klasificirati uzroke iz skupa zavijanje

II faza odlučivanja - sustav je naučio decizijsku funkciju i primjenjuje ju na neoznate nove uzorce

2) uzorak opisan primitivima i odnosom među njima, gramatika (V_N, V_T, P, S)

- jezik \Rightarrow za sintaktički pristup

- svakom razredu pripadaju je jezik i stroj koji prepoznaće njegovu gramatiku

3) neognaničeni uzorci, sustav ih "prirodno grupira"

eksperimentira se s različitim postupcima grupiranja

na temelju rezultata korisnik potvrđuje ili odbacuje hipoteze

Učenje s kritikom


na ulazu je uzorak za koji se odredi (tentativni) razred

ako je u krovnom razredu \Rightarrow korekcija decizijske funkcije proporcionalno "veličini" uzorka

sve skupa paratni signal je samo: T ili N

(neura zašto, kako...)

Prikaz RU-redukcija informacije




- osnovne faze u oblikovanju sustava:

- 1) senzor
- 2) generiraće znakove
- 3) izbor znakova
- 4) oblikovanje klasičatora
- 5) evaluacija sustava

INTERSET znakove su bitne \times

- decizije grancice-decizijskim funkcijama: $d_1(x) \dots d_M(x)$

↳ pravilo razvrstavanja: Ako $d_i(\vec{x}) > d_j(\vec{x}) \Rightarrow \vec{x}$ pripada w_i



linearna decizjska fja $d(\vec{x}) = w_1 x_1 + w_2 x_2 + \dots + w_n x_n + w_{n+1} = \vec{w}_0^T \vec{x} + w_{n+1}$

\uparrow težinski koef. \uparrow pomeknuće

Decizjsko pravilo $M=2$	ako $d(\vec{x}) > 0$ onda $\vec{x} \in w_1$
	ako $d(\vec{x}) < 0$ onda $\vec{x} \in w_2$
	ako $d(\vec{x}) = 0$ nije definirano

neklik: hiperpovršina: $\vec{u}^T (\vec{x} - \vec{p}) = 0$

$$\vec{w}_0^T \vec{x} + w_{n+1} = 0 \quad / : \|\vec{w}_0\|$$

$$\frac{\vec{w}_0^T \vec{x}}{\|\vec{w}_0\|} = \frac{-w_{n+1}}{\|\vec{w}_0\|} \quad \vec{u}^T \vec{x} = -\vec{p}^T \vec{u}$$

$$\vec{u} = \frac{\vec{w}_0}{\|\vec{w}_0\|} \rightarrow \text{orientacija hiper-površine}$$

ako je neka komponenta = 0

⇒ paralelna s tom osi

⇒ ako $w_{n+1} = 0 \Rightarrow$ pravži kroz ishodište

$$D_u = \frac{|w_{n+1}|}{\|\vec{w}_0\|} - \text{udaljenost hiperpovršine od ishodišta}$$

Više razreda: M > 2

→ zapravo m problema klasifikacije u 2 razreda

1. slučaj granica između w_i i ostalih razreda:

$$d_i(\vec{x}) = \vec{w}_i^T \vec{x} + w_{i,n+1}$$

2. slučaj $\frac{c(c-1)}{2}$ fja, svaka odjeljuje po 2 razreda

$$d_{ij}(\vec{x}) = w_{ij_1}x_1 + w_{ij_2}x_2 + \dots + w_{ijn+1} = 0$$

3. slučaj $d_{ij}(\vec{x}) = d_i(\vec{x}) - d_j(\vec{x}) = (\vec{w}_i - \vec{w}_j)^T \vec{x} + (w_{i,n+1} - w_{j,n+1}) = 0$

ako je $d_i(\vec{x}) > d_j(\vec{x})$ onda $\vec{x} \in w_i$

određivanje $d(\vec{x})$ $\vec{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \\ 1 \end{bmatrix} \Rightarrow d(\vec{x}) = \vec{w}^T \vec{x}$

Uzorak \vec{x} je pravilno razvrstani ako: $\forall \vec{x} \in w_1 : \vec{w}^T \vec{x} > 0$; $\vec{w}^T \vec{x} < 0$
 $\forall \vec{x} \in w_2 : \vec{w}^T \vec{x} < 0$

\Rightarrow jedinstven uvjet $\vec{w}^T \vec{x} > 0$ ako $\forall \vec{x} \in w_2 \quad (-1)$

Tražimo \vec{w} t.d. je $\vec{w}^T \vec{x} > 0$ $\forall \vec{x}$ iz skupa uzorka, $\vec{x} \in w_2 \Rightarrow \vec{x} \cdot (-1)$

Ako radimo matricu $[X]$ onda upisujemo rečice i $[X] \vec{w} > [0]$

$\vec{w} \rightarrow$ razdvajni vektor

A) GRADIJENTNI POSTUPCI ODREĐIVANJA \vec{w}

$$\text{grad } f(\vec{y}) = \frac{df(\vec{y})}{d\vec{y}} = \begin{bmatrix} \frac{df}{dy_1} \\ \frac{df}{dy_2} \\ \vdots \\ \frac{df}{dy_n} \end{bmatrix}$$

rekto → **gradijent** → vektor

→ svaka komponenta - veličina
promjene je u tom smjeru

→ povećanje argumenta u smjeru negativnog gradijenta
dovodi do minimuma funkcije

FUNKCIJA

$$J(\vec{w}, \vec{x}) = |\vec{w}^T \vec{x}| - \vec{w}^T \vec{x}$$

Netrivijalan slučaj: $\vec{w}^T \vec{x} > 0$

→ povećavamo argument \vec{w} u smjeru negativnog gradijenta sve dok ne dođemo do minimuma fje!

$\vec{w}(k)$ - biti korač

$$\vec{w}(k+1) = \vec{w}(k) - c \left\{ \frac{\partial J(\vec{w}, \vec{x})}{\partial \vec{w}} \right\}_{\vec{w}=\vec{w}(k)} \quad c \neq 0$$

PERCEPTRON

- klasificira uzorke u 1 od 2 razreda

$$R = \sum_{i=1}^{n+1} w_i x_i = \vec{w}^T \cdot \vec{x} = d(\vec{x})$$

Pravilo: ako $R > 0$ ide u w_1
 $R < 0$ ide u w_2

- razredi moraju biti linearno separabilni

- modifikacija za $M > 2$

$$\vec{x} \in w_i \Leftrightarrow R_i > R_j \quad \forall j$$

- modifikacija za nelinearne $d(\vec{x})$

⇒ umetanje nelinearnog preprocesora između $A : \mathbb{R}$

⇒ višeslojni perceptron MLP

Algo perceptrona NE mijenja (-1) za $\vec{x} \in w_2$

Ali za uzorke iz $w_1 \neq w_2$

a) postupak učenja za kriterijsku funkciju $\frac{1}{2}(|\vec{w}^T \vec{x}| - \vec{w}^T \vec{x})$

$$\vec{w}(k+1) = \vec{w}(k) + c \begin{cases} 0 & \vec{w}^T(k) \vec{x}(k) > 0 \\ \vec{x}(k) & \vec{w}^T(k) \vec{x}(k) \leq 0 \end{cases}$$

↳ POSTUPAK PERCEPTRONA SA STANIM PRIRASTOM

b) $J(\vec{w}, \vec{x}) = \frac{1}{4\vec{x}^T \vec{x}} (|\vec{w}^T \vec{x}|^2 - |\vec{w}^T \vec{x}| \cdot \vec{w}^T \vec{x})$

$$\frac{\partial J}{\partial w} = \dots \Rightarrow \vec{w}(k+1) = \vec{w}(k) + \lambda \cdot \frac{|\vec{w}^T \vec{x}(k)|}{\vec{w}^T \vec{x}(k)} \cdot \begin{cases} 0, \vec{w}^T \vec{x} > 0 \\ \vec{x}(k), \vec{w}^T \vec{x} \leq 0 \end{cases}$$

Počevši algoritmu perceptrona za $M > 2$ (3. slučaj)

Počevši oblik lin. d(\vec{x})

$$\vec{x} \rightarrow f(\vec{x})$$


$$d(\vec{x}) = w_1 f_1(\vec{x}) + w_2 f_2(\vec{x}) + \dots + w_{k+1}$$

$$= \sum_{i=1}^{k+1} w_i f_i(\vec{x}) \quad f_{k+1} = 1$$

$$\vec{x}^* = \begin{bmatrix} f_1(\vec{x}) \\ f_2(\vec{x}) \\ \vdots \\ f_{k+1}(\vec{x}) \end{bmatrix}$$

$$d(\vec{x}) = \vec{w}^T \vec{x}^*$$

r-stupanj fi, m - broj razreda



$k \gg n$

SUSTAV ZA RASPOZNAVANJE →

Potencijalne fje

↳ učenje $d(\vec{x})$ bez pretpostavke o konačnom obliku fje

↳ pogle algoritam

použice na $M \geq 2$ razreda

↳ ona koja je iz tog razreda mora imati najveću vrijednost

postupak: $d_0^1(\vec{x}), d_0^2(\vec{x}), \dots, d_0^M(\vec{x}) = 0$

1 korak - 1 uzorak

$$d_k^{(i)}(\vec{x}) = d_{k-1}^{(i)} + K(\vec{x}, \vec{x}_k)$$

$$d_k^{(l)}(\vec{x}) = d_{k-1}^{(l)} - K(\vec{x}, \vec{x}_k)$$

$$d_k^{(j)}(\vec{x}) = d_{k-1}^{(j)}$$

Bayes

Ako samo na temelju „a prior“ vjerojatnosti:

Uvijek odluka za w_1 ako $P(w_1) > P(w_2)$
inace w_2 . To je za bez mijenja.

Svojstva funkcije gustoće razdiobe vjerojatnosti } $p(x|w_j)$
za kontinuiranu varijablu x :

$$1. f(x) \geq 0, \forall x$$

$$2. \int_{-\infty}^{\infty} f(x) dx = 1$$

$$3. \int_{x_1}^{x_2} f(x) dx = P\{x_1 < x < x_2\}$$

$p(x|w_j)$ - vjerodostojnost, likelihood of w_j } known
 $P(w_j)$

$$\Rightarrow \text{Bayesovo pravilo: } p(w_j|x) = \frac{p(x|w_j) \cdot P(w_j)}{p(x)}$$

$$\downarrow \quad p(x) = \sum_{j=1}^J p(x|w_j) \cdot P(w_j)$$

pokazuje kako x mijenja „prior“ vjerojatnost $P(w_j)$
u „posterior“ $p(w_j|x)$

Vjerojatnost pogreške:

$$P(\text{error}|x) = \begin{cases} P(w_1|x), \text{ ako uzmemo } w_2 \\ P(w_2|x), \text{ ako uzmeno } w_1 \end{cases}$$

Odluka: (minimizacija pogreška)

$$\begin{cases} w_1 \text{ ako je } P(w_1|x) > P(w_2|x) \\ w_2 \text{ ako je } P(w_2|x) > P(w_1|x) \end{cases}$$

minimizira jer $P(\text{error}) = \int_{-\infty}^{\infty} P(\text{error}, x) dx = \int_{-\infty}^{\infty} P(\text{error}|x) \cdot p(x) dx$,

a on je uvijek najmanji, pa je i integral najmanji

Modificirano pravilo: uzmi w_1 ako $p(x|w_1) \cdot P(w_1) > p(x|w_2) \cdot P(w_2)$
inaze w_2

1) ≥ 1 značajki $\Rightarrow x \rightarrow \vec{x} \in \mathbb{R}^d$

2) ≥ 2 razeda (c)

3) akcija umjesto samo odluka o stanju prirode - skup $\{d_1, \dots, d_n\}$ akcije

4) fja gubitka $\lambda(d_i|w_j)$

Očekivani gubitak - rizik - poduzimanjem akcije d_i

$$R(d_i|\vec{x}) = \sum_{j=1}^c \lambda(d_i|w_j) P(w_j|\vec{x})$$

$\# \vec{x}$ decizijska fja daje jednu akciju. Ukupni rizik:

$$R = \int R(d(\vec{x})|\vec{x}) p(\vec{x}) d\vec{x}$$

$R(d_i|\vec{x})$ - vjetni rizik akcije d_i

d -volumenski el., \int - po cijelom prostoru značajki

Ako $d(\vec{x})$ takav da $R(d_i(\vec{x}))$ što je moguce uveći $\# \vec{x} \Rightarrow$ ukupni rizik minimum

Bayesovo decizijsko pravilo:

$$R(d_i|\vec{x}) = \sum_{j=1}^c \lambda(d_i|w_j) \cdot P(w_j|\vec{x}) \quad \text{za } i=1, 2, \dots, a$$

i izaberemo d_i t.d. je $R(d_i|\vec{x})$ MINIMALAN

Rezultirajući minimum ukupni rizik \Rightarrow Bayesov rizik

omjer vjerojatnosti za 2 razeda: $\frac{P(\vec{x}|w_1)}{P(\vec{x}|w_2)} > \frac{(\lambda_{12} - \lambda_{22})}{(\lambda_{21} - \lambda_{11})} \cdot \frac{P(w_2)}{P(w_1)}$

Odlučujemo se za w_1 ako je omjer

vjerojatnosti prešao prag neutralnosti od \vec{x} !

$$\lambda(d_i|w_j) = \frac{\partial}{\partial w_j} \lambda(d_i|w_i) \quad i, j = 1, \dots, c$$

$$R(d_i|\vec{x}) = \sum_{j \neq i} \lambda(d_i|w_j) \cdot P(w_j|\vec{x}) = \sum_{j \neq i} P(w_j|\vec{x}) = 1 - P(w_i|\vec{x})$$

Pravilo:
 w_i ako $P(w_i|\vec{x}) > P(w_j|\vec{x}) \quad \forall j \neq i$

Primjer klasifikacije za $M=C$ ($C>2$) razreda



- opći slučaj s rizikom: $g_i(\vec{x}) = -R(\alpha_i | \vec{x})$

- slučaj minimalne pogreške: $g_i(\vec{x}) = P(w_i | \vec{x})$

↑
nije jedinstveno, može $\propto \text{const} + \text{const}$, te
 $f \circ g$ je monotono rastućom funkcijom

$$= g_i(\vec{x}) = P(w_i | \vec{x}) = \frac{P(\vec{x} | w_i) \cdot P(w_i)}{\sum_j P(\vec{x} | w_j) \cdot P(w_j)} = p(\vec{x} | w_i) \cdot P(w_i)$$

$$g_i(\vec{x}) = \ln p(\vec{x} | w_i) + \ln P(w_i)$$

I dalje pravilo: $g_i(\vec{x}) > g_j(\vec{x}) \quad \forall i \neq j \Rightarrow w_i$

Decizionska ploha: $g_{ij}(\vec{x}) = g_i(\vec{x}) - g_j(\vec{x}) = 0, \quad i, j = 1, 2, \dots, M, \quad i \neq j$

Bayesova klasifikacija za normalne distribucije (Gauss)

$$p(\vec{x} | w_i) = \frac{1}{(2\pi)^{l/2} |\Sigma_i|^{1/2}} \exp\left(-\frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma_i^{-1} (\vec{x} - \vec{\mu}_i)\right)$$

l -dimenzija značajki

$\vec{\mu}_i = E[\vec{x}] \Rightarrow$ srednja vrijednost razreda w_i

$\Sigma_i \rightarrow l \times l$ kovarijantna matrica: $\Sigma_i = E[(\vec{x} - \vec{\mu}_i)(\vec{x} - \vec{\mu}_i)^T]$

$|\Sigma_i|$ determinanta

E - očekivane sluč. var.

Gaussova distribucija $N(\vec{\mu}, \Sigma)$

$$g_i(\vec{x}) = f(p(w_i | \vec{x}))$$

$\uparrow \ln(\cdot)$

$$g_i(\vec{x}) = \ln p(\vec{x} | w_i) + \ln P(w_i)$$

$$g_i(\vec{x}) = -\frac{1}{2} \vec{x}^T \Sigma_i^{-1} \vec{x} + \frac{1}{2} \vec{x}^T \Sigma_i^{-1} \vec{\mu}_i - \frac{1}{2} \vec{\mu}_i^T \Sigma_i^{-1} \vec{\mu}_i + \frac{1}{2} \vec{\mu}_i^T \Sigma_i^{-1} \vec{x} + \ln P(w_i) + C_i$$

$$C_i = -\left(\frac{1}{2}\right) \ln 2\pi - \left(\frac{1}{2}\right) \ln |\Sigma_i|$$

$g_i(\vec{x})$ - nelinearna kvadratna forma. Za $l=2$ dec. kružnje / parabole / hiperbole $\boxed{2+13}$

elipsoidi

Ocjena parametara (Bay3)

trebamo poznavati: $p(w_i)$ i $p(\vec{x}|w_i)$

ako je Gaussova $N(\vec{\mu}_i, \Sigma_i)$

\rightarrow problem se svodi na ocjenu parametara $\vec{\mu}_i$ i Σ_i

Gauss:

$$p(\vec{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp -\frac{1}{2} [(\vec{x} - \vec{\mu}_i)^\top \Sigma^{-1} (\vec{x} - \vec{\mu}_i)]$$

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} & \dots & \Sigma_{1d} \\ \vdots & & & \\ \Sigma_{d1} & \Sigma_{d2} & \dots & \Sigma_{dd} \end{bmatrix}$$

Skup za učenje: $\vec{\mu}_i \doteq \frac{1}{N_1} \sum_{j=1}^{N_1} \vec{x}_j$

$$\Sigma_i \doteq \frac{1}{N_1} \left(\sum_{j=1}^{N_1} (\vec{x}_j - \vec{\mu}_i) (\vec{x}_j - \vec{\mu}_i)^\top \right)$$

za sve mreže

Ako: $P(w_1) = P(w_2)$ $\text{ i } \Sigma_1 = \Sigma_2$ $\text{ i } \vec{\mu}_1 \neq \vec{\mu}_2$

\Rightarrow mreža je Gaussova

$$g_i(\vec{x}) = \log \{ p(\vec{x}|w_i) \}$$

$$P_i(\vec{x}) = (2\pi)^{-\frac{d}{2}} |\Sigma_i|^{-\frac{1}{2}} \exp \left[-\frac{1}{2} (\vec{x} - \vec{\mu}_i)^\top \Sigma_i^{-1} (\vec{x} - \vec{\mu}_i) \right]$$

$$g_i(\vec{x}) = \log \{ P(\vec{x}|w_i) \}$$

$$g_i(\vec{x}) = -\frac{1}{2} (\vec{x} - \vec{\mu}_i)^\top \Sigma_i^{-1} (\vec{x} - \vec{\mu}_i) - \frac{d}{2} \log (2\pi) - \frac{1}{2} \log |\Sigma_i|$$

$$\Sigma_1 = \Sigma_2$$

$$d_i^2 = (\vec{x} - \vec{\mu}_i)^\top \Sigma_i^{-1} (\vec{x} - \vec{\mu}_i)$$

$$g_i(\vec{x}) = -(\vec{x} - \vec{\mu}_i)^\top \Sigma_i^{-1} (\vec{x} - \vec{\mu}_i)$$

$$g_i(\vec{x}) = -\vec{x}^\top \Sigma_i^{-1} \vec{x} + 2\vec{\mu}_i^\top \Sigma_i^{-1} \vec{x} - \vec{\mu}_i^\top \Sigma_i^{-1} \vec{\mu}_i$$

$$g_i(\vec{x}) = (\Sigma_i^{-1} \vec{\mu}_i)^\top \vec{x} - \frac{1}{2} \vec{\mu}_i^\top \Sigma_i^{-1} \vec{\mu}_i$$

$$g_i(\vec{x}) = \vec{w}_i^\top \vec{x} - w_{i0}$$

$$w_i = \Sigma_i^{-1} \cdot \vec{\mu}_i$$

$$w_{i0} = \frac{1}{2} \vec{\mu}_i^\top \Sigma_i^{-1} \vec{\mu}_i$$

Granica:

$$g_1(\vec{x}) - g_2(\vec{x}) = 0$$

Klasifikacija pomoću najmanje udaljenosti

- mjeru udaljenosti mora zadovoljavati:


- a) $D(\vec{x}_k, \vec{x}_l) = 0$ za $\vec{x}_k = \vec{x}_l$
 $D(\vec{x}_k, \vec{x}_l) \neq 0$; $D(\vec{x}_k, \vec{x}_l) > 0$ za $\vec{x}_k \neq \vec{x}_l$
- b) $D(\vec{x}_k, \vec{x}_l) = D(\vec{x}_l, \vec{x}_k)$
- c) $D(\vec{x}_k, \vec{x}_l) \leq D(\vec{x}_k, \vec{x}_j) + D(\vec{x}_j, \vec{x}_l)$

Udaljenost Minkovskog:

$$D(\vec{x}_k, \vec{x}_l) = \left(\sum_{j=1}^n |x_{kj} - x_{lj}|^s \right)^{\frac{1}{s}}$$

$s=2$ Euklidova udaljenost

$$s=1$$
 Manhattenska $D(\vec{x}_k, \vec{x}_l) = \sum_{j=1}^n |x_{kj} - x_{lj}|$



$$s \rightarrow \infty$$
 Čebišljeva $D(\vec{x}_k, \vec{x}_l) = \max \{ |x_{kj} - x_{lj}| \}$

$s=n$

Tejinska Minkovskog: $D(\vec{x}_k, \vec{x}_l) = \left(\sum_{j=1}^n w_j |x_{kj} - x_{lj}|^s \right)^{\frac{1}{s}}$, $w_j \geq 1$

Mahalanobisova:

$$D(\vec{x}_k, \vec{x}_l) = (\vec{x}_k - \vec{x}_l)^T C^{-1} (\vec{x}_k - \vec{x}_l)$$

$$C(\vec{x}_k, \vec{x}_l) = \frac{\sum_{j=1}^n (x_{kj} - m)(x_{lj} - m)}{\sum_{j=1}^n (x_{kj} - m)^2 \sum_{j=1}^n (x_{lj} - m)^2}$$
 kovarijacijska matrica iz skupa učenje
 m - srednja vrijednost od x_j .

sličnost = $D^{-1}(\vec{x}_k, \vec{x}_l)$

Hausdingova udaljenost $D(\vec{x}_k, \vec{x}_l) = \sum_{j=1}^n (w_j) d_j$ $d_j = \begin{cases} 1, & x_{kj} \neq x_{lj} \\ 0, & x_{kj} = x_{lj} \end{cases}$

A) Klasifikacija na temelju jednog prototipa

M razreda \Rightarrow prototipovi $\vec{z}_1, \vec{z}_2, \dots, \vec{z}_M$

$$D_i = \| \vec{x} - \vec{z}_i \| = \sqrt{(\vec{x} - \vec{z}_i)^T (\vec{x} - \vec{z}_i)}$$

Pravilo $\vec{x} \in w_i$ ako $D_i \leq D_j \quad \forall j \neq i$

$$\begin{aligned} D_i^2 &= \| \vec{x} - \vec{z}_i \| ^2 = (\vec{x} - \vec{z}_i)^T (\vec{x} - \vec{z}_i) \\ &= \vec{x}^T \vec{x} - 2 \vec{x}^T \vec{z}_i + \vec{z}_i^T \vec{z}_i \\ &= \vec{x}^T \vec{x} - 2 (\vec{x}^T \vec{z}_i + \frac{1}{2} \vec{z}_i^T \vec{z}_i) \end{aligned}$$

$\min D_i^2 \rightarrow \min D_i$ jer su sve udaljenosti pozitivne

$\vec{x}'\vec{z}$ - ne zavisi od i

$$\text{maksimum} = \vec{x}'\vec{z}_i - \frac{1}{2}\vec{z}_i'\vec{z}_i$$

↑ to je kada je D_i minimalan

Lecijaška fja: $d_i(\vec{x}) = \vec{x}'\vec{z}_i - \frac{1}{2}\vec{z}_i'\vec{z}_i$, $i=1,2,\dots,M$

$\vec{x} \in w_i$ ako je $d_i(\vec{x}) > d_j(\vec{x}) \quad \forall j \neq i$

$d_i(\vec{x})$ - linearna dec. fja.

$z_{ij} \quad j=1,2,\dots,n$ - komponente \vec{z}_i

$w_{ij} = z_{ij} \quad j=1,2,\dots,n$

$w_{i,n+1} = -\frac{1}{2}\vec{z}_i'\vec{z}_i$

$$\vec{x} = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ \vdots \\ x_n \\ 1 \end{pmatrix}$$

$d_i(\vec{x}) = \vec{w}_i' \vec{x} \quad i=1,2,\dots,M$

→ korelacijska metoda

$$\vec{w}_i = (w_{i1}, w_{i2}, \dots, w_{i,n+1})$$

3 Klasifikacija na temelju više prototipova za pojedini razred

- razred w_i grupira se oko N_i prototipova $\vec{z}_i^1, \vec{z}_i^2, \dots, \vec{z}_i^{N_i}$

$$D_i = \min_l \|\vec{x} - \vec{z}_i^l\|, \quad l=1, \dots, N_i$$

Izračunati D_i za $i=1,2,\dots,M$

"Pravilo": $\vec{x} \in w_i$ ako $D_i < D_j \quad \forall j \neq i$

Dec. fja: $d_i(\vec{x}) = \max_l \{ (\vec{x}'\vec{z}_i^l) - \frac{1}{2}(\vec{z}_i^l)' \vec{z}_i^l \} \quad l=1,2,\dots,N_i$

Pravilo: $\vec{x} \in w_i$ ako je $d_i(\vec{x}) > d_j(\vec{x}) \quad \forall j \neq i$

Klas. pravilo najbližeg susjeda: 1-NN

$$D(\vec{s}_i, \vec{x}) = \min_l \{ D(\vec{s}_i, \vec{x}) \}, \quad l=1,2,\dots,N$$

$\vec{s}_i \in \{\vec{s}_1, \vec{s}_2, \dots, \vec{s}_N\}$, D - mjeru udaljenosti def. u prostoru značajki

Nepoznati uzorak \vec{x} : $\vec{x} \in w_k$ ako je \vec{s} najbliži susjed iz razreda w_k

g-NN pravilo - koristi g najblžih susjeda, $g \geq 1$

U načeluju N uzoraka nati g NN u zorku \hat{x} ($g \geq 1$ da nije višekratnik razreda)

$\sum_i g_i = g$, g je broj vektora koji spadaju razredu w_i , $i=1,2,\dots,N$

razvrstaj \hat{x} u razred w_k za koji je g maksimalan

Ocjena pogreške NN, $N \rightarrow \infty$ $P_{NN} : P_B \leq P_{NN} \leq P_B \left(2 - \frac{M P_B}{N-1}\right) \leq 2 P_B$
opt. Bay pgr.

$N=2$: $P_B \leq P_{g=2} = P_B + \sqrt{\frac{2P_B}{g}}$ ako $g \rightarrow \infty$ \Rightarrow je optimalan

NN; g-NN \Rightarrow za velik step učenja \Rightarrow dobro djelovanje

Ljepote - složenos $O(k^d)$ + ako je velika d, $d \gg 1$

Inačice NN

(g, l)-NN pravilo \Rightarrow od g najblj. sus. barem l iz w_i $l = \frac{2}{3}g$ npr.
 \Rightarrow u suprotnom se ne klasificira ili nekak druge

(g, l)-NN \Rightarrow $P_1 = P_B - \frac{2}{3}g$, $P_2 = \frac{3}{4}g$, ..., $P_M = \frac{5}{6}g$

\Rightarrow na temelju apriorne vjeroj. razreda vizorka koje su razlikuju

Metode: - s obzirom na način zapisa: u mem. svim uzorcima
u mem. samo predstavnici razreda

- na broj (najblj.) susjedova: 1, g ($g > 1$), gl i (g, l)-NN

Normalizacija podataka

Fazilišiti razponi (redovi veličina), a ne mora značenjem biti tako

Normalizacija \Rightarrow da budu u sličnim opsezinama

N-podataka k-te karakteristike: $\vec{x}_k = \frac{1}{N} \sum_{i=1}^N x_{ik}$, $k=1,2,\dots,d$

$$\sigma_k^2 = \frac{1}{N-1} \sum_{i=1}^N (x_{ik} - \vec{x}_k)^2$$

Normalizirana vrijednost: $\hat{x}_{ik} = \frac{x_{ik} - \vec{x}_k}{\sigma_k}$ \leftarrow linearna metoda

- imaju $\bar{x}=0$ i $\sigma_k=1$

Nelinearne metode - ako se podaci ne pomijeju ako stečje vrijednosti

"softmax" skaliranje: $y = \frac{x_{ik} - \bar{x}_k}{\sigma_k}$, $\hat{x}_{ik} = \frac{1}{1 + \exp(-y)}$
 \downarrow user defined

Eval

1) Imamo dva daju uзорака

→ Holdout metoda



su - učenje

si - ispitivanje

$$S = S_u \cup S_i$$

$$\emptyset = S_u \cap S_i$$

→ inačica - random subsampling: proj. točnost_k = $\frac{1}{k} \sum_{i=1}^k$ točnost_i

2) Leave-one-out → ponavlja se N puta i broj greške
→ da li velika mæurska slož.

3) Metoda gornje zavijene - isti step preuze učenje, pa ispit.
- optimistična pretpostava


k-fold cross-validation → k puta (Leave-1-out → k=N)

Uzorci: - dovoljnost informacije
- postojanje značajki
- geometrijska postaganost

Preporuka za $N = (3-5) * d * M$

Jezični snimak

Shematski prikaz sustava za sintaktičko raspoznavanje:



Gram. tip: 0 → slabo građen

1 → kontekstno zavisna

2 → kontekstno neovisna → Chomsky

3 → regularna građa.

$$L(T_3) \subset L(T_2) \subset L(T_1) \subset \emptyset$$

Problem sintaktičkog raspoznavanja užorka

fraz - sastavljen od termina

→ pripada 3 gramatika & sa sistemom da se jezik koji generira sedi

ot užorka koji isključivo pripadaju samo jednom rečniku, npr. W_1

2. dan užorak može biti razvrstan u W_1 ako je on rečenica iz $L(G)$.

U drugom slučaju je užorak iz W_2 .

Gruširanje

osnovni koraci u gruširanju:

1. izbor znakova
2. izbor mjeru sličnosti/rez.
3. kriterij grupiranja
4. algo gruširanja
5. validacija rez.
6. interpolacija rez.

Znakove: 1. nominalne (0/1)

2. rednero 1-5
3. intervalno skalične - stup.
4. skalične omjerom 120kg/60kg

X-dupodatak, $\vec{x} = (x_1, x_2, \dots, x_N)$

m-gruširajuće $X \rightarrow C_1, \dots, C_m$ cluster

3 uvjeta: 1. $C_i \neq \emptyset, i=1,2,\dots,m$

$$2. \cup_{i=1}^m C_i = X$$

$$3. C_i \cap C_j = \emptyset, i \neq j, i,j=1,2,\dots,m$$

-izrazito gruširajuće

Neizrazito gruširajuće: $\mu_j: X \rightarrow [0,1], j=1,2,\dots,m$

$$\sum_{j=1}^m \mu_j(\vec{x}_i) = 1 \quad i=1,2,\dots,N$$

$$0 \leq \sum_{i=1}^N \mu_j(\vec{x}_i) < N \quad j=1,2,\dots,m$$

membership functions

Mjere bliskosti

-mjera različitosti DM $\rightarrow d: X \times X \rightarrow \mathbb{R}$

uvjeti: 1. $\exists d_0 \in \mathbb{R}: -\infty < d_0 \leq d(\vec{x}, \vec{y}) < +\infty$

$$\forall \vec{x}, \vec{y} \in X \\ d(\vec{x}, \vec{y}) = d_0 \quad \forall \vec{x} \in X$$

$$2. d(\vec{x}, \vec{y}) = d(\vec{y}, \vec{x}) \quad \forall \vec{x}, \vec{y} \in X$$

$$3. d(\vec{x}, \vec{y}) \geq d_0 \quad \text{if } \vec{x} = \vec{y}$$

$$\text{odatli 4. } d(\vec{x}, \vec{z}) \leq d(\vec{x}, \vec{y}) + d(\vec{y}, \vec{z}), \quad \forall \vec{x}, \vec{y}, \vec{z} \in X$$

-similarity obrazac: $SM \rightarrow s: X \times X \rightarrow \mathbb{R}$

$$1. \exists s_0 \in \mathbb{R}: -\infty < s(\vec{x}, \vec{y}) \leq s(\vec{x}, \vec{y}) \leq +\infty \quad \forall \vec{x}, \vec{y} \in X$$

$$2. \text{ isto, 3. isto, 4. } s(\vec{x}, \vec{y}) \cdot s(\vec{y}, \vec{z}) \leq [s(\vec{x}, \vec{y}) + s(\vec{y}, \vec{z})] \cdot s(\vec{x}, \vec{z})$$

Kriteriji grupiranja

- Poštući:
- i) Heuristički - odeni inicijom i istraživom
 - ii) temeljeni na minimizaciji (ili maksimizaciji)
- neke kriterijske funkcije ili indeksa

najčešći kriterij $J = \sum_{j=1}^{N_c} \sum_{\vec{x} \in S_j} \|\vec{x} - \vec{m}_j\|^2$

N_c - broj grupe

S_j - skup uzorka iz grupe j

$$\vec{m}_j = \frac{1}{N_j} \sum_{\vec{x} \in S_j} \vec{x}, N_j > \# S_j$$

- iii) kombinacija i) ; ii)