

b) Postupak učenja za kriterijsku funkciju:

$$J(\vec{w}, \vec{x}) = \frac{1}{4\vec{x}^T \vec{x}} (|\vec{w}^T \vec{x}|^2 - |\vec{w}^T \vec{x}| \cdot \vec{w}^T \vec{x})$$

Parcijalna derivacija kriterijske funkcije:

$$\frac{\partial}{\partial w_i} (w \cdot v) = v \cdot v^T + w w^T$$

$$\frac{\partial J}{\partial \vec{w}} = \frac{1}{4\vec{x}^T \vec{x}} [2|\vec{w}^T \vec{x}| \cdot \vec{x} \operatorname{sgn}(\vec{w}^T \vec{x}) - (|\vec{w}^T \vec{x}| \cdot \vec{x} + |\vec{w}^T \vec{x}| \cdot \vec{x} \operatorname{sgn}(\vec{w}^T \vec{x}))]$$

$$\frac{\partial J}{\partial \vec{w}} = \frac{1}{4\vec{x}^T \vec{x}} [2|\vec{w}^T \vec{x}| \vec{x} \operatorname{sgn}(\vec{w}^T \vec{x}) - 2|\vec{w}^T \vec{x}| \vec{x}]$$

$$(\vec{w}^T \vec{x}) \cdot \vec{x} \cdot \operatorname{sgn}(\vec{w}^T \vec{x}) =$$

$$|\vec{w}^T \vec{x}| \cdot \vec{x}$$

$$\frac{\partial J}{\partial \vec{w}} = \frac{1}{2\vec{x}^T \vec{x}} [|\vec{w}^T \vec{x}| \vec{x} \operatorname{sgn}(\vec{w}^T \vec{x}) - |\vec{w}^T \vec{x}| \vec{x}]$$

Postupak učenja:

$$\vec{w}(k+1) = \vec{w}(k) + \lambda \frac{|\vec{w}^T(k) \cdot \vec{x}(k)|}{2\vec{x}^T(k) \vec{x}(k)} \left[\vec{x}(k) - \vec{x}(k) \cdot \operatorname{sgn}(\vec{w}^T(k) \cdot \vec{x}(k)) \right]$$

$$w(t+1) = \vec{w}(t) + \lambda \frac{[\vec{w}^T(t) \vec{x}(t)]}{\vec{x}^T(t) \vec{x}(t)} \cdot \begin{cases} \text{Uzeto je } \vec{w}^T(t) \vec{x}(t) > 0 \\ \vec{x}(t) \text{ ako je } \\ \vec{w}^T(t) \cdot \vec{x}(t) \leq 0 \end{cases}$$

λ - korekcijski faktor

- početna vrijednost \vec{w} različita od $\vec{0}$
- ako je $\lambda > 1$ promatrani uticaj se pravilno razvratova nakon (slike) korekcije vektora \vec{w}
- postoji dobar da postupak učenja konvergira (za lin. separabilne reči) tzn $0 < \lambda < 2$;

Ako
tai

$$\vec{w}(k+1) = \vec{w}(k) + c \begin{cases} \cdot 0 \text{ ako je } \vec{w}^T(k)\vec{x}(k) > 0 \\ \cdot \vec{x}(k) \text{ ako je } \vec{w}^T(k)\vec{x}(k) \leq 0 \end{cases}$$

varijacija u zavisnosti od izbora korekcijskog intrementa c

- 1) algoritam sa stalnim (fixed) prirastom (fixed-increment)
- 2) algoritam s apsolutnom korekcijom (absolute-correction)
- 3) algoritam s djelomičnom korekcijom (fractional-correction)

1) $c = \text{konst.} > 0$

2) c izabran tako da je dovoljno velik da jamči da će neoreš biti ispravno klasificiran nakon ugadjanja tešinskog faktora \vec{w}

Ako je $\vec{w}^T(k) \cdot \vec{x}(k) \leq 0$ izabire se c tako da vrijedi:

$$\vec{w}^T(k+1) \vec{x}(k) = [\vec{w}(k) + c \vec{x}(k)]^T \vec{x}(k) > 0$$

c je najmanji cijeli broj veci od

3)

c je reakcija tako da je

$$|\vec{w}^T(k)\vec{x}(k) - \vec{w}^T(k+1)\vec{x}(k)| \leq \lambda$$

od | $\vec{w}^T(k)\vec{x}(k)|$:

$$|\vec{w}^T(k)\vec{x}(k) - \vec{w}^T(k+1)\vec{x}(k)| = \lambda |\vec{w}^T(k) \cdot \vec{x}(k)|$$

Uvratimo $\vec{w}(k+1) = \vec{w}(k) + c\vec{R}(k)$

$$\vec{w}^T(k)\vec{x}(k) - (\vec{w}^T(k) + c\vec{R}^T(k))\vec{x}(k) = \lambda |\vec{w}^T(k)\vec{x}(k)|$$

Dobivamo:

$$c = \lambda \frac{|\vec{w}^T(k) \cdot \vec{x}(k)|}{\vec{R}^T(k) \cdot \vec{x}(k)}$$

- zahtijeva ce da posljedna vrijednost vektora \vec{w} bude razlicita od $\vec{0}$


- za $\lambda > 1$ ukorak se pravilno razvrtava nizom svakog ugledanja, te se vektori

- za $0 < \lambda < 1$ "postupak konvergira"

PERCEPTRON (Korenblatt, 1957)

- bionika (biologija - elektronika):
grana znanosti koja trazi' polazne
tocke za rješenje tehničkih problema
u uzorima što ih čovjeku pruža
sama priroda
: primjena bioloških koncepta
ta integriraju električnih
npravila

Perceptron - klasificira uzorce u jedan
od dva razreda



jedinica u polju A generira izlaz realničit od 0 ako je dovoljan broj senzorskih jedinica povezanih na A jediniciu po budem (aktivan).

x_i - odgovor i-te asocijativne jedinice

w_i - težinska vrijednost

Odgovor R proporcionalan je sumi odgovora A jedinica; odgovori su pomnoženi težinskim vrijednostima w_i :

$$R = \sum_{i=1}^{n+1} w_i x_i = \vec{w}^T \vec{x}$$

Pravilo klasifikacije:

- ako je $R > 0$ nepoznati se uzorak razvrstava u ω_1

- ako je $R < 0$ nepoznati se uzorak razvrstava u ω_2

Perceptron - klasifikator ugoraka u dva razreda - ako su razredi linearno separabilni

- modifikacija perceptrona za klasifikaciju ugoraka u $M > 2$ razreda:

M - jedinica R

R_1, R_2, \dots, R_M

Pravilo:

ugorak se razvrstava u razred w_i atko $R_i > R_j$ za sve $i \neq j$.

Osnovni model perceptrona može se raširiti na nelinearne dečistajke funkcije umetanjem nelinearnog pretprocesora između $A : R$ poja

- višestojni perceptron MLP

ALGORITAM PERCEPTRONA

(Reward - Punishment Concept)

Algoritam učenja perceptrona:

- Razdano su dva skupa uzoraka za učenje koji pripadaju razredu ω_1 i ω_2

- $\vec{w}(1)$ početna vrijednost vektora težinskih koeficijenata - pravovojno (toleran)

- k-ti korak učenja :

- Ako $\vec{x}(k) \in \omega_1$ i

$\vec{w}^T(k)\vec{x}(k) \leq 0$ zamijeni $\vec{w}(k)$ na

$$\vec{w}(k+1) = \vec{w}(k) + c\vec{x}(k),$$

gdje je c korakajški faktor

- Ako $\vec{x}(k) \in \omega_2$ i


$\vec{w}^T(k)\vec{x}(k) \geq 0$ zamijeni

$$\vec{w}(k+1) = \vec{w}(k) - c\vec{x}(k)$$

- U drugim slučajevima ostavi

$$\vec{w}(k) \Rightarrow \vec{w}(k+1) = \vec{w}(k)$$

PRIMER



$$\begin{cases} 0 \in \omega_1 \\ 0 \notin \omega_2 \end{cases}$$

$$\omega_1 = \{(0,0,1)', (0,1,1)'\}$$

$$\omega_2 = \{(1,0,1)', (1,1,1)'\}$$

$$c=1 \quad \vec{w}(1)=\vec{0}$$

$$\vec{w}^T(1) \cdot \vec{x}(1) = (0,0,0) \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} = 0$$

$$\vec{w}(2) = \vec{w}(1) + \vec{x}(1) = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{w}^T(2) \cdot \vec{x}(2) = (0,0,1) \begin{pmatrix} 0 \\ 1 \\ 1 \end{pmatrix} = 1$$

$$\vec{w}(3) = \vec{w}(2) = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

$$\vec{w}^T(3) \cdot \vec{x}(3) = (0,0,1) \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = 1$$

$$\vec{w}(4) = \vec{w}(3) - \vec{x}(3) = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \\ 0 \end{pmatrix}$$

$$\vec{w}^T(4) \vec{x}(4) = (-1, 0, 0) \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix} = -1$$

LMSE (Least-Mean-Square-Error) (Ho - Kashyap algoritam, 1966.)

- Algoritam perceptrona (i njegove varijacije) konvergira kada su razredi linearno razdvojivi
- Ne može se sa sigurnosti utvrditi da li duga sekvenca učenja znači i da su razredi linearno separabilni
- Algoritam koji brže konvergira i ima ugraden mehanizam za detekciju slučaja kada razredi nisu linearno separabilni

Umjesto nalaženja vektora \tilde{w} tako da vrijedi $[X]\tilde{w} > \tilde{b}$

trebit će nam vektor \tilde{w} i \tilde{b} tako da vrijedi

$$[X]\tilde{w} = \tilde{b},$$

gdje je $\tilde{b} = (b_1, b_2, \dots, b_N)^T$ takav da su sve njegove komponente b_i , $i=1, 2, \dots, N$ pozitivne.

Kriterijska funkcija:

$$J(\vec{w}, \vec{x}, \vec{b}) = \frac{1}{2} \sum_{j=1}^N (\vec{w}^T \vec{x}_j - b_j)^2 = \frac{1}{2} \| [\vec{x}] \vec{w} - \vec{b} \|^2,$$

gdje $\| [\vec{x}] \vec{w} - \vec{b} \|^2$ označava veličinu vektora $([\vec{x}] \vec{w} - \vec{b})$.

Kriterijska funkcija $J(\vec{w}, \vec{x}, \vec{b})$ postiže minimum kada je $[\vec{x}] \vec{w} = \vec{b}$

Umjesto traženja vektora \vec{w} koji zadovoljavaju nejednadžbu tražimo vektore \vec{w} i \vec{b} tako da je zadovoljena jednadžba:

$$[\vec{x}] \vec{w} = \vec{b}$$

- Možemo obje varijable \vec{w} i \vec{b} upotrijebiti u minimizacijskoj proceduri
- Očekujemo poloboljsani postupak (brzi) konvergencije
- Gradijenti:

$$\frac{\partial J}{\partial \vec{w}} \cdot [\vec{x}]^T ([\vec{x}] \vec{w} - \vec{b})$$

$$\frac{\partial J}{\partial \vec{b}} = -([\vec{x}] \vec{w} - \vec{b})$$

ktor \vec{w} nije ograničen jime
postaviti:

$$\frac{\partial J}{\partial \vec{w}} = \vec{0}$$

$$[x]^T([x]\vec{w} - \vec{b}) = \vec{0}$$

$$[x]^T[x]\vec{w} - [x]^T\vec{b} = \vec{0}$$

$$[x]^T[x]\vec{w} = [x]^T\vec{b} / ([x]^T[x])^{-1}$$

$$\vec{w} = ([x]^T[x])^{-1}[x]^T\vec{b}$$

$$\boxed{\vec{w} = [x]^* \vec{b}}$$

xx

$[x]^*$ - generalized
inverse of
 $[x]$

Vektor \vec{b} je ograničen - to je vektor sa svim
pozitivním komponentami

vektor \vec{b} treba tako mijenjati da uvijek
bude zadovoljstvo: $b_i > 0$ za $i = 1, 2, \dots, N$

To se postiže na ovaj način:

$$\vec{b}(k+1) = \vec{b}(k) + \delta \vec{b}(k),$$

gde je $\delta \vec{b}(k) = \begin{cases} 2c[x]\vec{w}(k) - \vec{b}(k) \end{cases}$

$$\delta b_i(k) = \begin{cases} \text{ako } [x]\vec{w}(k) - b_i(k) > 0 \\ 0 \quad \text{ako } [x]\vec{w}(k) - b_i(k) \leq 0 \end{cases}$$

5.3 DERIVATION OF PATTERN CLASSIFICATION ALGORITHMS

$$\frac{\partial J}{\partial \vec{b}} = -([x] \vec{w} - \vec{b})$$

Jednadžbu \circledast zapisimo u vektorskom obliku:

$$\delta \vec{b}(k) = c [x] \vec{w}(k) - \vec{b}(k) + |[x] \vec{w}(k) - \vec{b}(k)|$$

gde je

$$| [x] \vec{w}(k) - \vec{b}(k) |$$

označava apsolutnu vrijednost svake komponente vektora $[x] \vec{w}(k) - \vec{b}(k)$

Iz jednadžbi \circledast i $\circledast \circledast \circledast$ dobivamo:

$$\begin{aligned} \vec{w}(k+1) &= [x]^* \vec{b}(k+1) \\ &= [x]^* [\vec{b}(k) + \delta \vec{b}(k)] \\ &= [x]^* \vec{b}(k) + [x]^* \delta \vec{b}(k) \\ &= \vec{w}(k) + [x]^* \delta \vec{b}(k) \end{aligned}$$

Oznacimo

$$\vec{e}(k) = [x] \vec{w}(k) - \vec{b}(k)$$

Algoritam:

$$\vec{w}(1) = [X]^T \vec{b}(1)$$

$\vec{b}(1)$ pravovoljno uz uvjet

$$b_i > 0 \text{ za sve } i$$

$$\vec{e}(k) = [X] \vec{w}(k) - \vec{b}(k)$$

$$\vec{w}(k+1) = \vec{w}(k) + c [X]^T [\vec{e}(k) - |\vec{e}(k)|]$$

$$\vec{b}(k+1) = \vec{b}(k) + c [\vec{e}(k) + |\vec{e}(k)|]$$

$\vec{w}(k+1)$ može se izračunati i kao:

$$\vec{w}(k+1) = [X]^T \vec{b}(k+1)$$

Napomena: $|\vec{e}(k)|$ označava vektor čije su komponente
apsolutne vrijednosti komponenti
vektora $\vec{e}(k)$


Vatno svojstvo algoritma:

- * Ako su u bilo kojem iteracijskom koraku
sve komponente vektora $\vec{e}(k)$
ne pozitivne (ali ne jednake 0)
tada su linearne nešparabilne!
- * Kada je $\vec{e}(k) = \vec{0}$ $\vec{w}(k)$ je rješenje!

Osnovna snažnja algoritma:

- Ako rješenje za nejednadžbu $[X]\hat{w} > \hat{b}$ postoji, postupak konvergira za $0 < c \leq 1$
- Razredi nisu separabilni s linearnom decizijom funkcijom ako u bilo kojem koraku postupka nisu sve komponente vektora $\hat{e}(k)$ pozitivne ili jednake nuli.
- Ako je $\hat{e}(k) = \vec{0}$ znači da vrijedi $[X]\hat{w}(k) = \hat{b}(k)$, t.j. $\hat{w}(k)$ je rješenje
- Postupak kriče konvergira negoli postupak perceptronu i može biti "bolje" granice između razreda.

$$\begin{aligned} w_1 &:= \{(0,0)^T, (0,1)^T\} \\ w_2 &:= \{(1,0)^T, (1,1)^T\} \end{aligned}$$



$$[x] = \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 1 \\ -1 & 0 & -1 \\ -1 & -1 & -1 \end{bmatrix}_{4 \times 3}$$

Potražimo

$$[x]^* = ([x]^T [x])^{-1} [x]^T$$

$$[x]^* = \frac{1}{4} \begin{bmatrix} -1 & -1 & -1 & -1 \\ -1 & 1 & 1 & 1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix}$$

Neka je $\tilde{b}(1) = (1, 1, 1, 1)^T$; $c=1$; $b_i > 0$

$$\tilde{w}(1) = [x]^* \tilde{b}(1) = \begin{pmatrix} -2 \\ 0 \\ 1 \\ 1 \end{pmatrix}$$

$$\tilde{e}(1) = [x] \tilde{w}(1) - \tilde{b}(1) = \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} - \begin{pmatrix} 1 \\ 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ 0 \\ 0 \end{pmatrix}$$

$\tilde{w}(1) = (-2, 0, 1)^T$ traženo rješenje


$$d(x) = -2x_1 + 1$$

5.3 DERIVATION OF PATTERN CLASSIFICATION ALGORITHMS

Network =

$$\omega_1 : \{(0,0)^T, (1,1)^T\}$$

$$\omega_2 : \{(0,0)^T, (1,0)^T\}$$



Razredi nisu linearno
separabilni!

(XOR
problem)

$$\vec{b}(1) = (1, 1, 1, 1)^T, c=1$$

$$[X] = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 1 & 1 \\ 0 & -1 & -1 \\ -1 & 0 & -1 \end{bmatrix}$$

$$\text{izracunajmo } [X]^* = ([X]^T [X])^{-1} [X]^T$$

$$[X]^* = \begin{bmatrix} -\frac{1}{2} & \frac{1}{2} & \frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & \frac{1}{2} & -\frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} & -\frac{1}{2} \end{bmatrix}$$

$$\vec{w}(1) = [X]^* \vec{b}(1) = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix}$$

$$\vec{e}(1) = [X] \cdot \vec{w}(1) - \vec{b}(1)$$

$$= \begin{pmatrix} -1 \\ -1 \\ -1 \end{pmatrix}$$

$\vec{e}(1)$ negativno $[X]\vec{w} > 0$ mna
projekcija

as can be proved in a variety of ways. The proof
given above, however, is one of the most concise.

UČENJE U M>2 RAZREDIMA

- Problem učenja koeficijenata linearne dečitljivke funkcije za $M > 2$ razreda skupa ta učenje može se riješiti poopćenim postupkom perceptronu ali i postupkom Ho-Kashyapa.

Podejctimo se: 3. slučaja

1. slučaj: svaki od $M > 2$ razreda separabilan je od ostalih razreda jednom dečitljivkom (hiper) ravninom;
(Traži se $M > 2$ dečitljivkih funkcija)
2. slučaj: svaki je razred separabilan od svakog drugog razreda;
(Traži se $M(M-1)/2$ dečitljivkih funkcija)
3. slučaj: postoji M dečitljivkih funkcija: d_1, d_2, \dots, d_M ; $\vec{x} \in \omega_i$ ako $d_i(\vec{x}) > d_j(\vec{x})$; $i \neq j$

5.3 DERIVATION OF PATTERN CLASSIFICATION ALGORITHMS

3. slučaj \rightarrow Počevni algoritam perceptron

- istodobno određujemo tešinatske konficijentne vektore: $\vec{w}_1, \vec{w}_2, \dots, \vec{w}_M$
- M razreda vektori za učenje: w_1, w_2, \dots, w_M

U k-tom koraku postupka:

$\vec{x}(k)$ - vektor iz skupa za učenje

$$\vec{x}(k) \in w_i$$

Računamo M decizijskih funkcija:

$$d_j(\vec{x}(k)) = \vec{w}_j^T(k) \vec{x}(k); \\ j=1, 2, \dots, M$$

Ako je

$$d_i(\vec{x}(k)) > d_j(\vec{x}(k)); \\ j=1, 2, \dots, M \quad j \neq i$$

tešinatski vektori se ne "popravljaju":

$$\vec{w}_j(k+1) = \vec{w}_j(k), \quad j=1, 2, \dots, M$$

Ako je

$$d_i(\vec{x}(k)) \leq d_e(\vec{x}(k))$$

popravljaju se vrijednosti tečinskih vektora:

$$\vec{w}_i(k+1) = \vec{w}_i(k) + c\vec{x}(k)$$

$$\vec{w}_e(k+1) = \vec{w}_e(k) - c\vec{x}(k)$$

$$\vec{w}_j(k+1) = \vec{w}_j(k) \text{ za } j=1, 2, \dots, M \quad j \neq i$$

$$j \neq e$$

c - pozitivna konstanta

Postupak konvergira u konačnom broju ponavljanja za proizvoljno izabrane početne vrijednosti vektora tečinskih koeficijenata $\vec{w}_j(1); j=1, 2, \dots, M$

ako su razredi linearno separabilni.

SKUP UZORAKA SA UČENJEM


I SKUP UZORAKA ZA ISPITIVANJE - METODE

ISPITIVANJA

skup uzoraka za učenje - uzorci s poznatom klasifikacijom
(označeni uzorci)

Važna pretpostavka: u uzorcima za učenje sadržana je redina informacija o svojstvima razreda kojima uzorci pripadaju

1. Ako imamo dovoljno veliki skup uzoraka s poznatom klasifikacijom



Holdout metoda

$$\#S_u = N$$

S_u - skup uzoraka sa učenje

S_i - skup uzoraka za ispitivanje

$$S = S_u \cup S_i ; \quad S_u \cap S_i = \emptyset$$

S - skup uzoraka s poznatom klasifikacijom

grupna učenja decizijama funkcija potencijalnim funkcijama

Dosudotni postupci \rightarrow unaprijed smo pretpostavili oblik decizijске funkcije

Potencijalne funkcije dopuštaju učenje decizijskih funkcija bez pretpostavke o konacnom obliku decizijskog funkcije

Decizijске funkcije mogu se generirati uporabom potencijalnih funkcija na temelju uzoraka \vec{x}_k , $k=1, 2, \dots$

Potencijalna funkcija za neki uzorak \vec{x} može se opisati kao:

$$K(\vec{x}, \vec{x}_k) = \sum_{i=1}^{\infty} \lambda_i^2 \varphi_i(\vec{x}) \varphi_i(\vec{x}_k)$$

gdje su $\varphi_i(\vec{x})$ $i=1, 2, \dots$ ortonormalne funkcije i λ_i realni brojevi $\neq 0$ izabrani tako da je $K(\vec{x}, \vec{x})$ ogranicena

$$\text{sa } \vec{x} \in W, \cup W_k.$$

Decizijска funkcija $d(\vec{x})$ konstruira se iz sekvence potencijalnih funkcija $K(\vec{x}, \vec{x}_1), K(\vec{x}, \vec{x}_2), \dots$ koje odgovaraju sljedu uзорака za učenje $\vec{x}_1, \vec{x}_2, \dots$ i koji su predstavljeni stroju tijekom procesa učenja.


Potencijalne funkcije:

Kontinuirane funkcije koje zadovoljavaju sljedeće uvjete:

1. $K(\vec{x}, \vec{x}_k) = K(\vec{x}_k, \vec{x})$
simetrična
2. $K(\vec{x}, \vec{x}_k)$ ima maksimum pri $\vec{x} = \vec{x}_k$
3. $K(\vec{x}, \vec{x}_k) \rightarrow 0$ ako udaljenost $\|\vec{x} - \vec{x}_k\| \rightarrow \infty$

~~ostatak~~ Holdout metode:

- smjeruje se učenje skupa za učenje, skupa za ispitivanje
- tako podjeliti skup S na S_U i S_I ?
- Vjerojatnost greške klasifikatora koji se oblikuje uporabom konavnog stupna za učenje N je uvisko veća negoli je odgovarajuća estimatorska vjerojatnost pogreške ($N \rightarrow \infty$)



2. Leave-One-Out metoda

- metoda pokušava "zaobići" problem podjele skupa označenih uzoraka

Učenje se obavlja uporabom $N-1$ uzoraka a ispitivanje se izvodi uporabom onog jednog preostalog uzorka.

računat → incrementirati brojlo pogreške;

Postupak se ponavlja N puta ali tako da je svaki put isti uz drugi učetak.

Ukupan broj pogrešaka nosi uporužje na procijenu vjerojatnosti pogreške klasifikatora

Nedostatak metode: velika računska složenost

3. Resubstitution metoda (Metoda ponovne zamjene)

Isti se stup podataka koristi, prvo za učenje a zatim za ispitivanje.

- optimistička procjena vjerojatnosti pogreške klasifikatora

zahtijeva se (za svaki učorak):

- dovoljnost informacije
- postojanost enačajki
- geometrijska postojanost

(mala udaljenost medju učorcima u prostoru enačajki enati i mala razlika u svojstvima objekta)

$N?$

Idealno $N \rightarrow \infty$

Preporuka za N

- barem 3 do 5 puta više učoraka za učenje po redusu od broja enačajki (dimensionalnost vektora enačajki)

Primjer: Sustav za autorizaciju
stoba na temelju lica
580 korisnika ($M = 580$)
110 - komponentni vektor enačajki

$$N = 5 * 110 * 580 = 319\,000 !!!$$

slika lica \uparrow

nih snakova

$$M = 30 + 10 = 40$$

w_1, w_2, \dots, w_{40}

Dimensionalnost vektora enačajki

$$n = 18.$$

$$N = 5 * 18 * 40 = 3600$$

\uparrow
slika brojčano -
slovačanih znakova

Pooprćene (linearne) decizijske funkcije

- složenost granica:

lineарне \rightarrow vrlo nelineарне!

- vrlo nelineарне?

Rješenje:

Pooprćni oblik (linearne) decizijske funkcije:

$$d(\vec{x}) = w_1 f_1(\vec{x}) + w_2 f_2(\vec{x}) + \dots + w_k f_k(\vec{x}) + w_{k+1}$$

$$= \sum_{i=1}^{k+1} w_i f_i(\vec{x})$$

$$\{f_i(\vec{x})\}, i=1, 2, \dots, k$$

$$f_{k+1} = 1$$

Paži: $f_i(\vec{x})$

$$\vec{x}^* = \begin{bmatrix} f_1(\vec{x}) \\ f_2(\vec{x}) \\ \vdots \\ f_k(\vec{x}) \\ 1 \end{bmatrix}$$

$$d(\vec{x}) = \vec{w}^T \vec{x}^*$$

$d(\vec{x})$ je linearna funkcija po \vec{x}^*

$$d(\vec{x}) = \vec{w}^T \vec{x}^*$$

$$\vec{x}^* = \begin{bmatrix} f_1(\vec{x}) \\ f_2(\vec{x}) \\ \vdots \\ f_k(\vec{x}) \\ 1 \end{bmatrix}$$

$$\vec{w} = (w_1, w_2, \dots, w_k)$$

Decizijska funkcija $d(\vec{x})$ može se promatrati kao linearna funkcija u k -dimensionalnom prostoru!

Transformacija:

$$\vec{x} \rightarrow \vec{x}^*$$

n -dimenzija \rightarrow k -dimenzija

Vrijedi:

$$k > n$$

$d(\vec{x})$ se često naziva i "virtualno linearne"

Kako izabrati $\{f_i(\vec{x})\}_{i=1}^k$?

Mogućnost:

$$\{f_i(\vec{x})\} \quad f_i(\vec{x}) \text{ u obliku polinoma}$$

- Najjednostavniji slučaj: linearne funkcije

$$\vec{x} = (x_1, x_2, \dots, x_n)^T$$

$$f_i(\vec{x}) = x_i \quad \vec{x} = \vec{x}^*$$

$$k=n$$

- Polinom drugog stupnja:

$$\text{Npr. } n=2 \quad \vec{x} = (x_1, x_2)^T$$

$$d(\vec{x}) = w_{11}x_1^2 + w_{12}x_1x_2 + w_{22}x_2^2 + w_3x_1 + \\ w_4x_2 + w_5$$

$$d(\vec{x}) = \vec{w}^T \vec{x}^*$$

$$\vec{x}^* = (x_1^2, x_1x_2, x_2^2, x_1, x_2, 1)^T$$

Opći slučaj kvadratnog oblika:

$$d(\vec{x}) = \sum_{j=1}^n w_{jj}x_j^2 + \underbrace{\sum_{j=1}^{n-1} \sum_{k=j+1}^n}_{r \text{-takta}} w_{jk}x_jx_k + \underbrace{\sum_{j=1}^n w_jx_j}_{1 \text{-takta}} + w_{n+r}$$

Kvadratnu decijejsku funkciju možemo promatrati kao linearne ("linear by virtue") funkcije s

$$k = \frac{(n+1)(n+2)}{2} \text{ varijabli}$$

$$\{f_1(\vec{x}), \dots, f_n(\vec{x})\} = \{x_1^2, x_2^2, \dots, x_n^2\}$$

$$\{f_{n+1}(\vec{x}), \dots, f_{2n}(\vec{x})\} = \{x_1, x_2, \dots, x_n\}$$

$$\{f_{2n+1}(\vec{x}), \dots, f_k(\vec{x})\} = \{x_1x_2, x_1x_3, \dots, x_{n-1}x_n\}$$

- Decijejske funkcije višeg reda

(polinomi stupnja $r > 2$) možemo promatrati kao linearne funkcije

$$\frac{(n+r)!}{r! n!} \text{ varijabli}$$

n -dimensionalnost vektora \vec{x}

r - stupanj polinoma

RYAII 20002914

red množi g. XKKI

function algorithm can be formulated as:
the correction increment α is used.
Learning algorithms are as:

ALGORITHMS OF PATTERN CLASSIFICATION

s :

$$f_i(\vec{x}) = X_{p_1}^{s_1} X_{p_2}^{s_2} \dots X_{p_r}^{s_r}$$

$$p_1, p_2, \dots, p_r = 1, 2, \dots, n$$

$$s_1, s_2, \dots, s_r = 0, 1$$

Decisijsku funkciju u obliku polinoma r -tog stupnja možemo zapisati u rekurzivnom obliku:

$$d^r(\vec{x}) = \left(\sum_{p_1=1}^n \sum_{p_2=p_1}^n \dots \sum_{p_r=p_{r-1}}^n w_{p_1 p_2 \dots p_r} X_{p_1} X_{p_2} \dots X_{p_r} \right) + d^{r-1}(\vec{x}) ; \quad d^0(\vec{x}) = W_{n+1}$$

Primjer:

za $r=2$ i $n=2$:

$$d^2(\vec{x}) = \sum_{p_1=1}^2 \sum_{p_2=p_1}^2 w_{p_1 p_2} X_{p_1} X_{p_2} + d^1(\vec{x})$$

$$d^1(\vec{x}) = \sum_{p_1=1}^2 w_{p_1} X_{p_1} + d^0(\vec{x})$$

$$d^0(\vec{x}) = w_1 X_1 + w_2 X_2 + w_3$$

$$d^2(\vec{x}) = w_{11} X_1^2 + w_{12} X_1 X_2 + w_{22} X_2^2 + d^1(\vec{x})$$

$$d^1(\vec{x}) = w_{11} X_1^2 + w_{12} X_1 X_2 + w_{22} X_2^2 + w_1 X_1 + w_2 X_2 + w_3$$

$$\vec{W}^T = \begin{bmatrix} w_{11} \\ w_{12} \\ w_{22} \\ w_1 \\ w_2 \\ w_3 \end{bmatrix}$$

$$\vec{x}^* = [X_1^2, X_1 X_2, X_2^2, X_1, X_2, 1]^T$$

Primjer: $r=3$; $n=2$

$$d^3(\vec{x}) = \left(\sum_{p_1=1}^2 \sum_{p_2=p_1}^2 \sum_{p_3=p_2}^2 w_{p_1 p_2 p_3} X_{p_1} X_{p_2} X_{p_3} \right) + d^2(\vec{x}) ;$$

$$d(\vec{x}) = w_{111} X_1^3 + w_{112} X_1^2 X_2 + w_{122} X_1 X_2^2 + w_{222} X_2^3 + d^2(\vec{x})$$


$$d(\vec{x}) = w_{111} X_1^3 + w_{112} X_1^2 X_2 + w_{122} X_1 X_2^2 + w_{222} X_2^3 + w_{11} X_1^2 + w_{12} X_1 X_2 + w_{22} X_2^2 + w_1 X_1 + w_2 X_2 + w_3$$

Cijena koju placamo za linearizaciju:

- broj koeficijenata (težinečkih faktora) za funkciju r-tog stupnja i razlicite n:

$n \setminus r$	1	2	3	...	6	10
1	2	3	4		7	11
2	3	6	10		18	66
3	4	10	20		84	286
:						
9	10	55	220	5005	92378	
10	11	66	286	8008	184756	

Dimensionalnost "lineariziranog prostora"!



Approach
the value of the perceptron algorithm can be found
and training algorithm

5.3 DERIVATION OF PERCEPTRON ALGORITHM

$$\vec{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \\ 1 \end{bmatrix} \quad d(\vec{x}) = \vec{w}^T \vec{x}$$
$$\vec{w} = \begin{bmatrix} w_1 \\ w_2 \\ w_3 \\ w_4 \\ w_5 \end{bmatrix}$$

M računada w_1, w_2, \dots, w_M

Potpustavimo da u k-tom koraku tijekom učenja
vezorak $\hat{x}(k)$ pripada računu w_i .

Racunamo M karakteristickih funkcija.

Ako je

$$d_i[\hat{x}(k)] > d_j[\hat{x}(k)] \quad j=1, 2, \dots, M; \quad j \neq i$$

tečinski vektor se ne ugada:

$$\vec{w}_i(k+1) = \vec{w}_i(k), \quad j=1, 2, \dots, M$$

Potpustavimo da je za neki l

$$d_i[\hat{x}(k)] \leq d_l[\hat{x}(k)]$$

tečinski vektori se sada ugadaju:

$$\vec{w}_i(k+1) = \vec{w}_i(k) + c \hat{x}(k)$$

$$\vec{w}_l(k+1) = \vec{w}_l(k) - c \hat{x}(k)$$

$$\vec{w}_j(k+1) = \vec{w}_j(k), \quad j=1, 2, \dots, M \quad j \neq i \quad j \neq l$$

c - pozitivna konstanta

$\vec{w}_i(1)$ su početni vektori
 $i=1, 2, \dots, M$

The Perceptron Approach

Minimization of the perceptron algorithm
and its convergence


1. MATERIJAL

Zadani je skup učenja za učenje:

- $U_4^1 = \{(0,0)^T, (0,4)^T, (4,0)^T, (4,4)^T\}$

- $U_4^2 = \{(1,1)^T, (1,3)^T, (3,1)^T, (3,3)^T\}$

- $U_4^3 = \{(2,2)^T\}$



Zadane učinke ne moguće odrediti linearnim indec funkcijama!

Pokušajmo kvadratnim $\rightarrow r=2$, $r=8$

$$R = \frac{(n+1)(n+2)}{2} = 6 - \text{dimensionalni prostor}$$

$$\begin{matrix} n=2 \\ n=8 \end{matrix} \quad Z = 2^{16} \rightarrow 6 - \text{dim.}$$

Predlikavanje 2 - u 6-dimens. prostor funkcijama

$$f_1 = x_1^2 \quad f_2 = x_1 x_2 \quad f_3 = x_2^2 \quad f_4 = x_1 \quad f_5 = x_2 \quad f_6 = 1$$



Predlikan skup za učenje je:

$$U_4^1 = \{(0,0,0,0,4)^T, (0,0,16,0,4,1)^T, (16,0,0,4,0,1)^T, (16,16,16,4,4,1)^T\}$$

$$U_4^2 = \{(1,1,1,1,1,1)^T, (1,3,3,1,3,1)^T, (3,3,1,3,1,1)^T, (3,3,3,3,3,1)^T\}$$

5.3 DERIVATION ALGORITHM
Upotrijebimo perceptron algorithm ($M=3$).

Dva od mogućih rezultata (u tvarnosti od izbora početnih vrijednosti):




imeri potencijalnih funkcija:

$$1. K(\vec{x}, \vec{x}_k) = e^{-\alpha \|\vec{x} - \vec{x}_k\|^2}; \alpha > 0$$

$$2. K(\vec{x}, \vec{x}_k) = \frac{1}{1 + \alpha \|\vec{x} - \vec{x}_k\|^2}$$

$$3. K(\vec{x}, \vec{x}_k) = \left| \frac{\sin \alpha \|\vec{x} - \vec{x}_k\|^2}{\alpha \|\vec{x} - \vec{x}_k\|^2} \right|$$

Ilustracija potencijalnih funkcija na
grafu



- Potencijalne funkcije opisuju potencijal
tačke \vec{x} (u prostoru značajki) zbog
naboja \vec{x}_k (u tački prostora)

- Ako je potencijal tačke \vec{x} zbog
jediničnog naboja u tački \vec{x}_k
jednak $K(\vec{x}, \vec{x}_k)$ onda je u
taj tački prosječni potencijal
zbog jediničnih naboja N_i uzorka
iz razreda W_i jednak

$$\frac{1}{N_i} \sum_{k=1}^{N_i} K(\vec{x}, \vec{x}_k)$$

- Uzoreci iz razreda W_1 i W_2 .

- Uzoreci su u prostoru predstavljeni
tačkama kojima je dodijeljen
jedinični naboj
uzorcima iz $W_1 \rightarrow$ pozitivan
jedinični naboj

uzorcima iz $W_2 \rightarrow$ negativan
jedinični naboj

+2 svakom uzorku $\vec{x}_k \in W_1$

-2 svakom uzorku $\vec{x}_k \in W_2$, $k=1, \dots, N$

* (A) $\|w\|_2^2$
requires that the starting weight vector be
in the geometrical discussion of Section 3.3.1
ratio of the distance between the old weight vector
weight vector $w(k+1)$ to the weight vector
pattern hyperplane in the Euclidean space
converges after each weight update.

Učenje perceptronom s užorkom
i svog novoga prouzrokuju
potencijalno polje - potencijal

- Potencijal ima vršnu vrijednost u samoj točki \vec{x}_k i pada s udaljenosti od \vec{x}_k
- Uzorci koji pripadaju razredu w_1 oblikuju "positivni plato" s točkama koje su smještene na vrhovima tog platoa
- Uzorci iz w_2 oblikuju "negativni plato"
- Dva platoa zbog različitosti naboja (+q i -q) oblikuju dva platoa koja su odijeljena udolinom u kojoj je potencijal jednak nuli
- Udolina \rightarrow granica između razreda \rightarrow decizijska funkcija

Postupak učenja:

N uzoraka u skupu za učenje

$$\vec{x}_i \in w_1 \cup w_2$$

Potpustavimo da se decizijska funkcija oblikuje ovako:

$$d_k(\vec{x}) = d_{k-1}(\vec{x}) + r_k K(\vec{x}, \vec{x}_k), \text{ gdje je}$$

$$d_0(\vec{x}) = 0$$

r_k je korektivski faktor

$$r_k = \begin{cases} 0 & \text{ako je } \vec{x}_k \in w_1 \text{ i } d_{k-1}(\vec{x}_k) > 0 \\ 0 & \text{ako je } \vec{x}_k \in w_2 \text{ i } d_{k-1}(\vec{x}_k) < 0 \\ 1 & \text{ako je } \vec{x}_k \in w_1 \text{ i } d_{k-1}(\vec{x}_k) \leq 0 \\ -1 & \text{ako je } \vec{x}_k \in w_2 \text{ i } d_{k-1}(\vec{x}_k) \geq 0 \end{cases}$$

za $k=1$ (uzimamo prvi uzorak iz skupa za učenje)

$$d_1(\vec{x}_1) = 0 + K(\vec{x}, \vec{x}_1)$$

ako je $\vec{x}_1 \in w_1$

$$d_1(\vec{x}_1) = 0 - K(\vec{x}, \vec{x}_1)$$

ako je $\vec{x}_1 \in w_2$

u $k+1$ korak:

- Ako je $\vec{x}_{k+1} \in \omega_1$ i

$$d_k(\vec{x}_{k+1}) > 0 \text{ ili}$$

$$\vec{x}_{k+1} \in \omega_2 \text{ i}$$

$$d_k(\vec{x}_{k+1}) < 0 \text{ tada}$$

$$d_{k+1}(\vec{x}) = d_k(\vec{x})$$

- Ako je $\vec{x}_{k+1} \in \omega_1$ i

$$d_k(\vec{x}_{k+1}) \leq 0 \text{ onda}$$


$$d_{k+1}(\vec{x}) = d_k(\vec{x}) + K(\vec{x}, \vec{x}_{k+1})$$

- Ako je $\vec{x}_{k+1} \in \omega_2$ i $d_k(\vec{x}_{k+1}) \geq 0$

onda

$$d_{k+1}(\vec{x}) = d_k(\vec{x}) - K(\vec{x}, \vec{x}_{k+1})$$

Graficka interpretacija.



korje postupka za $M > 2$ razreda:
razered w_i :

svaka točka područja P_i u prostoru
izačajki koji odgovara uzorcu
iz w_i ima prosječni potencijal
(zlog naboja uzorka iz w_i)
veći od potencijala zlog naboja
uzorka iz ostalih razreda

$$d_i(\vec{x}) = \frac{1}{N_i} \sum_{k=1}^{N_i} K(\vec{x}, \vec{x}_k)$$

W. S. Meisel (1969. godine) je
pokazao da se uvijek može naći
takva potencijalna funkcija
 $K(\vec{x}, \vec{x}_k)$ da granicom

$$d(\vec{x}) = d_i(\vec{x}) - d_j(\vec{x}) = 0$$

pravilno razgranicavamo
uzorce iz skupa za učenje
iz razreda w_i i w_j .

Postupak učenja za $M > 2$

$$d_i^{(k)}(\vec{x}), d_i^{(k)}(\vec{x}) \dots d_i^{(M)}(\vec{x}) = 0$$

- u k -tom koraku učenja obrađujemo
uzorak \vec{x}_k koji pripada razredu w_i .
- decisijsku funkciju u k -tom
koraku određujemo na sljedeći način:

- ako je $\vec{x}_k \in w_i$

$$d_{k-1}^{(i)}(\vec{x}_k) > d_{k-1}^{(j)}(\vec{x}_k) \text{ za } j \neq i$$

funkciju odlučivanja ne mijenjamo
 $d_k^{(i)}(\vec{x}) = d_{k-1}^{(i)}$ $i = 1, 2, \dots, M$

- ako je $\vec{x}_k \notin w_i$ i za neki l
je $d_{k-1}^{(i)}(\vec{x}_k) \leq d_{k-1}^{(l)}(\vec{x}_k)$

Tada MORAMO PORDAVITI DEC. FUNKCIJE

$$d_k^{(i)}(\vec{x}) = d_{k-1}^{(i)} + K(\vec{x}, \vec{x}_k)$$


$$d_k^{(l)}(\vec{x}) = d_{k-1}^{(l)} - K(\vec{x}, \vec{x}_k)$$

$$d_k^{(j)}(\vec{x}) = d_{k-1}^{(j)} \quad j = 1, 2, \dots, M \quad j \neq i, j \neq l$$

Zadana su dva rastreda uzoraka:

$$\omega_1 = \{(0,0)^T, (1,1)^T\}$$

$$\omega_2 = \{(0,1)^T, (1,0)^T\}$$



Izaberimo potencijalnu funkciju $K(\vec{x}, \vec{x}_k) = e^{-\|\vec{x} - \vec{x}_k\|^2}$

$$\alpha = 1$$

Za $n=2$ (dimensionalnost uzorka) potencijalna funkcija ima oblik:

$$K(\vec{x}, \vec{x}_k) = e^{-[(x_1 - x_{k1})^2 + (x_2 - x_{k2})^2]}$$

Započnimo postupkom učenja:

- $\vec{x}_1 = (0,0)^T \in \omega_1$ prvi uzorak za učenje

$$d_0(\vec{x}) = d_0(\vec{x}) + K(\vec{x}, \vec{x}_1), \quad d_0(\vec{x}) = 0$$

$$d_1(\vec{x}) = e^{-[(x_1 - 0)^2 + (x_2 - 0)^2]}$$

$$d_2(\vec{x}) = e^{-(x_1^2 + x_2^2)}$$

- uzorak $\vec{x}_2 = (1,1)^T \in \omega_1$ vrijedi

$$d_1(\vec{x}_2) = e^{-(1+1)} = e^{-2} > 0$$

$$\text{zato je: } d_2(\vec{x}) = d_1(\vec{x}) = e^{-(x_1^2 + x_2^2)}$$

$$\bullet \text{ uzorak } \vec{x}_3 = (1,1)^T \in \omega_2$$

$$d_2(\vec{x}_3) = e^{-(x_1^2 + x_2^2)} = e^{-2} > 0$$

PAZI! $\vec{x}_3 \notin \omega_2$!

$$d_3(\vec{x}) = d_2(\vec{x}) - K(\vec{x}, \vec{x}_3)$$

$$d_3(\vec{x}) = e^{-(x_1^2 + x_2^2)} - [e^{-(x_1^2 + x_2^2)} - e^{-[(x_1 - 1)^2 + (x_2 - 1)^2]}]$$

- za sljedeći uzorak $\vec{x}_4 = (1,0)^T \in \omega_2$ dobivamo:

$$d_3(\vec{x}_4) = e^{-(1^2)} - e^{-[(1^2 + (-1)^2)]}$$

$$= e^{-1} - e^{-2} > 0$$

Moramo popraviti funkciju odlučivanja

$$d_4(\vec{x}) = d_3(\vec{x}) - K(\vec{x}, \vec{x}_4)$$

$$d_4(\vec{x}) = e^{-(x_1^2 + x_2^2)} - e^{-[(x_1^2 + (x_2 - 1)^2)]} - e^{-[(x_1 - 1)^2 + x_2^2]}$$

Provjeravamo da li se funkcijom $d_4(\vec{x})$ može pravilno razvrstati sve uzorce u skupu za učenje!

$$\vec{x}_5 = \vec{x}_1 = (0,0)^T \in \omega_1$$

$$d_4(\vec{x}_5) = e^0 - e^{-1} - e^1 > 0$$

$$d_5(\vec{x}) = d_4(\vec{x})$$

$$\text{za } \vec{x}_6 = \vec{x}_2 = (1, 1)^T \in \omega_1$$

$$d_5(\vec{x}_6) = e^{-2} - e^{-1} - e^{-1} < 0$$

Treba popraviti deciziju funkciju!

$$d_6(\vec{x}) = d_4(\vec{x}) + K(\vec{x}, \vec{x}_6)$$

$$d_6(\vec{x}) = \frac{-e^{-(x_1^2+x_2^2)}}{-e} - \frac{[(x_1^2+(x_2-1)^2)]}{-e} - \frac{[(x_1-1)^2+x_2^2]}{-e}$$

$$+ \frac{e^{-[(x_1-1)^2+(x_2-1)^2]}}{+}$$

$$\text{za } \vec{x}_7 = \vec{x}_3 = (0, 1)^T \in \omega_2 \text{ je}$$

$$d_6(\vec{x}_7) = e^{-1} - e^0 - e^{-2} + e^{-1} < 0 \text{ zato je}$$

$$d_7(\vec{x}) = d_6(\vec{x})$$

$$\text{za } \vec{x}_8 = \vec{x}_4 = (1, 0)^T \in \omega_2 \text{ je}$$

$$d_7(\vec{x}_8) = e^{-1} - e^{-2} - e^0 + e^{-1} < 0 \text{ zato je}$$

$$d_8(\vec{x}) = d_7(\vec{x})$$

$$\text{za } \vec{x}_9 = \vec{x}_1 = (0, 0)^T \in \omega_1 \text{ je}$$

$$d_8(\vec{x}_9) = e^0 - e^{-1} - e^{-1} + e^{-2} > 0 \text{ zato je}$$

$$d_9(\vec{x}) = d_8(\vec{x})$$

$$\text{za } \vec{x}_{10} = \vec{x}_2 = (1, 1)^T \in \omega_1$$

$$d_9(\vec{x}_{10}) = e^{-2} - e^{-1} - e^{-1} + e^0 > 0$$

$$d_{10}(\vec{x}) = d_9(\vec{x})$$

Sve smo uroke iz skupa za učenje pravilno razvrstali funkcijom odlučivanja:

$$d(\vec{x}) = \frac{-e^{-(x_1^2+x_2^2)}}{-e} - \frac{[(x_1^2+(x_2-1)^2)]}{-e} - \frac{[(x_1-1)^2+x_2^2]}{-e} +$$


$$+ \frac{e^{-[(x_1-1)^2+(x_2-1)^2]}}{+}$$

Funkcija odlučivanja ima onoliko eksponencijalnih članova koliko je bilo korekcija u postupku učenja.


KLASIFIKACIJA UZORAKA POMOĆU FUNKCIJA UDALJENOSTI

- jedan od najstarijih i najpoznatijih metoda
- zasnovana na intuiriciji
- mjeri sličnosti između vektora uzorka

vektor = tačka u euklidskom prostoru



gluterna metoda (najstariji metod za grupiranje podataka prema sličnosti grupiranja (engl. clustering))



• KLASIFIKACIJA POMOĆU NAJMANJE UDALJENOSTI

(MINIMUM-DISTANCE PATTERN
CLASSIFICATION)

MJERA UDALJENOSTI BLO KOM FUNKCIJA
NAVA ZADODRAGA UNJETE:

- $D(\vec{x}_k, \vec{x}_c) = 0$ za $\vec{x}_k = \vec{x}_c$
- $D(\vec{x}_k, \vec{x}_c) \neq 0$ za $\vec{x}_k \neq \vec{x}_c$
- $D(\vec{x}_k, \vec{x}_c) = D(\vec{x}_c, \vec{x}_k)$
- $D(\vec{x}_k, \vec{x}_c) \leq D(\vec{x}_k, \vec{x}_f) + D(\vec{x}_f, \vec{x}_c)$

euklidska udaljenost:

$$D = \| \vec{x}_k - \vec{x}_c \| = \sqrt{\sum_{i=1}^n (x_{ki} - x_{ci})^2}$$

- razdjeljuje se grupa u odnosu na translaciju i rotaciju