

a) Postupak učenja za
kriterijsku funkciju

$$J(\vec{w}, \vec{x}) = \frac{1}{2} (|\vec{w}^T \vec{x}| - \vec{w}^T \vec{x})$$

- parcijalna derivacija funkcije


$$\frac{\partial J}{\partial \vec{w}} = \frac{1}{2} [\vec{x} \operatorname{sgn}(\vec{w}^T \vec{x}) - \vec{x}]$$

$$\operatorname{sgn}(\vec{w}^T \vec{x}) = \begin{cases} 1 & \text{ako je } \vec{w}^T \vec{x} > 0 \\ -1 & \text{ako je } \vec{w}^T \vec{x} \leq 0 \end{cases} \quad \frac{d}{dx} (\vec{x}^T \cdot \vec{a}) = \vec{a}$$

UVRSTIMO $\frac{\partial J}{\partial \vec{w}}$

u:

$$\vec{w}(k+1) = \vec{w}(k) - c \left\{ \frac{\partial J}{\partial \vec{w}} \right\}$$



$$\frac{dy}{dx} = \operatorname{sgn} x$$

$$\vec{w}(k+1) = \vec{w}(k) + \frac{c}{2} \{ \vec{x}(k) - \vec{x}(k) \operatorname{sgn}[\vec{w}^T(k) \vec{x}(k)] \}$$

$\vec{x}(k)$ - uzorak iz skupa za učenje
koji se primjenjuje u k-tom
koraku učenja

$$\vec{w}(k+1) = \vec{w}(k) + c \begin{cases} \vec{0} & \text{ako je } \vec{w}^T(k) \vec{x}(k) > 0 \\ \vec{x}(k) & \text{ako je } \vec{w}^T(k) \vec{x}(k) \leq 0 \end{cases}$$



POSTUPAK PERCEPTRONA

SA STALNIM PRIRASTOM

(Rosenblatt, 1962.)

b) Postupak učenja za kriterijsku funkciju :

$$J(\vec{w}, \vec{x}) = \frac{1}{4\vec{x}^T\vec{x}} (|\vec{w}^T\vec{x}|^2 - |\vec{w}^T\vec{x}| \cdot \vec{w}^T\vec{x})$$

Parcijalna derivacija kriterijske funkcije:

$$D_x(u \cdot v) = u \cdot v' + v \cdot u'$$

$$\frac{\partial J}{\partial \vec{w}} = \frac{1}{4\vec{x}^T\vec{x}} [2|\vec{w}^T\vec{x}| \cdot \vec{x} \operatorname{sgn}(\vec{w}^T\vec{x}) - (|\vec{w}^T\vec{x}| \cdot \vec{x} + (\vec{w}^T\vec{x}) \cdot \vec{x} \operatorname{sgn}(\vec{w}^T\vec{x}))]$$

$$\frac{\partial J}{\partial \vec{w}} = \frac{1}{4\vec{x}^T\vec{x}} [2|\vec{w}^T\vec{x}| \vec{x} \operatorname{sgn}(\vec{w}^T\vec{x}) - 2|\vec{w}^T\vec{x}| \cdot \vec{x}]$$

$$(\vec{w}^T\vec{x}) \cdot \vec{x} \cdot \operatorname{sgn}(\vec{w}^T\vec{x}) = |\vec{w}^T\vec{x}| \cdot \vec{x}$$

$$\frac{\partial J}{\partial \vec{w}} = \frac{1}{2\vec{x}^T\vec{x}} [|\vec{w}^T\vec{x}| \vec{x} \operatorname{sgn}(\vec{w}^T\vec{x}) - |\vec{w}^T\vec{x}| \cdot \vec{x}]$$

Postupak učenja:

$$\vec{w}(k+1) = \vec{w}(k) + \lambda \frac{|\vec{w}(k) \cdot \vec{x}(k)|}{2\vec{x}^T(k)\vec{x}(k)} \left[\vec{x}(k) - \vec{x}(k) \cdot \operatorname{sgn}(\vec{w}(k) \cdot \vec{x}(k)) \right]$$

$$\vec{w}(k+1) = \vec{w}(k) + \lambda \frac{|\vec{w}^T(k) \vec{x}(k)|}{\vec{x}^T(k) \vec{x}(k)} \cdot \begin{cases} \vec{0} \text{ ako je } \vec{w}^T(k) \vec{x}(k) > 0 \\ \vec{x}(k) \text{ ako je } \vec{w}^T(k) \cdot \vec{x}(k) \leq 0 \end{cases}$$

λ - korekcijski faktor

- početna vrijednost \vec{w} različita od $\vec{0}$
- ako je $\lambda > 1$ promatrani uzorak se pravilno razvrstava nakon (svake) korekcije vektora \vec{w}
- postoji dokaz da postupak učenja konvergira (za lin. separabilne razrede) za $0 < \lambda < 2$;

UČENJE ZA SLUČAJ $M > 2$ RAZREDA

- Problem učenja koeficijenata linearne decizijske funkcije za $M > 2$ razreda skupa za učenje može se riješiti **poopćenim postupkom perceptrona** ali i postupkom **Ho-Kashyapa**.

Podsjetimo se: 3. slučaja

1. slučaj: svaki od $M > 2$ razreda separatibilan je od ostalih razreda jednom decizijskom (hiper)ravninom;
(Traži se $M > 2$ decizijskih funkcija)
2. slučaj: svaki je razred separatibilan od svakog drugog razreda;
(Traži se $M(M-1)/2$ decizij. funkcija)
3. slučaj: postoji M decizijskih funkcija: d_1, d_2, \dots, d_M ;
 $\vec{x} \in \omega_i$ ako
 $d_i(\vec{x}) > d_j(\vec{x}); \quad i \neq j$
 $i = 1, 2, \dots, M$

3. slučaj

→ Prostani algoritam perceptrona

- istodobno određujemo težinske koeficijente: $\vec{w}_1, \vec{w}_2, \dots, \vec{w}_M$

- M razreda uzoraka za učenje:
 $\omega_1, \omega_2, \dots, \omega_M$

U k -tom koraku postupka:

$\vec{x}(k)$ - uzorak iz skupa za učenje

$$\vec{x}(k) \in \omega_i$$

Računamo M dezijskih funkcija:

$$d_j(\vec{x}(k)) = \vec{w}_j^T(k) \vec{x}(k);$$

$$j = 1, 2, \dots, M$$

Ako je

$$d_i(\vec{x}(k)) > d_j(\vec{x}(k));$$

$$j = 1, 2, \dots, M \quad j \neq i$$

težinski vektori se ne "popravljaju":

$$\vec{w}_j(k+1) = \vec{w}_j(k), \quad j = 1, 2, \dots, M$$

Ako je

$$d_i(\vec{x}(k)) \leq d_\ell(\vec{x}(k))$$

popravlja ju se vrijednosti težinskih vektora :

$$\vec{w}_i(k+1) = \vec{w}_i(k) + c\vec{x}(k)$$

$$\vec{w}_\ell(k+1) = \vec{w}_\ell(k) - c\vec{x}(k)$$

$$\vec{w}_j(k+1) = \vec{w}_j(k) \quad \text{za}$$

$$j=1, 2, \dots, M \quad \begin{matrix} j \neq i \\ j \neq \ell \end{matrix}$$

c - pozitivna konstanta

Postupak konvergira u konačnom broju ponavljanja za proizvoljno izabrane početne vrijednosti vektora težinskih koeficijenata

$$\vec{w}_j(1); \quad j=1, 2, \dots, M$$

ako su razredi **linearno**
separabilni.

pola 1.

Pooprćene (Linearne) decizijske funkcije

- Složenost granica:

Linearne \rightarrow vrlo nelinearne!

- vrlo nelinearne?

Rješenje:

Pooprćeni oblik (linearne) decizijske funkcije:

$$\begin{aligned} d(\vec{x}) &= w_1 f_1(\vec{x}) + w_2 f_2(\vec{x}) + \dots + w_k f_k(\vec{x}) + w_{k+1} \\ &= \sum_{i=1}^{k+1} w_i f_i(\vec{x}) \end{aligned}$$

$$\{f_i(\vec{x})\}, i = 1, 2, \dots, k$$

$$f_{k+1} = 1$$

Pazi: $f_i(\vec{x})$

$$\vec{x}^* = \begin{bmatrix} f_1(\vec{x}) \\ f_2(\vec{x}) \\ \vdots \\ f_k(\vec{x}) \\ 1 \end{bmatrix}$$

$$d(\vec{x}) = \vec{w}^T \vec{x}^*$$

$d(\vec{x})$ je linearna funkcija po \vec{x}^*

$$d(\vec{x}) = \vec{w}^T \vec{x}^*$$

$$\vec{x}^* = \begin{bmatrix} f_1(\vec{x}) \\ f_2(\vec{x}) \\ \vdots \\ f_k(\vec{x}) \\ 1 \end{bmatrix}$$

$$\vec{w} = (w_1, w_2, \dots, w_k, w_{k+1})^T$$

Decizijska funkcija $d(\vec{x})$ može se promatrati kao linearna funkcija u $k+1$ -dimenzionalnom prostoru!

Transformacija:

$$\begin{array}{ccc} \vec{x} / & \xrightarrow{\quad} & \vec{x}^* / \\ n\text{-dimenzija} & & k\text{-dimenzija} \end{array}$$

Vrijedi:

$$k > n$$

$d(\vec{x})$ se često naziva i "virtualno linearna"

Kako izabrati $\{f_i(\vec{x})\}_{i=1}^k$?

Mogućnost:

$\{f_i(\vec{x})\}$ $f_i(\vec{x})$ u obliku polinoma

- Najjednostavniji slučaj: linearna funkcija

$$\vec{x} = (x_1, x_2, \dots, x_n)^T$$

$$f_i(\vec{x}) = x_i$$

$$\vec{x} = \vec{x}^*$$

$$k=n$$

- Polinom drugog stupnja:

Npr. $n=2$ $\vec{x} = (x_1, x_2)^T$

$$d(\vec{x}) = W_{11}x_1^2 + W_{12}x_1x_2 + W_{22}x_2^2 + W_1x_1 + W_2x_2 + W_3$$

$$d(\vec{x}) = \vec{W}^T \vec{x}^*$$

$$\vec{x}^* = (x_1^2, x_1x_2, x_2^2, x_1, x_2, 1)^T$$

Opci slučaj kvadratnog oblika:

$$d(\vec{x}) = \underbrace{\sum_{j=1}^n W_{jj}x_j^2}_{n \text{ izraza}} + \underbrace{\sum_{j=1}^{n-1} \sum_{k=j+1}^n W_{jk}x_jx_k}_{\frac{n(n-1)}{2} \text{ izraza}} + \underbrace{\sum_{j=1}^n W_jx_j}_{n \text{ izraza}} + \underbrace{W_{n+1}}_{1 \text{ izraz}}$$

Kvadratnu decizijsku funkciju možemo promatrati kao linearnu ("Linear by virtue") funkciju s

$$k = \frac{(n+1)(n+2)}{2} \text{ varijabli}$$

$$\{f_1(\vec{x}) \dots f_n(\vec{x})\} = \{x_1^2, x_2^2, \dots, x_n^2\}$$

$$\{f_{n+1}(\vec{x}), \dots, f_{2n}(\vec{x})\} = \{x_1, x_2, \dots, x_n\}$$

$$\{f_{2n+1}(\vec{x}), \dots, f_k(\vec{x})\} = \{x_1 x_2, x_1 x_3, \dots, x_{n-1} x_n\}$$

- Decizijske funkcije višeg reda

(polinomi stupnja $r > 2$) možemo promatrati kao linearne funkcije

$$\frac{(n+r)!}{r! n!} \text{ varijabli}$$

n - dimenzionalnost vektora \vec{x}

r - stupanj polinoma

Funkcije iz skupa $\{f_i(\vec{x})\}$ određene su

s :

$$f_i(\vec{x}) = x_{p_1}^{s_1} x_{p_2}^{s_2} \dots x_{p_r}^{s_r}$$

$$p_1, p_2, \dots, p_r = 1, 2, \dots, n$$

$$s_1, s_2, \dots, s_r = 0, 1$$

Decizijsku funkciju u obliku polinoma r -tog stupnja možemo zapisati u rekursivnom obliku:

$$d^r(\vec{x}) = \left(\sum_{p_1=1}^n \sum_{p_2=p_1}^n \dots \sum_{p_r=p_{r-1}}^n W_{p_1 p_2 \dots p_r} x_{p_1} x_{p_2} \dots x_{p_r} \right) + d^{r-1}(\vec{x}) \quad ; \quad d^0(\vec{x}) = W_{n+1}$$

Primjer:

za $r=2$; $n=2$:

$$d^2(\vec{x}) = \sum_{p_1=1}^2 \sum_{p_2=p_1}^2 W_{p_1 p_2} x_{p_1} x_{p_2} + d^1(\vec{x})$$

$$d^1(\vec{x}) = \sum_{p_1=1}^2 W_{p_1} x_{p_1} + d^0(\vec{x})$$

$$d^1(\vec{x}) = W_1 x_1 + W_2 x_2 + W_3$$

$$d^2(\vec{x}) = w_{11}x_1^2 + w_{12}x_1x_2 + w_{22}x_2^2 + d'(\vec{x})$$

$$d^2(\vec{x}) = w_{11}x_1^2 + w_{12}x_1x_2 + w_{22}x_2^2 + w_1x_1 + w_2x_2 + w_3$$

$$\vec{w}^T = \begin{bmatrix} w_{11} \\ w_{12} \\ w_{22} \\ w_1 \\ w_2 \\ w_3 \end{bmatrix}$$

$$\vec{x}^* = [x_1^2, x_1x_2, x_2^2, x_1, x_2, 1]^T$$

Primjer: $r=3$; $n=2$

$$d^3(\vec{x}) = \left(\sum_{p_1=1}^2 \sum_{p_2=p_1}^2 \sum_{p_3=p_2}^2 w_{p_1 p_2 p_3} x_{p_1} x_{p_2} x_{p_3} \right)$$

$$+ d^2(\vec{x}) ;$$

$$d(\vec{x}) = w_{111}x_1^3 + w_{112}x_1^2x_2 + w_{122}x_1x_2^2 + w_{222}x_2^3 + d^2(\vec{x})$$

$$d(\vec{x}) = w_{111}x_1^3 + w_{112}x_1^2x_2 + w_{122}x_1x_2^2 + w_{222}x_2^3 + w_{11}x_1^2 + w_{12}x_1x_2 + w_{22}x_2^2 + w_1x_1 + w_2x_2 + w_3$$

Cijena koju plaćamo za
linearizaciju:

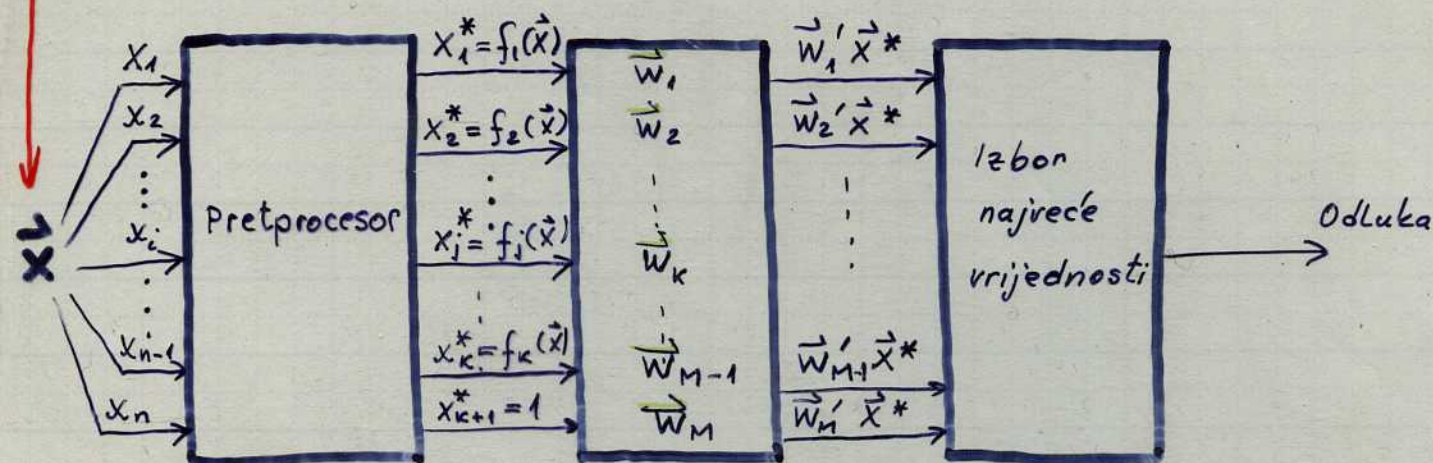
- broj koeficijenata (težijskih
faktora) za funkciju r -tog
stupnja i različite n :

$n \backslash r$	1	2	3	...	6	10
1	2	3	4		7	11
2	3	6	10		28	66
3	4	10	20		84	286
\vdots						
9	10	55	220		5005	92378
10	11	66	286		8008	184756

Dimenzionalnost "lineariziranog
prostora"!

n -dimenzionalni vektor

\vec{x}^* - k -dimenzionalni vektor



$$k \gg n$$

Blok-shema sustava za raspoznavanje

$$\vec{X}^* = \begin{bmatrix} x_1^2 \\ x_1 \cdot x_2 \\ x_2^2 \\ x_1 \\ x_2 \\ 1 \end{bmatrix}$$

$$d(\vec{X}) = \vec{W}^T \cdot \vec{X}^*$$

$$\vec{W} = ?$$

Općeni algoritam perceptrona

252

M razreda : $\omega_1, \omega_2, \dots, \omega_M$

Pretpostavimo da u k -tom koraku tijekom učenja uzorak $\vec{x}(k)$ pripada razredu ω_i .

Računamo M decizijskih funkcija.

Ako je

$$d_i[\vec{x}(k)] > d_j[\vec{x}(k)] \quad j=1,2,\dots,M; \\ j \neq i$$

težinski vektor se ne ugađa :

$$\vec{w}_j(k+1) = \vec{w}_j(k), \quad j=1,2,\dots,M$$

Pretpostavimo da je za neki ℓ

$$d_i[\vec{x}(k)] \leq d_\ell[\vec{x}(k)]$$

težinski vektori se sada ugađaju :

$$\vec{w}_i(k+1) = \vec{w}_i(k) + c \vec{x}(k)$$

$$\vec{w}_\ell(k+1) = \vec{w}_\ell(k) - c \vec{x}(k)$$

$$\vec{w}_j(k+1) = \vec{w}_j(k); \quad j=1,2,\dots,M \\ j \neq i \\ j \neq \ell.$$

c - pozitivna konstanta


$\vec{w}_i(1)$ su proizvoljni početni vektori
 $i=1,2,\dots,M$.

PRIMJER

233.
2 p d 9.

Zadan je skup uzoraka za učenje:

- $U_4^1 = \{(0,0)^T, (0,4)^T, (4,0)^T, (4,4)^T\}$
- $U_4^2 = \{(1,1)^T, (1,3)^T, (3,1)^T, (3,3)^T\}$
- $U_1^3 = \{(2,2)^T\}$



- $\in \omega_1$
- $\in \omega_2$
- $\in \omega_3$

u^s ← oznaka razreda
broj uzoraka "raz."

Zadane uzorke ne možemo odijeliti linearnim dec. funkcijama!

Pokušajmo kvadratnim! $\Rightarrow r=2; n=2$

$$K = \frac{(n+1)(n+2)}{2} = 6 - \text{dimenzionalni prostor}$$

$n=2$ 2-dim. \rightarrow 6-dim.

Preslikavanje 2 - u 6-dimenz. prostor funkcijama

$$f_1 = x_1^2 \quad f_2 = x_1 x_2 \quad f_3 = x_2^2 \quad f_4 = x_1 \quad f_5 = x_2 \quad f_6 = 1$$

Preslikan skup za učenje je:


$$U_4^1 = \{(0,0,0,0,0,1)^T, (0,0,16,0,4,1)^T, (16,0,0,4,0,1)^T, (16,16,16,4,4,1)^T\}$$

$$U_4^2 = \{(1,1,1,1,1,1)^T, (1,3,9,1,3,1)^T, (9,3,1,3,1,1)^T, (9,9,9,3,3,1)^T\}$$


$$U_1^3 = \{(4,4,4,2,2,1)^T\}$$

Upotrijebimo poopćeni algoritam perceptrona
($M=3$).

Dva od mogućih rezultata (u zavisnosti
od izbora početnih vrijednosti):



Decizijske se
granice
dobivaju
nakon nešto
više od
2000
koraka
poopćenog
algoritma
perceptrona




SKUP UZORAKA ZA UČENJE
I SKUP UZORAKA ZA

ISPITIVANJE - METODE
ISPITIVANJA

Skup uzoraka za učenje - uzorci
s poznatom klasifikacijom
(označeni uzorci)

Važna pretpostavka: u uzorcima za
učenje sadržana je većina
informacije o svojstvima
razreda kojima uzorci pripadaju

1. Ako imamo dovoljno veliki skup
uzoraka s poznatom klasifikacijom



Holdout
metoda

$$\#S_u = N$$

S_u - skup uzoraka za
učenje


S_i - skup uzoraka za
ispitivanje

$$S = S_u \cup S_i ; S_u \cap S_i = \emptyset$$

S - skup uzoraka s poznatom
klasifikacijom

Nedostaci Holdout metode:

- smanjuje se veličina skupa za učenje i skupa za ispitivanje
- kako podijeliti skup S na S_u i S_i ?
- Vjerojatnost greške klasifikatora koji se oblikuje uporabom konačnog skupa za učenje N je uvijek veća nego li je odgovarajuća asimptotska vjerojatnost pogreške ($N \rightarrow \infty$)



2. Leave-One-Out metoda

- metoda pokušava "zaobići" problem podjele skupa označenih uzoraka. Učenje se obavlja uporabom $N-1$ uzoraka a ispitivanje se izvodi uporabom onog jednog preostalog uzorka.

Ako je taj uzorak pogrešno razvrstan \rightarrow inkrementira se brojilo pogreške;

Postupak se ponavlja N puta ali tako da je svaki put isključen drugi uzorak.

Ukupan broj pogrešaka nas upućuje na procijenjenu vjerojatnost pogreške klasifikatora

Nedostatak metode: velika računaska složenost

3. Resubstitution metoda (Metoda ponovne zamjene)

Isti se skup podataka koristi, prvo za učenje a zatim za ispitivanje.

- optimistička procjena vjerojatnosti pogreške klasifikatora

Od skupa uzoraka za učenje
zahtijeva se (za svaki uzorak):

- dovoljnost informacije
- postojanost značajki
- geometrijska postojanost

(mala udaljenost među uzorcima u
prostoru značajki znači i malu
razliku u svojstvima objekta)

N ?

Idealno $N \rightarrow \infty$

Preporuka za N

- barem 3 do 5 puta više uzoraka
za učenje po razredu od
broja značajki (dimenzionalnost
vektora značajki)

Primjer: sustav za autorizaciju
osoba na temelju lica

580 korisnika ($M = 580$)

110 - komponentni vektor značajki

$$N \doteq 5 * 110 * 580 = 319\,000 !!!$$

slika lica \uparrow

Primjer: Klasifikacija broječno-slova-
nih znakova

$$M = 30 + 10 = 40$$

$$\omega_1, \omega_2, \dots, \omega_{40}$$

Dimenzionalnost vektora značajki

$$n = 18.$$

$$N = 5 * 18 * 40 = 3600$$

↑
slika broječno-
slovačkih znakova