

Klasifikacija temeljena na
Bayesovoj decizijskoj teoriji

/ statistički pristup raspoznavanju
uzoraka /

PRETPOSTAVKA: PROMATRAMO POJAVLJIVANJE DASKE

- SLUČAJNO POJAVLJIVANJE VRSTE DASKE
(JASEN ILI JELA)

"IGRA PRIRODE" \rightarrow STANJE PRIRODE (ILI VANJSKOG SVETA)

NEKA JE ω

$\omega = \omega_1$ Jasen

$\omega = \omega_2$ Jela

- Budući da se stanje prirode ne može predviđjeti ω se promatra kao slučajna (engl. random) varijabla

- Ako tvornica proizvodi jednak broj jelovih i jasekovih dasaka \rightarrow sljedeći komad daske ima jednaku vjerojatnost da bude jesen ili pak jela

$\left\{ \begin{array}{l} \text{a priori vjerojatnost } P(\omega_1) \text{ / da daska bude} \\ \text{od jasena) /} \\ \text{a priori vjerojatnost } P(\omega_2) \text{ / jelova daska /} \end{array} \right.$
 \rightarrow NAŠE "ZNANJE" O PROCESU

$$\begin{array}{l} P(\omega_1) \geq 0 \\ P(\omega_2) \geq 0 \end{array} \quad ; \quad P(\omega_1) + P(\omega_2) = 1$$

Pretpostavimo da odluku moramo donijeti samo na temelju vrijednosti a priori vjerojatnosti : \downarrow

DECIZIJSKO PRAVILO

Odlučujem se za ω_1 ako je

$$P(\omega_1) > P(\omega_2), \text{ inače}$$

odlučujem ω_2

"Čudno" pravilo \rightarrow uvijek donosim istu odluku i ako znamo da se oba tipa dasaka pojavljuju

Ako je $P(\omega_1) \gg P(\omega_2)$ O.K.

Ako je $P(\omega_1) = P(\omega_2)$ 50% - 50%.

UZMIMO U OBZIR SVJETLINU ODN. TON DRVETA !

- različiti uzorci dasaka daju različitu svjetlinu :

Neka je x kontinuirana slučajna varijabla čija distribucija zavisi od stanja prirode.

$p(x | \omega_j)$ - ^{razdiobe} uvjetna gustoća vjerojatnosti
(state-conditional probability density function)

\rightarrow **gustoća razdiobe vjerojatnosti**


/ funkcija gustoće vjerojatnosti /

Funkcija gustoće razdiobe vjerojatnosti
 (probability density function)
 za kontinuiranu varijablu x
 jeste takva funkcija $f(x)$
 koja ima svojstva:

1. $f(x) \geq 0$ za svaki x

2. $\int_{-\infty}^{+\infty} f(x) dx = 1$

3. $\int_{x_1}^{x_2} f(x) dx = P\{x_1 < x < x_2\}$



PRETPOSTAVKA:

- znamo a priori vjerojatnosti $P(w_j)$

i uvjetne gustoće ^{razdiobe} vjerojatnosti

$$p(x|w_j)$$

engl. likelihood of w_j

→ vjerođostojnost

Pretpostavimo da smo izmjerili svjetlinu daske i dobili vrijednost x

KAKO TO MJERENJE UTJEČE NA NAŠU ODLUKU O PRAVOM STANJU PRIRODE?

BAYESOVO PRAVILO:

(1764. godina)


$$P(w_j|x) = \frac{p(x|w_j) P(w_j)}{p(x)}$$

$$p(x) = \sum_{j=1}^2 p(x|w_j) P(w_j)$$

→ engl. evidence

BAYESOVO PRAVILO → pokazuje kako promatrana vrijednost x mijenja a priori vjerojatnost $P(\omega_j)$ u a posteriori vjerojatnost $P(\omega_j|x)$.

Npr. ako je $P(\omega_1) = \frac{2}{3}$ i $P(\omega_2) = \frac{1}{3}$



- imamo promatranje x za koje je

$$P(\omega_1|x) > P(\omega_2|x)$$

odluka: stanje prirode je ω_1 !

VJEROJATNOST POGREŠKE?

(vjerojatnost pogreške pri svakoj odluci: $P(\text{error}|x)$)

$$P(\text{error}|x) = \begin{cases} P(\omega_1|x) & \text{ako se odlučimo za } \omega_2 \\ P(\omega_2|x) & \text{ako se odlučimo za } \omega_1 \end{cases}$$

MINIMIZIRAMO VJEROJATNOST POGREŠKE DONOŠENJEM SLIJEDEĆIH ODLUKA:

ili
 ω_1 ako je $P(\omega_1|x) > P(\omega_2|x)$
 ω_2 ako je $P(\omega_2|x) > P(\omega_1|x)$.

Da li ovo pravilo minimizira srednju vjerovatnost pogreške?

Da \rightarrow

$$P(\text{error}) = \int_{-\infty}^{+\infty} P(\text{error}, x) dx$$

$$= \int_{-\infty}^{+\infty} P(\text{error}|x) p(x) dx$$

jer ako je sa svaki x $P(\text{error}|x)$ najmanja moguća vrijednost tada i integral mora biti najmanji.

Bayesovo odlučujuće pravilo za minimizaciju vjerovatnosti pogreške:

ODLUČI SE ZA ω_1 ako je
 $P(\omega_1|x) > P(\omega_2|x)$ inače
 odluči se za ω_2

$$P(\omega_j|x) = \frac{p(x|\omega_j) P(\omega_j)}{p(x)}$$

\nwarrow nije bitno!!!
 (samo skalarni faktor

koji osigurava da $P(\omega_1|x) + P(\omega_2|x) = 1$

MODIFICIRANO PRAVILO:

ODLUČI SE ZA ω_1 ako je $p(x|\omega_1) \cdot P(\omega_1) >$
 $> p(x|\omega_2) \cdot P(\omega_2)$
 inače ω_2

Pretpostavimo neke situacije :

- ako je za neki x

$$p(x|\omega_1) = p(x|\omega_2)$$

odluka se temelji na q priori vjerojatnosti

- ako je $P(\omega_1) = P(\omega_2)$


odluka se temelji na $p(x|\omega_j)$

→ vjerojatnost ω_j u odnosu na x .

UOPĆENJE:

- 1) upotreba više od jedne značajke,
- 2) više od dva stanja prirode,
- 3) dopustiti ćemo i akciju umjesto same odluke o stanju prirode,
- 4) uvesti ćemo funkciju gubitka kao općenitiju mjeru u odnosu na vjerojatnost pogreške

PRIMJER:




$$M = 2$$

 $\omega = \omega_1$ JASEN

 $\omega = \omega_2$ JELA

Znamo da je JELA svijetla.

TON drveta - karakteristika za klasifikaciju



x_0 - nije dovoljan

DRUGA KARAKTERISTIKA: IZRAŽENOST STRUKTURE DRVETA!


JASEN ima izraženiju strukturu drveta

VEKTOR UZORKA

$$\vec{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

x_1 - TON

x_2 - STRUKTURA



Decizijsko pravilo temeljeno na statističkom pristupu može se formulirati na dva glavna načina:

(i) Pretvorbom apriorne vjerojatnosti $P(\omega_i)$ u mjerenjem uvjetovanu (aposteriornu) vjerojatnost $P(\omega_i | \vec{x})$;

(ii) Definiranjem mjere očekivane klasifikacijske pogreške ili rizika te izborom decizijskog pravila koje MINIMIZIRA tu mjeru;

Tri jednostavna primjera:

Primjer 1: Nema mjerenja; broj razreda $C=2$

Pretpostavimo da je $P(\omega_1) = 0.7$ i $P(\omega_2) = 0.3$.
Pozor: nismo obavili mjerenje i nemamo vektor značajki!

Kakvo je klasifikacijsko pravilo?

-Označimo vjerojatnost klasifikacijske pogreške sa $P(\text{error})$;

$$P(\text{error}) = P(\text{izabrali } \omega_2 | \omega_1) \cdot P(\omega_1) + P(\text{izabrali } \omega_1 | \omega_2) \cdot P(\omega_2)$$

Decizijsko pravilo: Uvijek izaberi ω_1 jer je $P(\omega_1) > P(\omega_2)$.

$$\begin{aligned} \text{Taj pristup vodi do pogreške} \\ P(\text{error}) &= P(\text{izaberi } \omega_1 | \omega_2) \cdot P(\omega_2) \\ &= (1) \cdot (0.3) = 0.3 \end{aligned}$$


Primjer 2: Jedno mjerenje; $C=2$,
Gaussova gustoća razdiobe
vjerojatnosti

- dimenzionalnost vektora značajki d (ili L) = 1
 $C=2$

- Pretpostavimo da su apriorne vjerojatnosti
jednake $P(w_1) = P(w_2)$.

$$p(x|w_i) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{1}{2} \left(\frac{x - \mu_i}{\sigma} \right)^2 \right\}$$

- poseban slučaj: varijanca i apriorne
vjerojatnosti jednake \rightarrow samo
u srednje vrijednosti različite



Bayesovo pravilo daje: $P(w_i|x) = \frac{p(x|w_i) P(w_i)}{p(x)}$

Decizijsko pravilo:

Izaberi w_1 ako je $p(x|w_1) > p(x|w_2)$

- Ovaj pristup vodi definiranju područja
 R_1 i R_2 (vidi sliku na V6a)

za izabranu klasifikacijsku strategiju
možemo razmotriti klasifikacijsku
pogrešku:

$$P(\text{error}) = P(\vec{x} \text{ je dodjeđen pogrešnom razredu})$$

za $c=2$ imamo:

$$P(\text{error}) = P(\text{izaberi } \omega_1, \text{ a stvarno je } \vec{x} \text{ iz razreda } \omega_2) + \\ P(\text{izaberi } \omega_2, \text{ a stvarno je } \vec{x} \text{ iz razreda } \omega_1)$$

$$= P(\text{error} | \omega_1) \cdot P(\omega_1) + \\ + P(\text{error} | \omega_2) \cdot P(\omega_2)$$

$$P(\text{error}) = P(\hat{x} \in R_2 | \omega_1) \cdot P(\omega_1) + \\ P(\hat{x} \in R_1 | \omega_2) \cdot P(\omega_2) \\ = P(x < \alpha | \omega_2) \cdot P(\omega_2) + \\ + P(x > \alpha | \omega_1) \cdot P(\omega_1)$$

$$P(\text{error}) = P(\omega_2) \int_{-\infty}^{\alpha} p(\xi | \omega_2) d\xi + \\ + P(\omega_1) \int_{\alpha}^{+\infty} p(\xi | \omega_1) d\xi$$

integrali $\int_{-\infty}^{\alpha} \dots$ i $\int_{\alpha}^{+\infty}$ određuju

šrafiranu površinu (vidi sliku na 15a)

(Re)interpretacija Primjera 2:

"Klasifikator na temelju minimalne udaljenosti" (engl. 'Minimum-Distance Classifier')

- izbor praga α vodi dijeljenja prostora R^1 na potprostore (područja)

R_1 i $R_2 \rightarrow$

za slučaj $P(w_1) = P(w_2)$

možemo reći:

"Dodijeli x u R_i pri čemu je x najbliži $\mu_i - u$."

Primjer 3: $c=2$ $d(L|u)=2$

- primjer iz uvoda

$w_1 = \text{jasen}$

$w_2 = \text{jela}$

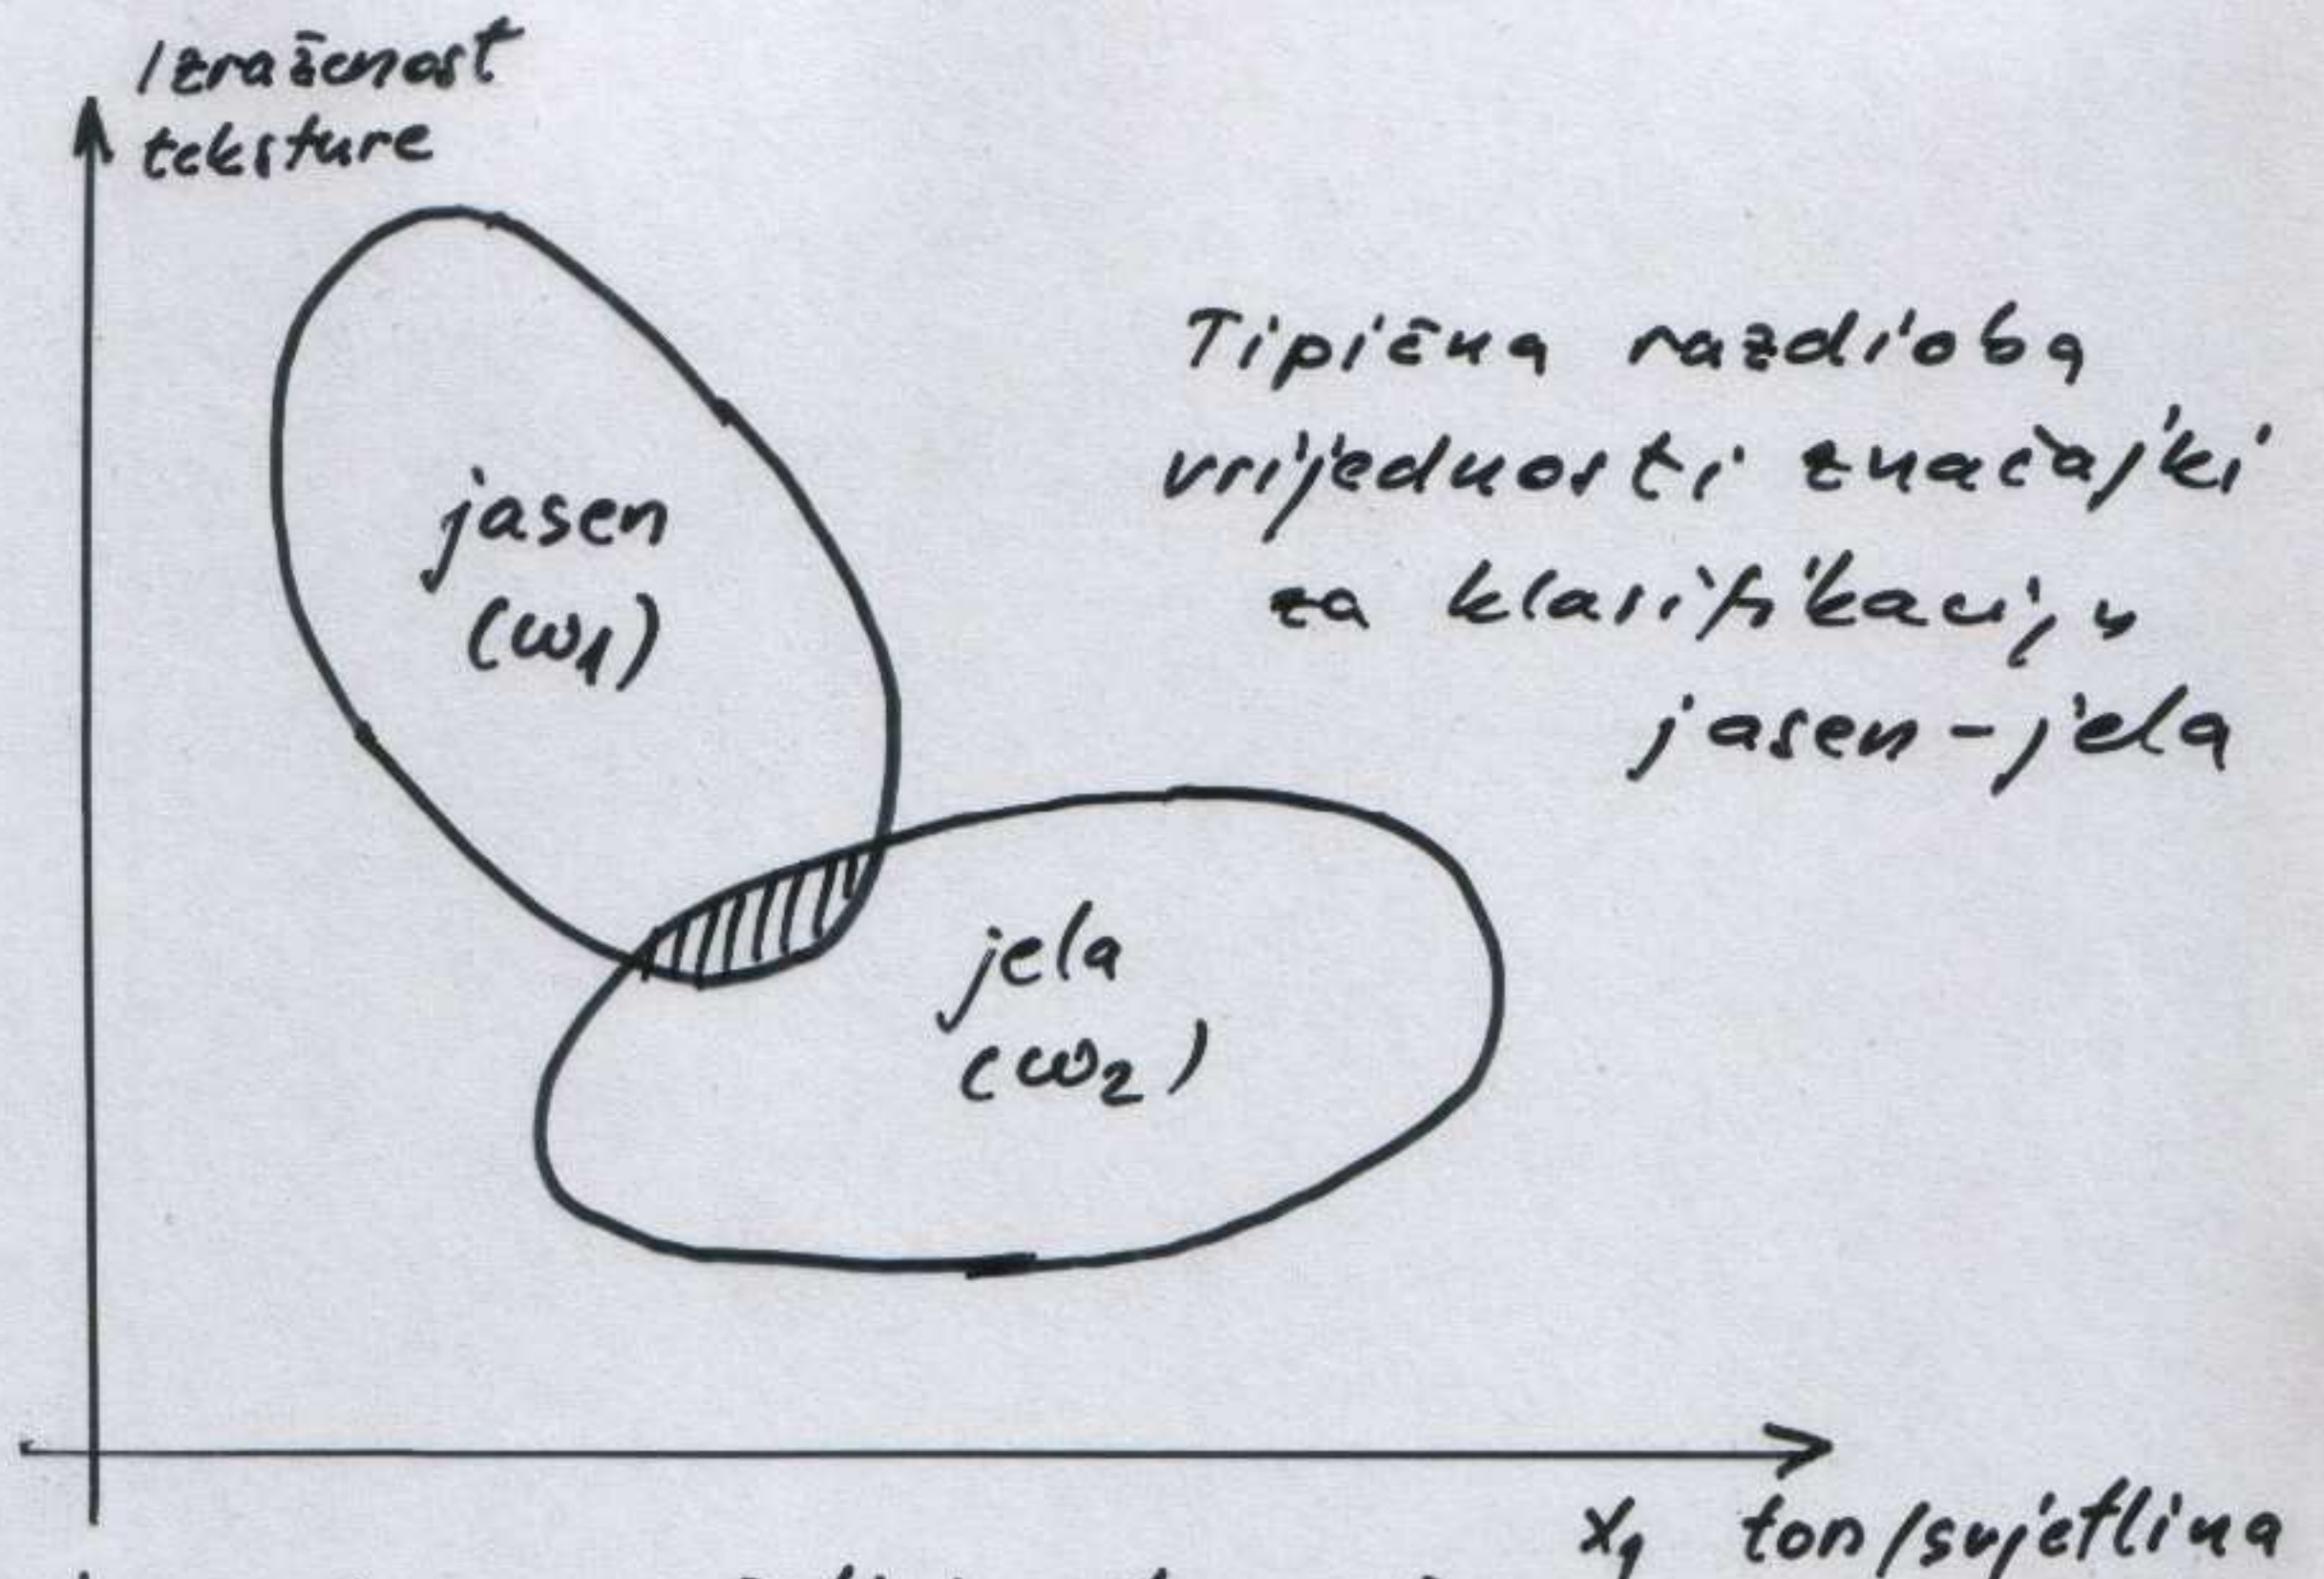
vektor značajki $\vec{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$; $\vec{x}^T = (x_1, x_2)$

x_1 - ton drveta (svjetlića)

x_2 - izraženost teksture

$p(x_1, x_2 | w_i) = p(\vec{x} | w_i)$; $i=1, 2$

$P(w_i)$; $i=1, 2$



Pretpostavimo da se četiri puta više proizvede jasenovih dasaka nego li jelovih

$$P(w_1) = 0.8$$

$$P(w_2) = 0.2$$

- Odrediti strategiju za klasifikaciju dasaka na temelju mjerenja \vec{x} i apriornih vjerojatnosti $P(w_1)$ i $P(w_2)$ uz pretpostavku da su poznate razdiobe gustoća vjerojatnosti $p(\vec{x}|w_1)$ i $p(\vec{x}|w_2)$.

Strategija se temelji na Bayesovom pravilu:

$$P(w_i|\vec{x}) = \frac{p(\vec{x}|w_i) \cdot P(w_i)}{p(\vec{x})}$$

$$p(\vec{x}) = \sum_i p(\vec{x}|w_i) \cdot P(w_i)$$

PRAVILO:

$$\text{izaberi } \begin{cases} \omega_1 \text{ ako } p(\vec{x}|\omega_1) \cdot P(\omega_1) > p(\vec{x}|\omega_2) \cdot P(\omega_2) \\ \omega_2 \text{ ako } p(\vec{x}|\omega_2) \cdot P(\omega_2) > p(\vec{x}|\omega_1) \cdot P(\omega_1) \end{cases}$$

POZOR: Monotonno nepadajuća funkcija
od $P(\omega_i|\vec{x})$ MOŽE SE RABITI ZA
GORNJI TEST!

VAŽNO: U gornjem pravilu klasifikacije
vidimo da su apriorna vjerojatnost
 $P(\omega_i)$ i mjerno-zavisna informacija
 $p(\vec{x}|\omega_i)$ kombinirane u decizijskoj
proceduri!

Primjer 4:

Uniformna gustoća; $c=2$; $d=1$

$$p(x|\omega_1) = \begin{cases} \frac{1}{a_2 - a_1} & \text{za } x \in [a_1, a_2] \\ 0 & \text{drugdje,} \end{cases}$$

$$p(x|\omega_2) = \begin{cases} \frac{1}{b_2 - b_1} & \text{za } x \in [b_1, b_2] \\ 0 & \text{drugdje,} \end{cases}$$





Pretpostavljamo $P(\omega_1) = P(\omega_2)$!

$$(i) \quad \begin{array}{ll} a_1 = 2 & a_2 = 6 \\ b_1 = 8 & b_2 = 12 \end{array}$$

$$(ii) \quad \begin{array}{ll} a_1 = 2 & a_2 = 8 \\ b_1 = 6 & b_2 = 12 \end{array}$$

$$(iii) \quad \begin{array}{ll} a_1 = 2 & a_2 = 6 \\ b_1 = 5 & b_2 = 7 \end{array}$$

$$(iv) \quad \begin{array}{ll} a_1 = 2 & a_2 = 12 \\ b_1 = 5 & b_2 = 7 \end{array}$$



slučaji (ii) - (iv) rezultirat će
 klasifikaciju s pogreškom (engl. nonzero
 classification error)

Primjer 5:

$c=3; d=2$

Gaussova razdioba

$$p(\vec{x}) = (2\pi)^{-\frac{d}{2}} |\Sigma_i|^{-\frac{1}{2}} \exp \left[-\frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma_i^{-1} (\vec{x} - \vec{\mu}_i) \right]$$

Pretpostavimo: $P(\omega_1) = P(\omega_2) = P(\omega_3)$


$$\Sigma_i = \Sigma = \begin{pmatrix} 1 & 0 \\ 0 & 1/2 \end{pmatrix}; i=1,2,3$$

$$p(\vec{x}|\omega_i) = N(\mu_i, \Sigma_i) \quad \vec{\mu}_1 = \begin{pmatrix} 0 \\ 2 \end{pmatrix} \quad \vec{\mu}_3 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$g_i(\vec{x}) = \log \{ p(\vec{x}|\omega_i) \} \quad \vec{\mu}_2 = \begin{pmatrix} 4 \\ 1 \end{pmatrix}$$

$$g_i(\vec{x}) = \underbrace{-\frac{1}{2} (\vec{x} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{x} - \vec{\mu}_i)}_{d_i^2} - \left(\frac{d}{2} \right) \log(2\pi) - \frac{1}{2} \log |\Sigma|$$

$$d_i^2 = (\vec{x} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{x} - \vec{\mu}_i)$$



Funkcije gustoce vjerojatnosti

$$\Sigma^{-1} = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$$

Mahalanobisova !!
udaljenost

Oblik funkcije gustoće razdiobe yjerojatnosti:

V13a

$$(\vec{x} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{x} - \vec{\mu}_i) = k$$

k - pozitivna (pozitivna) konstanta

za ω_1 :

$$\left[\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} - \begin{pmatrix} 0 \\ 2 \end{pmatrix} \right]^T \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \left[\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} - \begin{pmatrix} 0 \\ 2 \end{pmatrix} \right] = k$$

$$\begin{pmatrix} x_1 \\ x_2 - 2 \end{pmatrix}^T \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 - 2 \end{pmatrix} = k$$

$$[x_1, 2(x_2 - 2)] \begin{pmatrix} x_1 \\ x_2 - 2 \end{pmatrix} = k$$

$$x_1^2 + 2(x_2 - 2)^2 = k \quad \text{ili}$$

$$\left(\frac{x_1}{\sqrt{2}} \right)^2 + \left(\frac{x_2 - 2}{1} \right)^2 = \frac{k}{2}$$

elipsa

za ω_2 :

$$(x_1 - 4)^2 + 2(x_2 - 1)^2 = k \quad \text{ili}$$

$$\left(\frac{x_1 - 4}{\sqrt{2}} \right)^2 + \left(\frac{x_2 - 1}{1} \right)^2 = \frac{k}{2} \quad \text{elipsa}$$

za ω_3 :

$$(x_1 - 1)^2 + 2x_2^2 = k \quad \text{ili}$$

$$\left(\frac{x_1 - 1}{\sqrt{2}} \right)^2 + \left(\frac{x_2}{1} \right)^2 = \frac{k}{2}$$

elipsa

$$q_i(\vec{x}) = -(\vec{x} - \vec{\mu}_i)^T \Sigma^{-1} (\vec{x} - \vec{\mu}_i)$$

$$q_i(\vec{x}) = -\|\vec{x} - \vec{\mu}_i\|_{\Sigma^{-1}}^2$$

$$q_i(\vec{x}) = \underbrace{-\vec{x}^T \Sigma^{-1} \vec{x}}_{\text{ne zavisi od } i} + 2\vec{\mu}_i^T \Sigma^{-1} \vec{x} - \vec{\mu}_i^T \Sigma^{-1} \vec{\mu}_i$$

ne zavisi od i

Σ je simetrična!

$$q_i(\vec{x}) = (\Sigma^{-1} \vec{\mu}_i)^T \vec{x} - \frac{1}{2} \vec{\mu}_i^T \Sigma^{-1} \vec{\mu}_i$$

$$\boxed{q_i(\vec{x}) = \vec{w}_i^T \vec{x} - w_{i0}}$$

$$\vec{w}_i = \Sigma^{-1} \vec{\mu}_i$$

$$w_{i0} = +\frac{1}{2} \|\vec{\mu}_i\|_{\Sigma^{-1}}^2$$

Dobivamo:

$$q_1(\vec{x}) = \left[\begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 0 \\ 2 \end{pmatrix} \right]^T \vec{x} - \frac{1}{2} \begin{pmatrix} 0 \\ 2 \end{pmatrix}^T \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 0 \\ 2 \end{pmatrix}$$

$$q_1(\vec{x}) = (0 \ 4) \cdot \vec{x} - \left[(0 \ 2) \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 0 \\ 2 \end{pmatrix} \right] \cdot \frac{1}{2}$$

$$q_1(\vec{x}) = (0, 4) \cdot \vec{x} - \left[0 \ 4 \right] \begin{bmatrix} 0 \\ 2 \end{bmatrix} \cdot \frac{1}{2}$$

$$q_1(\vec{x}) = (0, 4) \cdot \vec{x} - \frac{8}{2}$$

$$q_1(\vec{x}) = 4x_2 - 4$$

Na sličan način:

$$q_2(\vec{x}) = (4 \ 2) \cdot \vec{x} - 9 = 4x_1 + 2x_2 - 9$$

$$q_3(\vec{x}) = (1 \ 0) \cdot \vec{x} - \frac{1}{2} = x_1 - \frac{1}{2}$$

Hiperravnine : $C=3$

$(C^2 - C)/2 = 3$ separabilne
hiperravnine

$$g_i(\vec{x}) = g_j(\vec{x})$$

$$\vec{w}_i^T \vec{x} - w_{i0} = \vec{w}_j^T \vec{x} - w_{j0}$$

$$\vec{w}_{ij}^T \vec{x} - w_{ij0} = 0, \text{ gdje je}$$

$$\vec{w}_{ij} = \vec{w}_i - \vec{w}_j = \sum^{-1} (\vec{\mu}_i - \vec{\mu}_j)$$

$$w_{ij0} = w_{i0} - w_{j0}$$

$$\vec{w}_{12} = \vec{w}_1 - \vec{w}_2 = \begin{pmatrix} 0 \\ 4 \end{pmatrix} - \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \begin{pmatrix} -4 \\ 2 \end{pmatrix}$$

$$w_{120} = -4 - (-9) = 5$$

H_{12} :

$$4x_1 - 2x_2 - 5 = 0$$


Micho:

$$\vec{w}_{23} = \begin{pmatrix} 3 \\ 2 \end{pmatrix}$$

$$H_{23}: 6x_1 + 4x_2 - 17 = 0$$

$$\vec{w}_{31} = \begin{pmatrix} -1 \\ 4 \end{pmatrix}$$

$$H_{31}: 2x_1 - 8x_2 + 7 = 0$$



1) upotreba više od jedne značajke

- umjesto skalar x rabimo vektor značajki $\vec{x} \in \mathbb{R}^d$; \vec{x} je d -dimenzionalni vektor iz Euklidskog prostora \mathbb{R}^d

2) više od dva stanja prirode

- Neka je $\{\omega_1, \dots, \omega_c\}$ konačan skup od c stanja (razreda, kategorija)

3) uvodenje akcije umjesto samo odluke o stanju prirode

- skup $\{\alpha_1, \alpha_2, \dots, \alpha_a\}$ konačan skup od a mogućih akcija

4) funkcija gubitka (engl. loss function) $\lambda(\alpha_i | \omega_j)$

$\lambda(\alpha_i | \omega_j)$ opisuje gubitak nastao poduzimanjem akcije α_i kada je stanje prirode ω_j .

\vec{x} - d -komponentni vektor značajki
 $p(\vec{x} | \omega_j)$ - funkcija ^{razdiobe} uvjetne gustoće vjerojatnosti