

Klasifikacija utemeljena na Bayesovoj decizijskoj teoriji

Statistički pristup raspoznavanju uzoraka

Uvod u raspoznavanje uzoraka

ak. god. 2019/2020

Prof. dr. sc. Slobodan Ribarić

Statistički pristup raspoznavanju uzoraka

Neki osnovni pojmovi:

- Uvjetne (relativne) vjerojatnosti
- Adicijski i multiplikacijski teorem
- Bayesov teorem

Statistički pristup raspoznavanju uzoraka

Formule za uvjetne vjerojatnosti mogu se jednostavno izvesti ako se pođe od relativnih frekvencija

- Promatrajmo dva događaja, A i B, kako se pojavljuju unutar n pokusa.

Pri tome mogu nastupiti ove mogućnosti:

- 1) A nastupi, B ne nastupi, (n_1)
- 2) B nastupi, A ne nastupi, (n_2)
- 3) Nastupe A i B, (n_3)
- 4) Ne nastupe ni A ni B, (n_4)

Neka su n_1 , n_2 , n_3 i n_4 brojevi koji nam predložuju koliko puta je nastupila prva, druga, treća, odnosno četvrta mogućnost, pri čemu vrijedi:

$$n_1 + n_2 + n_3 + n_4 = n$$

Statistički pristup raspoznavanju uzoraka

Relativne frekvencije za pojedine događaje A i B su ove:

$$f(A) = \frac{n_1 + n_3}{n}$$

$$f(B) = \frac{n_2 + n_3}{n}$$

- 1) A nastupi, B ne nastupi, (n_1)
- 2) B nastupi, A ne nastupi, (n_2)
- 3) Nastupe A i B, (n_3)
- 4) Ne nastupe ni A ni B, (n_4)

Relativna frekvencija da će se dogoditi ili događaj A ili događaj B ili oba:

$$f(A \cup B) = \frac{n_1 + n_2 + n_3}{n}$$

Relativna frekvencija da će se dogoditi događaj A i događaj B:

$$f(A \cap B) = \frac{n_3}{n}$$

Statistički pristup raspoznavanju uzoraka

Relativna frekvencija od B pod uvjetom da je nastupio A:

$$f(B | A) = \frac{n_3}{n_1 + n_3}$$

Relativna frekvencija od A pod uvjetom da je nastupio B:

$$f(A | B) = \frac{n_3}{n_2 + n_3}$$

- 1) A nastupi, B ne nastupi, (n_1)
- 2) B nastupi, A ne nastupi, (n_2)
- 3) Nastupe A i B, (n_3)
- 4) Ne nastupe ni A ni B, (n_4)

Statistički pristup raspoznavanju uzoraka

Pokažimo da vrijedi:

$$f(A \cup B) = f(A) + f(B) - f(AB)$$

$$\frac{n_1 + n_2 + n_3}{n} = \frac{n_1 + n_3}{n} + \frac{n_2 + n_3}{n} - \frac{n_3}{n} = \frac{n_1 + n_2 + n_3}{n}$$

$$f(A \cup B) = \frac{n_1 + n_2 + n_3}{n}$$

$$f(A) = \frac{n_1 + n_3}{n}$$

$$f(B) = \frac{n_2 + n_3}{n}$$

$$f(AB) = \frac{n_3}{n}$$

Statistički pristup raspoznavanju uzoraka

Pokažimo da vrijedi:

$$f(A \text{ B}) = f(A)f(B|A) = f(B)f(A|B)$$

$$\begin{aligned} f(A \text{ B}) &= \frac{n_3}{n} \\ f(A) &= \frac{n_1 + n_3}{n} \\ f(B|A) &= \frac{n_3}{n_1 + n_3} \end{aligned}$$
$$\frac{n_3}{n} = \frac{n_1 + n_3}{n} \times \frac{n_3}{n_1 + n_3} = \frac{n_3}{n}$$

Statistički pristup raspoznavanju uzoraka

- Pretpostavimo da broj pokusa $\rightarrow \infty$; relativne frekvencije \rightarrow vjerojatnosti
onda se

$$f(A \cup B) = f(A) + f(B) - f(AB)$$

i

$$f(A B) = f(A)f(B|A) = f(B)f(A|B)$$

pretvaraju u:

$$P(A \cup B) = P(A) + P(B) - P(AB) \quad \text{adicijski teorem}$$

$$P(AB) = P(A)P(B|A) = P(B)P(A|B) \quad \text{multiplikacijski teorem}$$

Statistički pristup raspoznavanju uzoraka

Bayesov teorem

Polazimo od formule $P(AB) = P(A)P(B|A)$, odnosno $P(AB) = P(B)P(A|B)$

/vjerojatnost da se dogode i događaj A i događaj B jednak je produktu apsolutne vjerojatnosti događaja A i relativne vjerojatnosti događaja B, uz uvjet da se dogodi događaj A i obratno /

Iz gornjih jednadžbi sljedi: $P(B|A) = \frac{P(AB)}{P(A)} = \frac{P(B)P(A|B)}{P(A)}$ Bayesov teorem (1764. god.)

Formula pokazuje nam kolika je vjerojatnost da će se dogoditi događaj B, ako se dogodio događaj A – **važno** nalazimo vjerojatnost $P(B|A)$ pomoću vjerojatnosti $P(A|B)$

Statistički pristup raspoznavanju uzoraka

Bayesov teorem (nastavak)

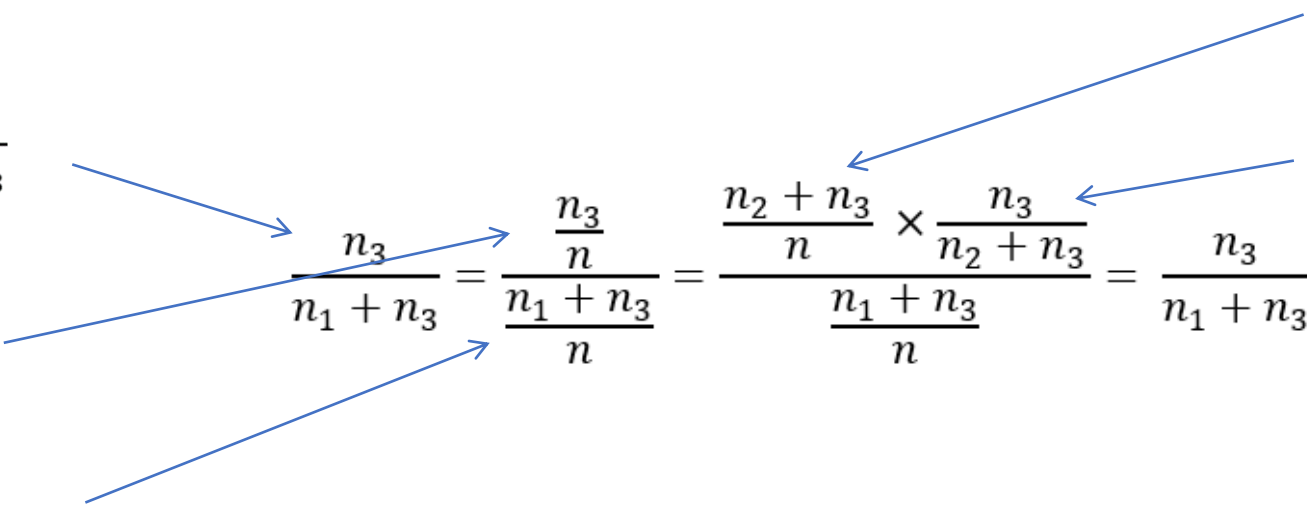
- Pomoću relativnih frekvencija pokažimo da vrijedi izraz za Bayesov teorem:

$$P(B|A) = \frac{P(AB)}{P(A)} = \frac{P(B)P(A|B)}{P(A)}$$

$$f(B | A) = \frac{n_3}{n_1 + n_3}$$

$$f(A B) = \frac{n_3}{n}$$


$$f(A) = \frac{n_1 + n_3}{n}$$

$$\frac{n_3}{n_1 + n_3} = \frac{\frac{n_3}{n}}{\frac{n_1 + n_3}{n}} = \frac{\frac{n_2 + n_3}{n} \times \frac{n_3}{n_2 + n_3}}{\frac{n_1 + n_3}{n}} = \frac{n_3}{n_1 + n_3}$$


Statistički pristup raspoznavanju uzoraka

Bayesov teorem (nastavak)

- neka je X prostor elementarnih događaja
- B_1, B_2, \dots, B_n njegov rastav na disjunktivne dijelove (događaje koji se međusobno isključuju)
- neka je A događaj definiran na istom prostoru X i vrijedi $P(A) > 0$
- za svaki događaj B_k ; $k = 1, 2, \dots, n$ vrijedi uvjetna vjerojatnost



$$f(A \cap B) = f(A)f(B|A) = f(B)f(A|B)$$

$$P(B_k|A) = \frac{P(B_k \cap A)}{P(A)}$$

Statistički pristup raspoznavanju uzoraka

- događaj A može se realizirati istodobno ili s događajem B_1 , ili s događajem B_2 , itd.
- to možemo zapisati:

$$A = B_1A + B_2A + \dots + B_nA$$


- budući da se događaji B_iA , $i = 1, 2, \dots, n$ međusobno isključuju vrijedi:

$$P(A) = \sum_{i=1}^n P(B_i A) = \sum_{i=1}^n P(B_i) P(A|B_i)$$

- Uvrštavanjem izraza za $P(A)$ u $P(B_k|A) = \frac{P(B_kA)}{P(A)}$ dobivamo:


$$P(B_k|A) = \frac{P(B_k)P(A|B_k)}{\sum_{i=1}^n P(B_i) P(A|B_i)}$$

Bayesov teorem



Statistički pristup raspoznavanju uzoraka

Primjer: **deterministički pristup** – statistički pristup



Statistički pristup raspoznavanju uzoraka

Primjer: **deterministički pristup** – statistički pristup (nastavak)

- znamo da je **jela** (daske iz razreda ω_2) **svjetlija**

- na temelju skupa za učenje

(daske s označenom klasifikacijom)


određujemo histogram



- ako odluku o pripadnosti razredu donosimo samo na temelju svjetline drveta – vrijednost praga x_0 nam

određuje razrede

- prag x_0 NIJE dovoljno dobar – klasifikator griješi



Statistički pristup raspoznavanju uzoraka

Primjer: **deterministički pristup** – statistički pristup (nastavak)

- ekspert nam je rekao da se daske mogu razlikovati i po izraženosti strukture drveta:


jasen (razred ω_1) ima izraženiju strukturu drveta

- uključujemo i tu značajku te dobivamo dvodimenzionalni vektor značajki:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \quad \begin{array}{l} x_1 - \text{ton (svjetlina) drveta} \\ x_2 - \text{struktura drveta} \end{array}$$

Statistički pristup raspoznavanju uzoraka

Primjer: **deterministički pristup** – statistički pristup (nastavak)



Statistički pristup raspoznavanju uzoraka

Primjer: deterministički pristup – **statistički pristup** (nastavak)

- Promatramo pojavljivanje daske na pokretnoj vrpci: **slučajno** se pojavljuje vrsta daske (jasen ili jela)
- „igra prirode” – stanje prirode (ili vanjskog svijeta) neka je ω :
 - $\omega = \omega_1$ jasen
 - $\omega = \omega_2$ jela
- budući da se stanje prirode ne može predvidjeti ω se promatra kao **slučajna varijabla**
- pretpostavimo da pilana proizvodi godišnje **jednak** broj jasenovih i jelovih dasaka
 - sljedeća daska ima jednaku vjerojatnost da bude jasen ili pak jela

Statistički pristup raspoznavanju uzoraka

Primjer: deterministički pristup – **statistički pristup** (nastavak)

- apriorna vjerojatnost $P(\omega_1)$ da daska **jasenova**
- apriorna vjerojatnost $P(\omega_2)$ da daska **iz jelovine**
- naše „znanje o procesu”: $P(\omega_1)$ i $P(\omega_2)$

$$P(\omega_1) \geq 0 \text{ i } P(\omega_2) \geq 0 \text{ i } P(\omega_1) + P(\omega_2) = 1$$

Pretpostavimo da odluku moramo donijeti samo na temelju **apriorne vjerojatnosti**:

Decizijsko pravilo:

odlučujem se za ω_1 akko je $P(\omega_1) > P(\omega_2)$, inače odlučujem se za ω_2

Statistički pristup raspoznavanju uzoraka

Primjer: deterministički pristup – **statistički pristup (nastavak)**

Decizijsko pravilo:

odlučujem se za ω_1 akko je $P(\omega_1) > P(\omega_2)$, inače odlučujem se za ω_2

„čudno” pravilo: „klasifikator” uvijek donosi istu odluku iako znamo da se pojavljuju obje vrste dasaka!

- međutim, ako je $P(\omega_1) \gg P(\omega_2)$ – možda bi i „klasifikator” dobro radio – pogreška klasifikatora bi bila jednaka $P(\omega_2)$!
- ako je $P(\omega_1) \sim P(\omega_2)$ ili $P(\omega_1) = P(\omega_2)$ pogreška 50%!

Statistički pristup raspoznavanju uzoraka

Primjer: deterministički pristup – **statistički pristup (nastavak)**

- uzmimo u obzir svjetlinu, odnosno ton drveta!

- znamo da različiti uzorci dasaka imaju različitu svjetlinu:

Neka je x kontinuirana (neprekinuta) slučajna varijabla čija distribucija zavisi od stanja prirode

$p(x|\omega_j)$ - uvjetna gustoća vjerojatnosti (engl. state-conditional probability density function)

Statistički pristup raspoznavanju uzoraka

Primjer: deterministički pristup – **statistički pristup (nastavak)**

Općenito:

Funkcija gustoće vjerojatnosti za kontinuiranu slučajnu varijablu x je takva funkcija $f(x)$

Koja ima svojstva:

1. $f(x) \geq 0$
2. $\int_{-\infty}^{+\infty} f(x)dx = 1$
3. $\int_{x_1}^{x_2} f(x)dx = P\{x_1 < x < x_2\}$

Statistički pristup raspoznavanju uzoraka

Primjer: deterministički pristup – **statistički pristup (nastavak)**

Općenito:

- Za diskretnu slučajnu varijablu koja može poprimiti vrijednost x_1, x_2, \dots, x_n funkcija vjerojatnosti je ona za koju vrijedi:

1. $f(x_i) \geq 0$

2. $\sum_{i=1}^n f(x_i) = 1$

3. $f(x_i) = P(X = x_i)$

Statistički pristup raspoznavanju uzoraka

Primjer: deterministički pristup – **statistički pristup (nastavak)**

Pretpostavka:

-znamo apriorne vjerojatnosti:


$P(\omega_1)$ i $P(\omega_2)$ i uvjetne gustoće vjerojatnosti

$p(x|\omega_j)$, $j = 1, 2$

\swarrow
vjerodostojnost (engl. Likelihood of ω_j)

Pretpostavimo da smo izmjerili svjetlinu daske i dobili vrijednost x !

Kako to mjerenje utječe na odluku o pravom stanju prirode (odluka: daska je iz razreda ω_1 ili ω_2)?



Statistički pristup raspoznavanju uzoraka

Primjer: deterministički pristup – **statistički pristup (nastavak)**

Kako to mjerenje utječe na odluku o pravom stanju prirode (odluka: daska je iz razreda ω_1 ili ω_2)?

Primjenimo Bayesov teorem:

$$P(B_k|A) = \frac{P(B_k)P(A|B_k)}{\sum_{i=1}^n P(B_i) P(A|B_i)}$$

$$P(\omega_j | x) = \frac{p(x|\omega_j)P(\omega_j)}{p(x)}$$

$$p(x) = \sum_{j=1}^2 p(x|\omega_j) P(\omega_j)$$

Bayesov teorem (pravilo) – pokazuje nam kako promatrana (izmjerena) vrijednost x **mijenja** apriornu vjerojatnost $P(\omega_j)$ u aposteriornu vjerojatnost $P(\omega_j | x)$,

Statistički pristup raspoznavanju uzoraka

Primjer: deterministički pristup – **statistički pristup (nastavak)**


- na primjer, ako je $P(\omega_1) = 1/3$ i $P(\omega_2) = 2/3$ onda aposteriorne vjerojatnosti izgledaju ovako

Bayesovo pravilo:

- imamo promatranje (mjerjenje x) za koje je

$$P(\omega_1 | x) > P(\omega_2 | x)$$

ODLUKA: stanje prirode je ω_1



Statistički pristup raspoznavanju uzoraka

Primjer: deterministički pristup – **statistički pristup (nastavak)**

Vjerojatnost pogreške?

(vjerojatnost pogreške pri svakoj odluci: $P(\text{error} | x)$)

$$P(\text{error} | x) = \begin{cases} P(\omega_1 | x) & \text{ako se odlučimo za } \omega_2 \\ P(\omega_2 | x) & \text{ako se odlučimo za } \omega_1 \end{cases}$$

Minimiziramo vjerojatnost pogreške donošenjem

sljedećih odluka:

ω_1 ako je $P(\omega_1 | x) > P(\omega_2 | x)$

ili

ω_2 ako je $P(\omega_2 | x) > P(\omega_1 | x)$

Statistički pristup raspoznavanju uzoraka

Primjer: deterministički pristup – **statistički pristup (nastavak)**

Da li pravilo minimizira srednju vrijednost pogreške?

Da!

$$\begin{aligned} P(\text{error}) &= \int_{-\infty}^{+\infty} P(\text{error}, x) dx \\ &= \int_{-\infty}^{+\infty} P(\text{error} | x) p(x) dx \end{aligned}$$

- jer ako je za svaki x vjerojatnost $P(\text{error} | x)$ *najmanja* moguća vrijednost tada i integral ima najmanju vrijednost.

Statistički pristup raspoznavanju uzoraka

Bayesovo decizijsko pravilo za minimizaciju vjerojatnosti pogreške:

odluči se za ω_1 ako je $P(\omega_1 | x) > P(\omega_2 | x)$, inače odluči se za ω_2

Promotrimo izraze:

$$P(\omega_j | x) = \frac{p(x|\omega_j)P(\omega_j)}{p(x)}$$

nije bitno! Služi samo za skaliranje i osigurava da $P(\omega_1 | x) + P(\omega_2 | x) = 1$

$$p(x) = \sum_{j=1}^2 p(x|\omega_j)P(\omega_j)$$

Modificirano pravilo:

odluči se za ω_1 ako je $p(x|\omega_1)P(\omega_1) > p(x|\omega_2)P(\omega_2)$, inače ω_2

Statistički pristup raspoznavanju uzoraka

Pretpostavimo dvije sljedeće situacije:

- ako je za neki x

$$p(x|\omega_1) = p(x|\omega_2)$$

odluka se temelji na apriornoj vjerojatnosti!

- ako je $P(\omega_1) = P(\omega_2)$


odluka se temelji na $p(x|\omega_j)$

Statistički pristup raspoznavanju uzoraka

Primjer:


- pretpostavimo da su poznate vjerodostojnosti:
- priorne vjerojatnosti $P(\omega_1) = 2/3$ i $P(\omega_2) = 1/3$

Odredite graf aposteriornih vjerojatnosti i definirajte područja koja odgovaraju razredima ω_1 i ω_2 !



Statistički pristup raspoznavanju uzoraka

Skica rješenja:



Statistički pristup raspoznavanju uzoraka

Dva jednostavna primjera:

1. Primjer

Nema mjerenja! Broj razreda $M = 2$; poznate apriorne vjerojatnosti $P(\omega_1) = 0.7$ i $P(\omega_2) = 0.3$

Pozor: nema mjerenja i nemamo vektor značajki!

Kakvo klasifikacijsko pravilo trebamo primijeniti?

- ako je $P(\omega_1) > P(\omega_2)$ onda x razvrstavamo u ω_1

Označimo vjerojatnost klasifikacijske pogreške sa $P(\text{error})$;

U našem slučaju klasifikacijsko pravilo: **Uvijek** izaberi ω_1 jer je $P(\omega_1) > P(\omega_2)$!

Taj pristup vodi do pogreške:

$$\begin{aligned} P(\text{error}) &= P(\text{izaberi } \omega_1 \mid \omega_2) P(\omega_2) \\ &= 1 \cdot 0.3 = 0.3 \end{aligned}$$

Statistički pristup raspoznavanju uzoraka

2. Primjer

Jedno mjerenje - dimenzionalnost vektora značajki $n=1$;

Dva razreda $M=2$;

Pretpostavimo da su apriorne vjerojatnosti jednaka $P(\omega_1) = P(\omega_2)$;

Pretpostavimo Gaussovu gustoću vjerojatnosti:

$$p(x|\omega_i) = \frac{1}{\sqrt{2\pi}\sigma_i} \exp\left\{-\frac{1}{2}\left(\frac{x - \mu_i}{\sigma_i}\right)^2\right\}$$

Poseban slučaj: standardna devijacija $\sigma_1 = \sigma_2$ ali $\mu_1 \neq \mu_2$; $\mu_2 > \mu_1$

Statistički pristup raspoznavanju uzoraka


2. Primjer (nastavak)

$$P(\omega_1) = P(\omega_2)$$

Bayes:

$$P(\omega_j | x) = \frac{p(x|\omega_j)P(\omega_j)}{p(x)}$$

$$p(x) = \sum_{j=1}^2 p(x|\omega_j)P(\omega_j)$$



Modificirano pravilo:

odluči se za ω_1 ako je $p(x|\omega_1)P(\omega_1) > p(x|\omega_2)P(\omega_2)$, inače ω_2

Statistički pristup raspoznavanju uzoraka

2. Primjer (nastavak)


Decizijsko pravilo:

izaberi ω_1 ako je $p(x|\omega_1) > p(x|\omega_2)$ inače ω_2

Prag α određuje klasifikaciju na temelju vrijednosti mjerenja x

R_1 – označava područje razreda ω_1

R_2 – označava područje razreda ω_2



Statistički pristup raspoznavanju uzoraka

2. Primjer (nastavak)

- Za izabranu klasifikacijsku strategiju možemo razmotriti pogrešku klasifikacije:

$$P(\text{error}) = P(x \text{ je dodjeljen pogrešnom razredu})$$


za $M = 2$ imamo:

$$P(\text{error}) = P(\text{izaberi } \omega_1, \text{ a stvarno je } x \text{ iz razreda } \omega_2) + P(\text{izaberi } \omega_2, \text{ a stvarno je } x \text{ iz razreda } \omega_1)$$

$$P(\text{error}) = P(\text{error}|\omega_1)P(\omega_1) + P(\text{error}|\omega_2)P(\omega_2)$$

$$P(\text{error}) = P(x \in R_2|\omega_1)P(\omega_1) + P(x \in R_1|\omega_2)P(\omega_2)$$

$$= P(x < \alpha|\omega_2)P(\omega_2) + P(x > \alpha|\omega_1)P(\omega_1)$$



Statistički pristup raspoznavanju uzoraka

2. Primjer (nastavak)

$$P(\text{error}) = P(\text{error}|\omega_1)P(\omega_1) + P(\text{error}|\omega_2)P(\omega_2)$$


$$P(\text{error}) = P(x \in R_2|\omega_1)P(\omega_1) + P(x \in R_1|\omega_2)P(\omega_2)$$

$$= P(x < \alpha|\omega_2)P(\omega_2) + P(x > \alpha|\omega_1)P(\omega_1)$$

$$\int_{-\infty}^{\alpha} p(\xi | \omega_2) d\xi$$

$$\int_{\alpha}^{+\infty} p(\xi | \omega_1) d\xi$$

Integrali određuju šrafiranu površinu!




Statistički pristup raspoznavanju uzoraka

2. Primjer (nastavak)

- Izbor praga α vodi dijeljenju prostora R^1 potprostore (područja) R_1 i R_2
za slučaj $P(\omega_1) = P(\omega_2)$ možemo reći:

“Dodijeli x u R_i pri čemu je x najbliži μ_i -ju”

Kakav je to klasifikator?



Statistički pristup raspoznavanju uzoraka

- Odgovor:

Klasifikator na temelju udaljenosti!

Statistički pristup raspoznavanju uzoraka

Potrebna pretpostavke:

1. Upotreba više od jedne značajke,
2. Više od dva stanja prirode (broj razreda $M > 2$),
3. Dopustiti ćemo i akciju umjesto same odluke o stanju prirode,
4. Uvest ćemo funkciju gubitka kao općenitiju mjeru u odnosu na vjerojatnost pogreške

Statistički pristup raspoznavanju uzoraka

1. Upotreba više od jedne značajke

- umjesto skalar x koristimo vektor značajki $\mathbf{x} \in R^n$; \mathbf{x} je n -dimenzionalni vektor iz Euklidskog prostora R^n

Primjer

$M = 2$;

$\omega_1 = \text{jasen}$

$\omega_2 = \text{jela}$

vektor značajki: $\mathbf{x} = (x_1, x_2)^T$; $n = 2$

x_1 – ton drveta; x_2 – svjetlina drveta

$p(x_1, x_2 | \omega_i) = p(\mathbf{x} | \omega_i)$; $i = 1, 2$

$P(\omega_i)$; $i = 1, 2$

Statistički pristup raspoznavanju uzoraka

- Multidimenzionalna Gaussova distribucija

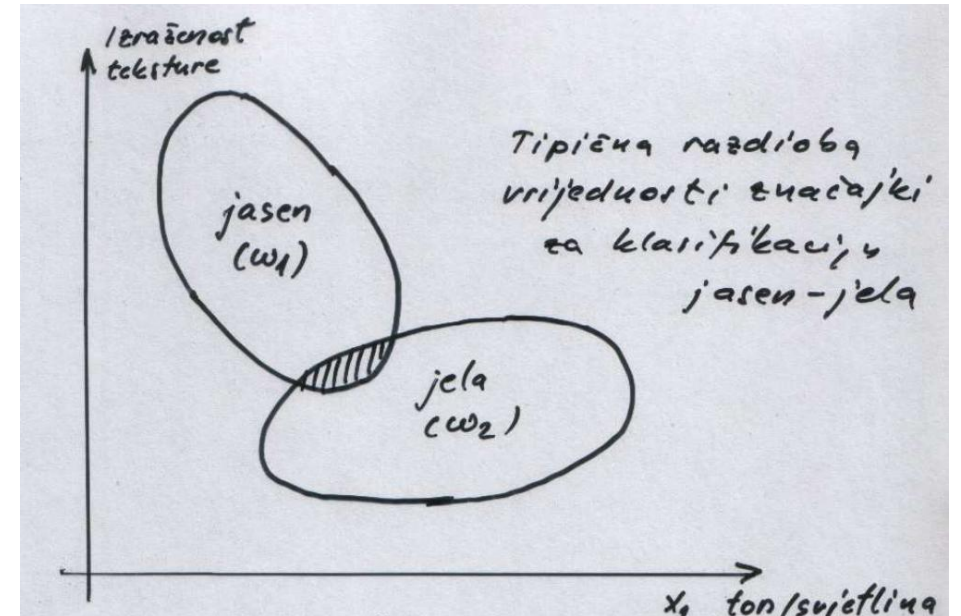
$$p(\mathbf{x}) = (2\pi)^{-\frac{n}{2}} |\Sigma|^{-\frac{1}{2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]$$

\mathbf{x} - n-dimenzionalni vektor

$\boldsymbol{\mu}$ - n-dimenzionalni vektor srednjih vrijednosti

Σ - kovarijacijska matrica $n \times n$

$|\Sigma|$ - determinanta kovarijacijske matrice



Statistički pristup raspoznavanju uzoraka

Primjer (nastavak)

Pretpostavimo da se četiri puta više proizvede jasenovih dasaka negoli jelovih:

$$P(\omega_1) = 0.8; \quad \omega_1 = \text{jasen}$$

$$P(\omega_2) = 0.2; \quad \omega_2 = \text{jela}$$

Treba odrediti strategiju za klasifikaciju dasaka na temelju mjerenja \mathbf{x} i apriornih vjerojatnosti $P(\omega_1)$ i $P(\omega_2)$!

- Uz pretpostavku da su poznate funkcije uvjetne gustoće vjerojatnosti

$$p(\mathbf{x} | \omega_i); i = 1, 2$$

strategiju temeljimo na **Bayesovom pravilu**

Statistički pristup raspoznavanju uzoraka

Bayesovo pravilo:

$$P(\omega_i | \mathbf{x}) = \frac{p(\mathbf{x} | \omega_i) P(\omega_i)}{p(\mathbf{x})}$$

$$p(\mathbf{x}) = \sum_{i=1}^2 p(\mathbf{x} | \omega_i) P(\omega_i)$$

izaberi $\begin{cases} \omega_1 & \text{ako } p(\mathbf{x}|\omega_1)P(\omega_1) > p(\mathbf{x}|\omega_2)P(\omega_2) \\ \omega_2 & \text{ako } p(\mathbf{x}|\omega_2)P(\omega_2) > p(\mathbf{x}|\omega_1)P(\omega_1) \end{cases}$

VAŽNO:

- u klasifikacijskom pravilu kombinirane su apriorna vjerojatnost i **mjerno zavisna informacija**
- Monotono ne padajuća funkcija od $P(\omega_i | \mathbf{x})$ može se rabiti za gornji test!

Statistički pristup raspoznavanju uzoraka

Monotono rastuća (nepadajuća) funkcija od $P(\omega_i | \mathbf{x})$:

Npr. $\log_2 P(\omega_i | \mathbf{x})$ ili $\ln P(\omega_i | \mathbf{x})$

Pravila (općenito):


$$\log_b(xy) = \log_b(x) + \log_b(y)$$

$$\log_b(x/y) = \log_b(x) - \log_b(y)$$

$$\log_b(x^p) = p \log_b(x)$$

$$\log_b(\sqrt[p]{x}) = 1/p \log_b(x)$$

$$\ln(e^x) = x$$



Statistički pristup raspoznavanju uzoraka

Primjer:

M = 3 razreda; dimenzionalnost $n = 2$; Gaussova razdioba

$$p(\mathbf{x}) = (2\pi)^{-\frac{n}{2}} |\Sigma|^{-\frac{1}{2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]$$

Pretpostavimo da je $P(\omega_1) = P(\omega_2) = P(\omega_3)$ – apriorne vjerojatnosti razreda jednake i da su kovarijacijske matrice **jednake**:

$$\Sigma = \Sigma_i; i = 1, 2, 3$$

$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1/2 \end{bmatrix}$$

$$\boldsymbol{\mu}_1 = (0, 2)^T; \boldsymbol{\mu}_2 = (4, 1)^T; \boldsymbol{\mu}_3 = (1, 0)^T$$

Statistički pristup raspoznavanju uzoraka

$$P(\omega_1) = P(\omega_2) = P(\omega_3)$$

$$\boldsymbol{\mu}_1 = (0, 2)^T; \boldsymbol{\mu}_2 = (4, 1)^T; \boldsymbol{\mu}_3 = (1, 0)^T$$


$$d_i(\mathbf{x}) = \log\{p(\mathbf{x}|\omega_i)\}$$

$$= \log\{(2\pi)^{-n/2} |\Sigma|^{-\frac{1}{2}} \exp[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_i)]\}$$

$$= -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_i) - \underbrace{\left(\frac{n}{2}\right) \log(2\pi) - \frac{1}{2} \log|\Sigma|}_{\text{ne zavisi od } i}$$

$$mdi^2 = (\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_i)$$

- (kvadrat) Mahalanobisove udaljenosti



Statistički pristup raspoznavanju uzoraka

$$mdi^2 = (\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_i)$$

Kada $d_i(\mathbf{x})$ ima najveću vrijedost?

$$d_i(\mathbf{x}) = -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_i) - \underbrace{\left(\frac{n}{2} \log(2\pi) - \frac{1}{2} \log |\Sigma| \right)}_{\text{konstanta}}$$

Onda kada je *mdi² najmanja!*

$$\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1/2 \end{bmatrix} \quad \Sigma^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$$

$$\det A = \det \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} = a_{11}a_{22} - a_{12}a_{21}$$

$$A^{-1} = \frac{1}{\det A} \begin{bmatrix} a_{22} & -a_{12} \\ -a_{21} & a_{11} \end{bmatrix}$$

Statistički pristup raspoznavanju uzoraka

Oblik funkcija gustoće vjerojatnosti:

- za ω_1 : $(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_i)$

$$\left[\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} - \begin{pmatrix} 0 \\ 2 \end{pmatrix} \right]^T \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} \left[\begin{pmatrix} x_1 \\ x_2 \end{pmatrix} - \begin{pmatrix} 0 \\ 2 \end{pmatrix} \right] = k \text{ (neka konstanta)}$$

$$\begin{pmatrix} x_1 \\ x_2 - 2 \end{pmatrix}^T \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} \begin{pmatrix} x_1 \\ x_2 - 2 \end{pmatrix} = k$$

$$(x_1, x_2 - 2) \begin{pmatrix} x_1 \\ 2(x_2 - 2) \end{pmatrix} = k$$

$$x_1^2 + 2(x_2 - 2)^2 = k \quad \text{ili}$$

$$\left(\frac{x_1}{\sqrt{2}} \right)^2 + \left(\frac{x_2 - 2}{1} \right)^2 = \frac{k}{2} \quad \text{jednadžba elipse}$$

Statistički pristup raspoznavanju uzoraka

Jednadžba elipse

- ako se koordinatne osi poklapaju s osima elipse, tada jednadžba elipse u normalnom obliku glasi:


$$\frac{x^2}{a^2} + \frac{y^2}{b^2} = 1$$

- jednadžba elipse sa središtem točki S određenoj koordinatama S(p, q) i poluosima a i b

$$\frac{(x - p)^2}{a^2} + \frac{(y - q)^2}{b^2} = 1$$

$$\left(\frac{x_1}{\sqrt{2}}\right)^2 + \left(\frac{x_2 - 2}{1}\right)^2 = \frac{k}{2}$$

$$S(p, q) = (0, 2)$$



Statistički pristup raspoznavanju uzoraka

Oblik funkcija gustoće vjerojatnosti:


- za ω_2 (izvodimo slično kao za ω_1):

$$(x_1 - 4)^2 + 2(x_2 - 1)^2 = k$$

$$\left(\frac{x_1 - 4}{\sqrt{2}}\right)^2 + \left(\frac{x_2 - 1}{1}\right)^2 = \frac{k}{2}$$

- za ω_3 :

$$\left(\frac{x_1 - 1}{\sqrt{2}}\right)^2 + \left(\frac{x_2}{1}\right)^2 = \frac{k}{2}$$



Statistički pristup raspoznavanju uzoraka

Odredimo decizijske funkcije: ; $i = 1, 2, 3!$

$$d_i(\mathbf{x}) = -(\mathbf{x} - \boldsymbol{\mu}_i)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_i)$$

$$d_i(\mathbf{x}) = -\|\mathbf{x} - \boldsymbol{\mu}_i\|_{\Sigma^{-1}}^2 \quad \text{oznaka za Mahalanobisovu udaljenost}$$

$$d_i(\mathbf{x}) = \underbrace{-\mathbf{x}^T \Sigma^{-1} \mathbf{x} + 2\boldsymbol{\mu}_i^T \Sigma^{-1} \mathbf{x}}_{\text{ne zavisi od } i} - \boldsymbol{\mu}_i^T \Sigma^{-1} \boldsymbol{\mu}_i$$

ne zavisi od i

Statistički pristup raspoznavanju uzoraka

$$d_i(\mathbf{x}) = 2\boldsymbol{\mu}_i^T \Sigma^{-1} \mathbf{x} - \boldsymbol{\mu}_i^T \Sigma^{-1} \boldsymbol{\mu}_i / 2$$

$$d_i(\mathbf{x}) = \boldsymbol{\mu}_i^T \Sigma^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_i^T \Sigma^{-1} \boldsymbol{\mu}_i$$

$$d_i(\mathbf{x}) = \boldsymbol{\mu}_i^T \Sigma^{-1} \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_i^T \Sigma^{-1} \boldsymbol{\mu}_i$$

Σ je simetrična matrica!

$$d_i(\mathbf{x}) = (\Sigma^{-1} \boldsymbol{\mu}_i)^T \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_i^T \Sigma^{-1} \boldsymbol{\mu}_i$$

$$d_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} - w_{i0}$$

$$\mathbf{w}_i = \Sigma^{-1} \boldsymbol{\mu}_i$$

$$w_{i0} = + \frac{1}{2} \|\boldsymbol{\mu}_i\|_{\Sigma^{-1}}^2$$

Statistički pristup raspoznavanju uzoraka

$$d_i(\mathbf{x}) = (\Sigma^{-1} \boldsymbol{\mu}_i)^T \mathbf{x} - \frac{1}{2} \boldsymbol{\mu}_i^T \Sigma^{-1} \boldsymbol{\mu}_i$$

$$d_i(\mathbf{x}) = \mathbf{w}_i^T \mathbf{x} - w_{i0}$$

$$\mathbf{w}_i = \Sigma^{-1} \boldsymbol{\mu}_i$$

$$w_{i0} = + \frac{1}{2} \|\boldsymbol{\mu}_i\|_{\Sigma^{-1}}^2$$

- Za decizijsku funkciju $d_1(\mathbf{x})$ dobivamo:

$$d_1(\mathbf{x}) = \left[\begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 0 \\ 2 \end{bmatrix} \right]^T \mathbf{x} - \frac{1}{2} \begin{bmatrix} 0 \\ 2 \end{bmatrix}^T \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 0 \\ 2 \end{bmatrix}$$

$$d_1(\mathbf{x}) = [0 \ 4] \mathbf{x} - \frac{1}{2} [[0 \ 2] \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 0 \\ 2 \end{bmatrix}]$$

$$d_1(\mathbf{x}) = [0 \ 4] \mathbf{x} - 4$$

$$d_1(\mathbf{x}) = 4 x_2 - 4$$

Statistički pristup raspoznavanju uzoraka

Na sličan način dobivamo $d_2(\mathbf{x})$ i $d_3(\mathbf{x})$:

$$d_2(\mathbf{x}) = [4 \ 2] \mathbf{x} - 9 = 4x_1 + 2x_2 - 9$$

$$d_3(\mathbf{x}) = [1 \ 0] \mathbf{x} - \frac{1}{2} = x_1 - \frac{1}{2}$$

- za vježbu izvesti $d_2(\mathbf{x})$ i $d_3(\mathbf{x})$!

Statistički pristup raspoznavanju uzoraka

- Nađimo (hiper)ravnine , odnosno granice potprostora koji odgovaraju pojedinim razredima
- za $M = 3$ imamo $M(M-1)/2$ separatibilnih granica


$$d_i(\mathbf{x}) = d_j(\mathbf{x})$$

$$\mathbf{w}_i^T \mathbf{x} - w_{0i} = \mathbf{w}_j^T \mathbf{x} - w_{0j}$$

$$\mathbf{w}_{ij}^T \mathbf{x} - w_{0ij} = 0$$

$$\mathbf{w}_{ij} = \mathbf{w}_i - \mathbf{w}_j = \Sigma^{-1}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)$$

$$w_{0ij} = w_{0i} - w_{0j}$$

$$\mathbf{w}_i = \Sigma^{-1} \boldsymbol{\mu}_i$$


Statistički pristup raspoznavanju uzoraka

- za H_{12} imamo: $\mathbf{w}_{ij} = \mathbf{w}_i - \mathbf{w}_j = \Sigma^{-1}(\boldsymbol{\mu}_i - \boldsymbol{\mu}_j)$

$$w_{0ij} = w_{0i} - w_{0j}$$

$$\mathbf{w}_{12} = \mathbf{w}_1 - \mathbf{w}_2 = \begin{bmatrix} 0 \\ 4 \end{bmatrix} - \begin{bmatrix} 4 \\ 2 \end{bmatrix} = \begin{bmatrix} -4 \\ 2 \end{bmatrix}$$

$$w_{012} = w_{01} - w_{02} = -4 - (-9) = 5$$

$$4x_1 - 2x_2 - 5 = 0$$

Statistički pristup raspoznavanju uzoraka


za H_{12} imamo: $4x_1 - 2x_2 - 5 = 0$

za H_{23} imamo:

$$6x_1 + 4x_2 - 17 = 0$$

za H_{31} imamo:

$$2x_1 - 8x_2 + 7 = 0$$



Statistički pristup raspoznavanju uzoraka

1) Upotreba više od jedne značajke

- umjesto skalara x koristimo vektor značajki $\mathbf{x} \in R^n$; \mathbf{x} je n -dimenzionalni vektor iz Euklidskog prostora R^n

2) Više od dva stanja prirode (broj razreda $M > 2$)

- neka je $\{\omega_1, \omega_2, \dots, \omega_M\}$ konačan skup od M stanja (razreda, kategorija)

3) Dopustiti ćemo i akciju umjesto same odluke o stanju prirode

- uvođenje akcije umjesto same odluke o stanju prirode
skup $\{\alpha_1, \alpha_2, \dots, \alpha_a\}$ konačan skup od mogućih a akcija

Statistički pristup raspoznavanju uzoraka

3) Dopustiti ćemo i akciju umjesto same odluke o stanju prirode

Primjer:

Testiranje na covid-19

ω_1 = “pozitivan na covid-19 test”

ω_2 = “negativan na covid-19 test”

skup akcija $\{\alpha_1, \alpha_2\}$

akcija α_1 – “uputiti u izolaciju”

akcija α_2 – “nije potrebna izolacija”

Statistički pristup raspoznavanju uzoraka

4) Uvest ćemo **funkciju gubitka kao općenitiju mjeru** u odnosu na vjerojatnost pogreške

- funkcija gubitka (engl. Loss function)

$\lambda(\alpha_i | \omega_j)$ opisuje gubitak nastao poduzimanjem akcije α_i kada je stanje prirode ω_j

Primjer:

Testiranje na covid-19

ω_1 = “pozitivan na covid-19 test”

ω_2 = “negativan na covid-19 test”

skup akcija $\{\alpha_1, \alpha_2\}$

akcija α_1 – “uputiti u izolaciju”

akcija α_2 – “nije potrebna izolacija”

gubici $\lambda(\alpha_i | \omega_j)$:

$$\lambda(\alpha_1 | \omega_1) = \lambda(\text{uputiti u izolaciju} | \text{pozitivan na covid – 19 test})$$

$$\lambda(\alpha_1 | \omega_2) = \lambda(\text{uputiti u izolaciju} | \text{negativan na covid – 19 test})$$

$$\lambda(\alpha_2 | \omega_1) = \lambda(\text{nije potrebna izolacija} | \text{pozitivan na covid – 19 test})$$

$$\lambda(\alpha_2 | \omega_2) = \lambda(\text{nije potrebna izolacija} | \text{negativan na covid – 19 test})$$

Statistički pristup raspoznavanju uzoraka

$$\lambda(\alpha_1|\omega_1) = \lambda(\text{uputiti u izolaciju}|\text{pozitivan na covid} - 19 \text{ test})$$

$$\lambda(\alpha_1|\omega_2) = \lambda(\text{uputiti u izolaciju}|\text{negativan na covid} - 19 \text{ test})$$

$$\lambda(\alpha_2|\omega_1) = \lambda(\text{nije potrebna izolacija}|\text{pozitivan na covid} - 19 \text{ test})$$

$$\lambda(\alpha_2|\omega_2) = \lambda(\text{nije potrebna izolacija}|\text{negativan na covid} - 19 \text{ test})$$

$$\lambda(\alpha_1|\omega_1) < \lambda(\alpha_1|\omega_2)$$

$$\lambda(\alpha_2|\omega_1) > \lambda(\alpha_2|\omega_2)$$

- najveći gubitak:

$$\lambda(\alpha_2|\omega_1) = \lambda(\text{nije potrebna izolacija}|\text{pozitivan na covid} - 19 \text{ test})$$

- najmanji gubitak:

$$\lambda(\alpha_2|\omega_2) = \lambda(\text{nije potrebna izolacija}|\text{negativan na covid} - 19 \text{ test})$$

Statistički pristup raspoznavanju uzoraka

4) Funkcija gubitka

\mathbf{x} – n -komponentni vektor značajki

$p(\mathbf{x}|\omega_j)$ – funkcija uvjetne gustoće vjerojatnosti

$P(\omega_j)$ – apriorna vjerojatnost da je stanje prirode ω_j

$$P(\omega_j | \mathbf{x}) = \frac{p(\mathbf{x}|\omega_j)P(\omega_j)}{p(\mathbf{x})} \text{ – aposteriorna vjerojatnost (Bayesova formula)}$$

$$p(\mathbf{x}) = \sum_{j=1}^M p(\mathbf{x}|\omega_j) P(\omega_j)$$

Statistički pristup raspoznavanju uzoraka

4) Funkcija gubitka (nastavak)

- Pretpostavimo da smo promotрили \mathbf{x} i da smo na temelju tog promatranja poduzeli akciju α_i
 - ako je stanje prirode ω_j , po definiciji, pretrpjeli smo gubitak $\lambda(\alpha_i | \omega_j)$
 - budući da je $P(\omega_j | \mathbf{x})$ vjerojatnost da je stanje prirode zaista ω_j (uz realizaciju uzorka \mathbf{x}), očekujemo gubitak koji nastaje poduzimanjem akcije α_i :

očekivani gubitak
uvjetni rizik

$$R(\alpha_i | \mathbf{x}) = \sum_{j=1}^M \lambda(\alpha_i | \omega_j) P(\omega_j | \mathbf{x})$$

Statistički pristup raspoznavanju uzoraka

$R(\alpha_i|\mathbf{x})$ je uvjetni rizik pridružen akciji α_i a budući da decizijsko pravilo specificira akciju **ukupan je rizik:**

$$R = \int R(\alpha(\mathbf{x})|\mathbf{x})p(\mathbf{x})d\mathbf{x}$$

$d\mathbf{x}$ – volumski element,

a integral se “proteže” nad cijelim prostorom značajki

- Ako je $\alpha(\mathbf{x})$ izabran tako da je $R(\alpha(\mathbf{x}))$ što je moguće manji za svaki \mathbf{x} , onda se i ukupan rizik minimizira

Statistički pristup raspoznavanju uzoraka

4) Funkcija gubitka (nastavak)

Izabiremo strategiju:

Kadgod se susretnemo s određenim \mathbf{x} , možemo MINIMIZIRATI očekivani gubitak tako da izaberemo akciju koja minimizira uvjetni rizik!

- Bayesova decizijska procedura daje optimalnu performansu

Decizijsko pravilo je sada funkcija $\alpha(\mathbf{x})$ koja nam kaže koju akciju poduzeti za svako promatranje \mathbf{x} :

za svaki \mathbf{x} decizijska funkcija $\alpha(\mathbf{x})$ podrazumijeva izbor jedne od akcija $\alpha_1, \alpha_2, \dots, \alpha_a$

Ukupan rizik R je očekivani gubitak pridružen decizijskom pravilu

Statistički pristup raspoznavanju uzoraka

Bayesovo decizijsko pravilo:

Da bismo minimizirali ukupan rizik, izračunajmo uvjetni rizik

$$R(\alpha_i | \mathbf{x}) = \sum_{j=1}^M \lambda(\alpha_i | \omega_j) P(\omega_j | \mathbf{x})$$

za $i = 1, 2, \dots$, a te tada IZABERIMO akciju α_i za koju je $R(\alpha_i | \mathbf{x})$ MINIMUM.

- rezultirajući minimalni ukupni rizik naziva se **Bayesov rizik**

Statistički pristup raspoznavanju uzoraka

Primjer: Klasifikacija za $M = 2$

α_1 – akcija koja odgovara odluci da je pravo stanje prirode ω_1

α_2 – akcija koja odgovara odluci da je pravo stanje prirode ω_2

- raspišimo izraze za uvjetni rizik:

$$R(\alpha_i | \mathbf{x}) = \sum_{j=1}^M \lambda(\alpha_i | \omega_j) P(\omega_j | \mathbf{x})$$

$$R(\alpha_1 | \mathbf{x}) = \lambda(\alpha_1 | \omega_1) P(\omega_1 | \mathbf{x}) + \lambda(\alpha_1 | \omega_2) P(\omega_2 | \mathbf{x})$$

$$R(\alpha_2 | \mathbf{x}) = \lambda(\alpha_2 | \omega_1) P(\omega_1 | \mathbf{x}) + \lambda(\alpha_2 | \omega_2) P(\omega_2 | \mathbf{x})$$

Statistički pristup raspoznavanju uzoraka

Klasifikacija za $M = 2$ (nastavak)

Bayesovo decizijsko pravilo

odluči se za ω_1 ako je

$$R(\alpha_1|\mathbf{x}) < R(\alpha_2|\mathbf{x})$$

zapišimo kraće $\lambda(\alpha_i|\omega_j) = \lambda_{ij}$

$$R(\alpha_1|\mathbf{x}) = \lambda(\alpha_1|\omega_1)P(\omega_1|\mathbf{x}) + \lambda(\alpha_1|\omega_2)P(\omega_2|\mathbf{x})$$

$$R(\alpha_2|\mathbf{x}) = \lambda(\alpha_2|\omega_1)P(\omega_1|\mathbf{x}) + \lambda(\alpha_2|\omega_2)P(\omega_2|\mathbf{x})$$

$$\lambda_{11} P(\omega_1|\mathbf{x}) + \lambda_{12} P(\omega_2|\mathbf{x}) < \lambda_{21} P(\omega_1|\mathbf{x}) + \lambda_{22} P(\omega_2|\mathbf{x})$$

Statistički pristup raspoznavanju uzoraka

$$\lambda_{11} P(\omega_1|\mathbf{x}) + \lambda_{12} P(\omega_2|\mathbf{x}) < \lambda_{21} P(\omega_1|\mathbf{x}) + \lambda_{22} P(\omega_2|\mathbf{x})$$

$$(\lambda_{11} - \lambda_{21}) P(\omega_1|\mathbf{x}) < (\lambda_{22} - \lambda_{12}) P(\omega_2|\mathbf{x})$$

$$-(\lambda_{21} - \lambda_{11}) P(\omega_1|\mathbf{x}) < -(\lambda_{12} - \lambda_{22}) P(\omega_2|\mathbf{x}) /(-1)$$

$$(\lambda_{21} - \lambda_{11}) P(\omega_1|\mathbf{x}) > (\lambda_{12} - \lambda_{22}) P(\omega_2|\mathbf{x})$$

Statistički pristup raspoznavanju uzoraka

Odlučujemo se za ω_1 ako je

$$(\lambda_{21} - \lambda_{11}) P(\omega_1 | \mathbf{x}) > (\lambda_{12} - \lambda_{22}) P(\omega_2 | \mathbf{x})$$

općenito vrijedi da je

$$\lambda_{11} < \lambda_{21} \text{ i } \lambda_{22} < \lambda_{12}$$

(gubitak za ispravnu klasifikaciju manji je negoli za neispravnu (pogrešnu))

$$\lambda_{21} - \lambda_{11} > 0$$

$$\lambda_{12} - \lambda_{22} > 0$$

Statistički pristup raspoznavanju uzoraka

Odlučujemo se za ω_1 ako je

$$(\lambda_{21} - \lambda_{11}) P(\omega_1 | \mathbf{x}) > (\lambda_{12} - \lambda_{22}) P(\omega_2 | \mathbf{x})$$

$$(\lambda_{21} - \lambda_{11}) p(\mathbf{x} | \omega_1) P(\omega_1) > (\lambda_{12} - \lambda_{22}) p(\mathbf{x} | \omega_2) P(\omega_2)$$

omjer vjerodostojnosti
(engl. Likelihood ratio)

$$\frac{p(\mathbf{x} | \omega_1)}{p(\mathbf{x} | \omega_2)} > \frac{(\lambda_{12} - \lambda_{22}) P(\omega_2)}{(\lambda_{21} - \lambda_{11}) P(\omega_1)}$$

Statistički pristup raspoznavanju uzoraka

$$(\lambda_{21} - \lambda_{11})p(\mathbf{x}|\omega_1)P(\omega_1) > (\lambda_{12} - \lambda_{22})p(\mathbf{x}|\omega_2)P(\omega_2)$$

$$\frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} > \frac{(\lambda_{12} - \lambda_{22}) P(\omega_2)}{(\lambda_{21} - \lambda_{11}) P(\omega_1)}$$

- Odlučujemo se za ω_1 ako je omjer vjerodostojnosti prešao prag koji je **nezavisan** od \mathbf{x} !

Prag je:

$$\frac{(\lambda_{12} - \lambda_{22}) P(\omega_2)}{(\lambda_{21} - \lambda_{11}) P(\omega_1)}$$

Statistički pristup raspoznavanju uzoraka

Klasifikacija s najmanjom pogreškom

U problemu klasifikacije svakom se stanju prirode (obično) pridružuje jedan od M razreda, i akcija α_i se tumači kao odluka da je pravo stanje prirode ω_i :

- ako je α_i akcija poduzeta i ako je pravo stanje prirode ω_j tada je odluka ispravna ako je $i = j$, a pogrešna ako je $i \neq j$,
- ako se pogreška želi izbjeći prirodno je tražiti decizijsko pravilo koje minimizira vjerojatnost pogreške

Statistički pristup raspoznavanju uzoraka

Funkcija gubitka za ovaj slučaj klasifikacije se obično izabire kao **simetrična** ili **nula-jedan funkcija gubitka**:

$$\lambda(\alpha_i | \omega_j) = \begin{cases} 0 & \text{za } i = j \\ 1 & \text{za } i \neq j \end{cases} \quad i, j = 1, 2, \dots, M$$

- funkcija gubitka dodjeljuje gubitak 0 za ispravnu odluku a 1 za bilo koju pogrešnu (sve pogrešne klasifikacije jednako koštaju)

Statistički pristup raspoznavanju uzoraka

Rizik koji odgovara toj funkciji gubitka je:

$$R(\alpha_i | \mathbf{x}) = \sum_{j=1}^M \lambda(\alpha_i | \omega_j) P(\omega_j | \mathbf{x})$$

$$R(\alpha_i | \mathbf{x}) = \lambda(\alpha_i | \omega_1) P(\omega_1 | \mathbf{x}) + \lambda(\alpha_i | \omega_2) P(\omega_2 | \mathbf{x}) + \dots + \lambda(\alpha_i | \omega_M) P(\omega_M | \mathbf{x})$$

$$R(\alpha_i | \mathbf{x}) = \sum_{i \neq j} P(\omega_j | \mathbf{x})$$

$$R(\alpha_i | \mathbf{x}) = 1 - P(\omega_i | \mathbf{x})$$

Minimalan rizik je u slučaju najveće aposteriori vjerojatnosti

$$P(\omega_1 | \mathbf{x}) + P(\omega_2 | \mathbf{x}) + \dots + P(\omega_M | \mathbf{x}) = 1$$

uvjetna vjerojatnost da je akcija α_i

Statistički pristup raspoznavanju uzoraka

Primjer:

$$\frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} > \frac{(\lambda_{12} - \lambda_{22}) P(\omega_2)}{(\lambda_{21} - \lambda_{11}) P(\omega_1)}$$

“0-1” funkcija gubitka:

$\lambda_{22} = 0;$
 $\lambda_{11} = 0;$
 $\lambda_{12} = 1;$
 $\lambda_{21} = 1;$

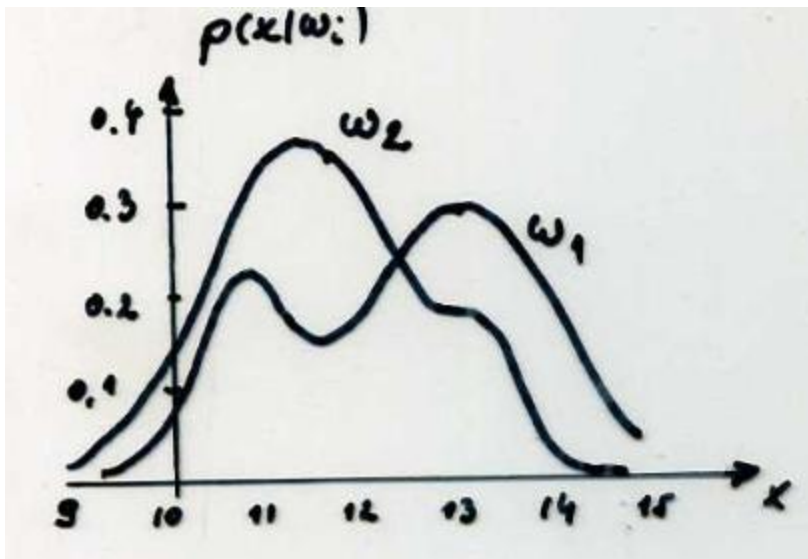
$$\frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} > \frac{(\lambda_{12} - \lambda_{22}) P(\omega_2)}{(\lambda_{21} - \lambda_{11}) P(\omega_1)} \longrightarrow \frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} > \frac{P(\omega_2)}{P(\omega_1)}$$

Statistički pristup raspoznavanju uzoraka

Primjer (nastavak):


funkcije gustoće vjerojatnosti:

$p(x | \omega_i); i = 1, 2$



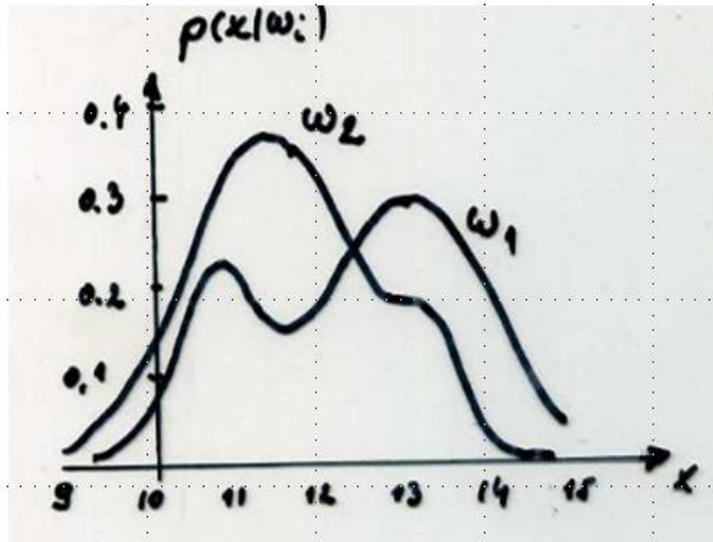
$$\frac{p(x|\omega_1)}{p(x|\omega_2)} > \frac{P(\omega_2)}{P(\omega_1)}$$

omjer vjerodostojnosti: $\frac{p(x|\omega_1)}{p(x|\omega_2)}$



Statistički pristup raspoznavanju uzoraka


Primjer (nastavak):



$$\frac{p(x|\omega_1)}{p(x|\omega_2)} > \frac{P(\omega_2)}{P(\omega_1)}$$



Prag Θ



npr. ako je $P(\omega_1) = 2/3$ a $P(\omega_2) = 1/3$; $\Theta = \Theta_a = 1/2$

Statistički pristup raspoznavanju uzoraka

Primjer (nastavak):

- ako funkcija gubitka “kažnjava” više pogrešnu klasifikaciju uzorka \mathbf{x} koji stvarno pripada razredu ω_2 onda je:

$$\lambda_{12} = \lambda(\alpha_1|\omega_2) > \lambda_{21} = \lambda(\alpha_2|\omega_1)$$


$$\frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} > \frac{(\lambda_{12} - \lambda_{22})P(\omega_2)}{(\lambda_{21} - \lambda_{11})P(\omega_1)}$$

$$\text{i pri } \lambda_{11} = \lambda_{22}$$

vrijednost praga $\Theta = \Theta_b > \Theta_a$

Kako se to odražava na područja R_1 i R_2 koja odgovaraju razredima ω_1 , odnosno ω_2 ?

Statistički pristup raspoznavanju uzoraka



Vidimo da se područje R_1 smanjuje!!!
(cijena pogrešne klasifikacije uzorka \mathbf{x} ,
koji stvarno pripada razredu ω_2 , u razred ω_1
je veća negoli cijena pogrešne klasifikacije
uzorka \mathbf{x} , koji stvarno pripada razredu ω_1 ,
u razred ω_2)

Statistički pristup raspoznavanju uzoraka

Primjer:

Testiranje na covid-19

ω_1 = “pozitivan na covid-19 test”

ω_2 = “negativan na covid-19 test”

skup akcija $\{\alpha_1, \alpha_2\}$

akcija α_1 – “uputiti u izolaciju”

akcija α_2 – “nije potrebna izolacija”

$$\lambda(\alpha_1|\omega_1) = \lambda(\text{uputiti u izolaciju}|\text{pozitivan na covid – 19 test})$$

$$\lambda(\alpha_1|\omega_2) = \lambda(\text{uputiti u izolaciju}|\text{negativan na covid – 19 test})$$

$$\lambda(\alpha_2|\omega_1) = \lambda(\text{nije potrebna izolacija}|\text{pozitivan na covid – 19 test})$$

$$\lambda(\alpha_2|\omega_2) = \lambda(\text{nije potrebna izolacija}|\text{negativan na covid – 19 test})$$

-neka je $\lambda_{11} = \lambda_{22}$ te $\lambda_{21} > \lambda_{12}$, kako će se to odraziti na područja ω_1 odnosno ω_2 ?

Statistički pristup raspoznavanju uzoraka


- neka je $\lambda_{11} = \lambda_{22}$ te $\lambda_{21} > \lambda_{12}$,
- kako će se to odraziti na područja ω_1 odnosno ω_2 ?

$$\frac{p(x|\omega_1)}{p(x|\omega_2)} > \frac{(\lambda_{12} - \lambda_{22}) P(\omega_2)}{(\lambda_{21} - \lambda_{11}) P(\omega_1)}$$

-prag Θ je sada manji od $\Theta_a = \frac{P(\omega_2)}{P(\omega_1)}$

-područje za razred ω_1 raste!

razred ω_1 “pozitivan na covid-19 test”



Statistički pristup raspoznavanju uzoraka

Ocjena parametara

\mathbf{x} – slučajna varijabla

Za Bayesov klasifikator trebamo poznavati apriornu vjerojatnost $P(\omega_i)$ i gustoću vjerojatnosti $p(\mathbf{x} | \omega_i)$!

Tipični slučaj:

- imamo pretpostavku utemeljenu na znanju o problemu
- imamo označene uzorke (uzorke iz skupa za učenje)

Statistički pristup raspoznavanju uzoraka

Pristup:

Uporabom uzoraka za učenje ocijeniti vjerojatnosti $P(\omega_i)$ i $p(\mathbf{x} | \omega_i)$

- apriorna vjerojatnost $P(\omega_i)$ ne predstavlja problem;
- problem je ocjena gustoće vjerojatnosti $p(\mathbf{x} | \omega_i)$!?
(posebno izražen problem kada je dimenzionalnost vektora značajki velika i kada imamo mali broj uzoraka za učenje;

Važno: ako nam znanje o problemu dopušta pretpostavku o razdiobi uzoraka stvar se pojednostavljuje;

Na primjer, ako pretpostavimo da $p(\mathbf{x} | \omega_i)$ ima normalnu (Gaussovu) razdiobu sa srednjom vrijednosti μ i kovarijacijskom matricom Σ : $N(\mu, \Sigma)$ problem se svodi na **ocjenu parametara** μ i Σ .

Statistički pristup raspoznavanju uzoraka

- ocjena parametara klasičan je problem iz statistike
- (metode: parametarske i neparametarske; S. Theodoridis; K. Koutrumbas, Pattern Recognition, 4th edition, pp.34 – 59)

Bayesov postupak ocjene parametara za Gaussovu razdiobu

$$p(\mathbf{x}) = (2\pi)^{-\frac{n}{2}} |\Sigma|^{-\frac{1}{2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]$$

\mathbf{x}_j – n -dimenzionalni uzorci iz skupa za učenje; $j = 1, 2, \dots, N$

$$\boldsymbol{\mu} = \frac{1}{N} \sum_{j=1}^N \mathbf{x}_j$$

$$\Sigma = \frac{1}{N} \sum_{j=1}^N (\mathbf{x}_j - \boldsymbol{\mu})(\mathbf{x}_j - \boldsymbol{\mu})^T$$

Statistički pristup raspoznavanju uzoraka

Primjer:

Zadani su uzorci iz skupa za učenje:

$$\omega_1 = \{[0, 0, 0]^T, [1, 0, 0]^T, [1, 0, 1]^T, [1, 1, 0]^T\}$$

$$\omega_2 = \{[0, 0, 1]^T, [0, 1, 0]^T, [0, 1, 1]^T, [1, 1, 1]^T\}$$

Pretpostavimo da je $P(\omega_1) = P(\omega_2)$

Izgradite Bayesov klasifikator uz pretpostavku da su uzorci opisani funkcijom *normalne gustoće vjerojatnosti*!

Statistički pristup raspoznavanju uzoraka

Primjer (nastavak):

- ocijenimo srednje vrijednosti uzoraka za pojedine razrede:

$$\mu_1 = \frac{1}{N_1} \sum_{j=1}^{N_1} \mathbf{x}_j$$

$$\mu_2 = \frac{1}{N_2} \sum_{j=1}^{N_2} \mathbf{x}_j$$

- dobivamo:

$$\mu_1 = \frac{1}{4} \left[\begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} \right] = \frac{1}{4} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}$$

$$\mu_2 = \frac{1}{4} \left[\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \right] = \frac{1}{4} \begin{bmatrix} 1 \\ 3 \\ 3 \end{bmatrix}$$

Statistički pristup raspoznavanju uzoraka

Primjer (nastavak):

- ocijenimo kovarijacijsku matricu:

$$\mathbf{\Sigma}_1 = \frac{1}{N_1} \left(\sum_{j=1}^{N_1} (\mathbf{x}_j - \boldsymbol{\mu}_1) (\mathbf{x}_j - \boldsymbol{\mu}_1)^T \right)$$

$$\begin{aligned} \mathbf{\Sigma}_1 = \frac{1}{N_1} & \left\{ \begin{aligned} & \left[\begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix} \right] \left[\begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix} \right]^T + \left[\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix} \right] \left[\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix} \right]^T \\ & + \left[\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix} \right] \left[\begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix} \right]^T + \left[\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix} \right] \left[\begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} - \frac{1}{4} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix} \right]^T \end{aligned} \right\} \end{aligned}$$

Statistički pristup raspoznavanju uzoraka

Primjer (nastavak):

- dobivamo:

$$\mathbf{\Sigma}_1 = \frac{1}{16} \begin{bmatrix} 3 & 1 & 1 \\ 1 & 3 & -1 \\ 1 & -1 & 3 \end{bmatrix}$$

- za vježbu ocijenite kovarijacijsku matricu $\mathbf{\Sigma}_2$
- odredite decizijske funkcije:

$$d_i(\mathbf{x}) = \log \{p(\mathbf{x}|\omega_i)\}; i = 1, 2$$

(Gaussova razdioba, apriorne vjerojatnosti za razrede jednake)

Statistički pristup raspoznavanju uzoraka

Primjer (nastavak):

- rješenje:

$$d_1(\mathbf{x}) = 4x_1 - \frac{3}{2}$$

$$d_2(\mathbf{x}) = -4x_1 + 8x_2 + 8x_3 - \frac{11}{2}$$

- provjerite rješenje!
- odredite granicu koja dijeli prostor uzoraka na dva razreda!
- rješenje:

$$2x_1 - 2x_2 - 2x_3 + 1 = 0$$

Statistički pristup raspoznavanju uzoraka

Primjer:

- za $M = 2$ razreda i $n = 2$ (dvodimenzionalni prostor značajki)
- normalna (Gaussova) razdioba

$$\begin{aligned}\mu_1 &= \begin{bmatrix} 2 \\ 0 \end{bmatrix} & \Sigma_1 &= \begin{bmatrix} 1 & 0 \\ 0 & \frac{1}{3} \end{bmatrix} \\ \mu_2 &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} & \Sigma_2 &= \begin{bmatrix} \frac{1}{3} & 0 \\ 0 & 1 \end{bmatrix} & \Sigma_1 &\neq \Sigma_2\end{aligned}$$

$$P(\omega_1) = P(\omega_2)$$

- Odredite $d_i(\mathbf{x}) = \log \{p(\mathbf{x}|\omega_i)\}$; $i = 1, 2$
(decizijske funkcije su kvadratne!)

Statistički pristup raspoznavanju uzoraka

Pojednostavljeni postupak ocjene funkcije gustoće vjerojatnosti (engl. Naive-Bayes Classifier)

- ocijena funkcija gustoće vjerojatnosti (pdf),

$$p(\mathbf{x}|\omega_i), i = 1, 2, \dots, M$$

koje su nam potrebne za Bayesovo klasifikacijsko pravilo, temelji na raspoloživom skupu uzoraka za učenje.

- za dobre ocjene pdfs broj uzoraka N u skupu za učenje mora biti dovoljno velik – raste eksponencijalno s n , gdje je n dimenzionalnost prostora značajki
- za velike vrijednost n točna procjena multidimenzionalnih pdfs “is a bit of an “illusion”...”

Statistički pristup raspoznavanju uzoraka

Pojednostavljeni postupak ocjene funkcije gustoće vjerojatnosti (engl. Naive-Bayes Classifier)- nastavak

- Jedan ustupak u vezi stupnja točnosti ocjene pdf:

pretpostavlja se da su pojedine značajke x_j , $j = 1, 2, \dots, n$ **statistički nezavisne (naivna pretpostavka)** te dobivamo

$$p(\mathbf{x}|\omega_i) = \prod_{j=1}^n p(x_j | \omega_i), \quad i = 1, 2, \dots, M$$

Naivni Bayesov klasifikator:

$$P(\omega_i|\mathbf{x}) = P(\omega_i) \prod_{j=1}^n p(x_j | \omega_i), \quad i = 1, 2, \dots, M$$

$\mathbf{x} \in \omega_i$ ako $P(\omega_i|\mathbf{x}) > P(\omega_k|\mathbf{x})$, za sve $k \neq i$