

### Linearne funkcije odlučivanja

Linearne funkcije odlučivanja su oblika:

$$d(\vec{x}) = \vec{w}_0^T \vec{x}_0 + w_{n+1} = \vec{w}^T \vec{x}$$

$$\vec{x}_0 = [x_1 \ x_2 \ \dots \ x_n \ 1]^T$$

$$\vec{x} = [x_1 \ x_2 \ \dots \ x_n \ 1]^T$$

$$\vec{w}_0 = [w_1 \ w_2 \ \dots \ w_n]^T$$

$$\vec{w} = [w_1 \ w_2 \ \dots \ w_n \ w_{n+1}]^T$$

**Slučaj 1.** Svaki razred je od ostalih moguće odvojiti jednom hiperravninom.

$$d_i(\vec{x}) = \vec{w}_i^T \vec{x} \begin{cases} > 0 \Rightarrow \vec{x} \in \omega_i \\ \leq 0 \Rightarrow \vec{x} \notin \omega_i \end{cases}$$

**Slučaj 2.** Razredi su linearno razdvojivi par po par. Za  $M$  razreda je tada potrebno  $M(M-1)/2$  funkcija odlučivanja.

$$d_{ij}(\vec{x}) > 0, \forall j \neq i, j = 1, \dots, M \Rightarrow \vec{x} \in \omega_i$$

**Slučaj 3.** Postoji  $M$  funkcija odlučivanja  $d_i(\vec{x}) = \vec{w}_i^T \vec{x}$ ,  $k = 1, 2, \dots, M$ .

$$d_i(\vec{x}) > d_j(\vec{x}), \forall j \neq i, j = 1, \dots, M \Rightarrow \vec{x} \in \omega_i$$

Granice razreda su određene kao  $d_i(\vec{x}) = d_j(\vec{j})$ .

### Gradijentni postupci

Promatramo funkciju oblika  $J(\vec{w}, \vec{x})$  koja postiže ekstrem (minimum) pri ispunjavanju uvjeta:

$$\vec{w}^T \vec{x}_i > 0, \quad i = 1, 2, \dots, N$$

Pri ispitivanju gornjeg uvjeta se vektor uzorka množi s  $-1$  ako ne pripada razredu  $\omega$  karakteriziranom s vektorom  $\vec{w}$ .

Tada iterativno mijenjamo vrijednost vektora  $\vec{w}$  prema:

$$\vec{w}_{(k+1)} = \vec{w}_{(k)} - c \left. \frac{\partial J(\vec{w}, \vec{x})}{\partial \vec{w}} \right|_{\vec{w}_{(k)}}$$

Iteracije prekidamo kada su uz dobiveni  $\vec{w}$  svi uzorci pravilno razvrstani.

### Algoritam perceptrona sa stalnim prirastom

$$J(\vec{w}, \vec{x}) = \frac{1}{2} (|\vec{w}^T \vec{x}| - \vec{w}^T \vec{x})$$

$$\frac{\partial J(\vec{w}, \vec{x})}{\partial \vec{w}} = \frac{1}{2} \text{sgn}(\vec{w}^T \vec{x}) \vec{x} - \frac{1}{2} \vec{x}$$

$$\vec{w}_{(k+1)} = \vec{w}_{(k)} + \begin{cases} 0, & \vec{w}_{(k)}^T \vec{x}_{(k)} > 0 \\ c \vec{x}_{(k)}, & \vec{w}_{(k)}^T \vec{x}_{(k)} \leq 0 \end{cases}$$

Algoritam perceptrona sa stalnim prirastom konvergira za linearno razdvojive razrede.

### Postupak perceptrona s djelomičnom korekcijom

$$J(\vec{w}, \vec{x}) = \frac{1}{4\vec{x}^T \vec{x}} (|\vec{w}^T \vec{x}|^2 - |\vec{w}^T \vec{x}| \vec{w}^T \vec{x})$$

$$\frac{\partial J(\vec{w}, \vec{x})}{\partial \vec{w}} = \frac{1}{2\vec{x}^T \vec{x}} (|\vec{w}^T \vec{x}| \vec{x} \text{sgn}(\vec{w}^T \vec{x}) - |\vec{w}^T \vec{x}| \vec{x})$$

$$\vec{w}_{(k+1)} = \vec{w}_{(k)} + \begin{cases} 0, & \vec{w}_{(k)}^T \vec{x}_{(k)} > 0 \\ \lambda \frac{|\vec{w}_{(k)}^T \vec{x}_{(k)}|}{\vec{x}_{(k)}^T \vec{x}_{(k)}} \vec{x}_{(k)}, & \vec{w}_{(k)}^T \vec{x}_{(k)} \leq 0 \end{cases}$$

Postupak konvergira za  $0 < \lambda < 2$  i  $\vec{w}_{(1)} \neq \vec{0}$ .

### Postupak Hoa i Kashyapa (LMSE)

LMSE – *Least Mean Square Error*

$$J(\vec{w}, \vec{x}, \vec{b}) = \frac{1}{2} \sum_{j=1}^N (\vec{w}^T \vec{x}_j - \vec{b}_j)^2 = \frac{1}{2} \|\mathbf{X}\vec{w} - \vec{b}\|^2$$

$$\mathbf{X} = [\vec{x}_1^T \ \vec{x}_2^T \ \dots \ \vec{x}_N^T]^T$$

Generalizirani inverz matrice  $\mathbf{X}$

$$\mathbf{X}^\# = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$$

$$\frac{\partial J(\vec{w}, \vec{x})}{\partial \vec{w}} = -\mathbf{X}\vec{w} + \vec{b}$$

Vektor pogreške  $\vec{e}$

$$\vec{e}_{(k)} = \mathbf{X}\vec{w}_{(k)} - \vec{b}_{(k)}$$

Vektor  $\vec{b}$

$$\vec{b}_{(k+1)} = \vec{b}_{(k)} + c(\vec{e}_{(k)} + |\vec{e}_{(k)}|)$$

Vektor  $\vec{w}$

$$\vec{w}_{(k+1)} = \mathbf{X}^\# \vec{b}_{(k+1)}$$

Vektor  $\vec{b}_{(1)}$  mora imati sve elemente pozitivne. Postupak završava kada je  $\vec{e} = 0$ . Ako su sve komponente vektora pogreške  $\vec{e}$  nepozitivne, ali nisu sve jednake nuli, tada razredi nisu linearno razdvojivi te možemo prekinuti postupak.

### Poopćeni postupak perceptrona

Neka postoji ukupno  $M$  razreda i neka je

$$d_j(\vec{x}_{(k)}) = \vec{w}_{(k)}^T \vec{x}_{(k)}, \quad j = 1, 2, \dots, M$$

U  $k$ -tom koraku promatramo uzorak  $\vec{x}_{(k)} \in \omega_i$ . Ako vrijedi

$$d_i(\vec{x}_{(k)}) > d_j(\vec{x}_{(k)}), \quad \forall j \neq i, j = 1, \dots, M$$

ne mijenjamo vektor  $\vec{w}_j$ , tj.

$$\vec{w}_{j(k+1)} = \vec{w}_{j(k)}, \quad j = 1, \dots, M$$

Ako vrijedi

$$\exists l, d_i(\vec{x}_{(k)}) \leq d_l(\vec{x}_{(k)})$$

moramo ispraviti vektore  $\vec{w}_i$  i  $\vec{w}_l$ .

$$\vec{w}_{i(k+1)} = \vec{w}_{i(k)} + c\vec{x}_{(k)}$$

$$\vec{w}_{l(k+1)} = \vec{w}_{l(k)} - c\vec{x}_{(k)}$$

$$\vec{w}_{j(k+1)} = \vec{w}_{j(k)}, \quad j = 1, \dots, M \wedge j \neq i, l$$

U pojedinom koraku postupka mijenjamo funkcije odlučivanja samo za jedan  $l$ , tj. ako postoji više  $l$  takvih da vrijedi

$$d_i(\vec{x}_{(k)}) \leq d_l(\vec{x}_{(k)})$$

ispravku vršimo samo za najmanji  $l$ . Postupak završavamo kada su svi vektori uzoraka ispravno razvrstani.

### Poopćene funkcije odlučivanja

Umjesto vektora uzoraka koristimo uzorke s transformiranim koordinatama preko funkcija  $f_i(\vec{x})$ . Vektor uzoraka

$$\vec{x} = [x_1 \quad x_2 \quad \dots \quad x_n \quad 1]^T$$

tada postaje

$$\vec{x}' = [f_1(\vec{x}) \quad f_2(\vec{x}) \quad \dots \quad f_k(\vec{x}) \quad 1]^T.$$

Odabiremo takvu transformaciju koja za novi vektor uzoraka  $\vec{x}'$  omogućuje korištenje linearnih funkcija odlučivanja.

**Kvadratna funkcija.** Funkcija odlučivanja postaje

$$d(\vec{x}) = \sum_{j=1}^n w_{jj}x_j^2 + \sum_{j=1}^{n-1} \sum_{k=j+1}^n w_{jk}x_jx_k + \sum_{j=1}^n w_jx_j + w_{n+1}$$

### Postupak učenja s potencijalnim funkcijama

Potencijalna funkcija mora zadovoljavati sljedeća svojstva:

1. Funkcija je simetrična,  $f(\vec{x}, \vec{x}_{(k)}) = f(\vec{x}_{(k)}, \vec{x})$ .
2. Funkcija trne kada  $\vec{x}$  teži prema beskonačnosti,  $\|\vec{x} - \vec{x}_{(k)}\| \rightarrow \infty \Rightarrow f(\vec{x}, \vec{x}_{(k)}) \rightarrow 0$ .
3. Funkcija ima ekstrem za  $\vec{x} = \vec{x}_{(k)}$ .

Ako je u  $k$ -tom koraku uzorak pogrešno razvrstan mijenjamo funkciju odlučivanja:

$$d_{(k+1)}(\vec{x}) = d_{(k)}(\vec{x}) + r_{(k)}f(\vec{x}, \vec{x}_{(k)})$$

$$r_{(k)} = \begin{cases} 0, & \vec{x}_{(k)} \in \omega \wedge d_{(k)}(\vec{x}_{(k)}) > 0 \\ 0, & \vec{x}_{(k)} \notin \omega \wedge d_{(k)}(\vec{x}_{(k)}) < 0 \\ 1, & \vec{x}_{(k)} \in \omega \wedge d_{(k)}(\vec{x}_{(k)}) \leq 0 \\ -1, & \vec{x}_{(k)} \notin \omega \wedge d_{(k)}(\vec{x}_{(k)}) \geq 0 \end{cases}$$

Postupak dopušta učenje bez pretpostavki o konačnom obliku funkcije odlučivanja.

### Klasifikacija pomoću udaljenosti

Za klasifikaciju pomoću udaljenosti moramo definirati razdaljinsku funkciju  $d : X^n \rightarrow \mathbb{R}_+$  koja zadovoljava sljedeća svojstva:

1.  $\forall \vec{x}, \vec{y} \in X : d(\vec{x}, \vec{y}) \geq 0$
2.  $d(\vec{x}, \vec{y}) = 0 \Leftrightarrow \vec{x} = \vec{y}$
3.  $\forall \vec{x}, \vec{y} \in X : d(\vec{x}, \vec{y}) = d(\vec{y}, \vec{x})$
4.  $\forall \vec{x}, \vec{y}, \vec{z} : d(\vec{x}, \vec{y}) \leq d(\vec{x}, \vec{z}) + d(\vec{z}, \vec{y})$

Euklidova udaljenost

$$d(\vec{x}, \vec{y}) = \|\vec{x} - \vec{y}\| = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Udaljenost Minkowskog

$$d(\vec{x}, \vec{y}) = \left( \sum_{i=1}^n |x_i - y_i|^s \right)^{1/s}$$

Za  $s = 2$  udaljenost postaje Euklidska, za  $s = 1$  udaljenost postaje "city block" udaljenost (Manhattan), a za  $s \rightarrow \infty$  udaljenost postaje Čebiševljeva udaljenost.

**Klasifikacija na temelju jednog prototipa.** Svaki razred  $\omega_i$  je predstavljen tipičnim predstavnikom  $\vec{z}_i$ .

$$\forall j \neq i, j = 1, \dots, M : d(\vec{x}, \vec{z}_i) < d(\vec{x}, \vec{z}_j) \Rightarrow \vec{x} \in \omega_i$$

**Klasifikacija na temelju više prototipova.** Svaki razred  $\omega_i$  je predstavljen s više predstavnika (prototipova)  $\vec{z}_i^1, \vec{z}_i^2, \dots, \vec{z}_i^{N_i}$ .

$$D(\vec{x}, \omega_i) = \min_k d(\vec{x}, \vec{z}_i^k)$$

$$\forall j \neq i, j = 1, \dots, M : D(\vec{x}, \omega_i) < D(\vec{x}, \omega_j) \Rightarrow \vec{x} \in \omega_i$$

$$d_i(\vec{x}) = \max_k \left( \vec{x}^T \vec{z}_i^k - \frac{1}{2} \vec{z}_i^{kT} \vec{z}_i^k \right)$$

### Klasifikacijsko pravilo najbližeg susjeda (NN)

NN – Nearest Neighbour

Uzorak  $\vec{x}$  razvrstavamo u razred  $\omega_i$  ako je njemu najbliži susjed iz razreda  $\omega_i$ .

#### 1-NN algoritam

Vjerojatnost pogreške

$$p_e = \frac{1}{2^N}$$

#### q-NN algoritam

Vjerojatnost pogreške

$$p_e = \frac{1}{2^N} \sum_{\alpha=0}^{(q-1)/2} C_\alpha^N$$

$$\alpha \leq (q-1)/2$$

Za  $q$ -NN algoritam pogreška se događa ako je broj uzoraka koji pripada ispravnom razredu manji od polovine broja susjeda koje promatramo.

## Grupiranje

Razlikujemo heurističke metode i metode koje se temelje na minimizaciji (ili maksimizaciji) neke kriterijske funkcije.

### Jednostavan heuristički postupak

Promatramo skup od  $N$  uzoraka.

1. Nasumce odaberemo središte prve grupe  $\vec{z}_1$  i negativni prag  $T$ .
2. Računamo udaljenost sljedećeg uzorka od središta grupe i ako je veća od praga tvorimo novo središte  $\vec{z}_2$ . Inače dodjeljujemo uzorak postojećoj grupi.
3. Za svaki od sljedeći uzoraka računamo sve udaljenosti od postojećih središta grupa, i ako su sve veće od praga stvaramo novo središte, a inače dodjeljujemo uzorak grupi čijem središtu je najbliži.

### Algoritam min-max udaljenosti

Promatramo skup od  $N$  uzoraka.

1. Odaberemo središte prve grupe  $\vec{z}_1$ .
2. Pronađemo najudaljeniji uzorak od prvog središta  $\vec{z}_1$  i stvorimo novu grupu s njim kao središtem (označimo ga s  $\vec{z}_2$ ).
3. Računamo udaljenosti svih preostalih uzoraka od oba središta. Za svaki uzorak od te dvije udaljenosti odaberemo manju, a iz tako dobivenog skupa odaberemo maksimalnu udaljenost.
4. Ako je udaljenost dobivena u prethodnom koraku usporediva s udaljenosti između  $\vec{z}_1$  i  $\vec{z}_2$  stvaramo novu grupu s uzorkom koji odgovara toj udaljenosti kao središtem, inače algoritam završava.
5. Ponavljamo određivanje maksimuma skupa minimalnih udaljenosti i stvaranje novih grupa sve dok udaljenost prestane biti usporediva s udaljenošću  $d(\vec{z}_1, \vec{z}_2)$ . Sve preostale uzorke rasporedimo prema najmanjoj udaljenosti.

### Algoritam $K$ srednjih vrijednosti

Promatramo skup od  $N$  uzoraka.

1. Odaberemo  $K < N$  središta grupa. Neka su to  $\vec{z}_{1(1)}, \vec{z}_{2(1)}, \dots, \vec{z}_{K(1)}$ .
2. U svakom koraku razdijelimo uzorke u grupe, i to  $\vec{x}$  u grupu  $S_{i(k)}$  ako je

$$\|\vec{x} - \vec{z}_{i(k)}\| < \|\vec{x} - \vec{z}_{j(k)}\|, \quad j = 1, \dots, K \wedge i \neq j.$$

$S_{i(k)}$  je grupa čije je središte  $\vec{z}_{i(k)}$

3. Izračunamo nova središta grupa prema

$$\vec{z}_{i(k+1)} = \frac{1}{\text{card } S_{i(k)}} \sum_{\vec{x} \in S_{i(k)}} \vec{x}.$$

OVAKO ODREĐENA SREDIŠTA GRUPE MINIMIZIRAJU KRI-  
TERIJSKU FUNKCIJU

$$J = \sum_{i=1}^K \sum_{\vec{x} \in S_{i(k)}} \|\vec{x} - \vec{z}_{i(k)}\|^2.$$

4. Postupak završava kada je

$$\vec{z}_{i(k+1)} = \vec{z}_{i(k)}, \quad i = 1, \dots, K$$

### Grupiranje na temelju teorije grafova

**Matrica sličnosti.** Potrebno je odrediti matricu sličnosti. Elementi matrice sličnosti su

$$s_{kl} = \begin{cases} 1, & D_{kl} \leq \theta \\ 0, & D_{kl} > \theta \end{cases},$$

gdje je

$$D_{kl} = \|\vec{x}_k - \vec{x}_l\|, \quad k, l = 1, 2, \dots, N,$$

a  $\theta$  je vrijednost praga. Postupak:

1. Odabiremo redak s najviše "1", npr. neka je to  $i$ -ti redak (odgovara  $i$ -tom elementu).
2. Promatramo stupce u  $i$ -tom retku koji također sadrže "1", npr.  $j$ ,  $k$  i  $l$ . Promatramo retke od  $j$ ,  $k$  i  $l$  koji također sadrže "1" (povezani su s  $i$ ). Ponavljamo postupak dok ne pokupimo sve elemente koji su povezani s  $i$ -tim elementom.
3. Brišemo elemente koji su povezani s  $i$ -tim elementom (retke i stupce  $i$ ,  $j$ ,  $k$ ,  $l$ ), te prelazimo na sljedeći element.
4. Postupak ponavljamo dok ne uklonimo sve retke.

**Stablo minimalne duljine.** Rezanjem grana u stablu minimalne duljine dobivamo grupe. Grane koje treba prerezati možemo odrediti prema histogramu udaljenosti.

### Statistički pristup raspoznavanju uzoraka

Vjerojatnost unije

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Vjerojatnost presjeka

$$P(A \cap B) = P(A)P(B|A) = P(B)P(A|B)$$

Formula potpune vjerojatnosti

$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

Bayesova formula

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{\sum_{j=1}^n P(A_j)P(B|A_j)}$$

## Bayesov klasifikator

$$d_i(\vec{x}) = p(\omega_i|\vec{x})p(\vec{x})$$

### Bayesov klasifikator za uzorke s normalnom razdiobom

#### Jednodimenzionalni slučaj

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2}\left(\frac{x-m}{\sigma}\right)^2\right)$$

$$m = E[x] = \int_{-\infty}^{\infty} x p(x) dx$$

$$\sigma^2 = E[(x-m)^2] = \int_{-\infty}^{\infty} (x-m)^2 p(x) dx$$

#### Višedimenzionalni slučaj

$$p(\vec{x}) = \frac{1}{\sqrt{(2\pi)^n |\mathbf{C}|}} \exp\left(-\frac{1}{2}(\vec{x} - \vec{m})^T \mathbf{C}^{-1}(\vec{x} - \vec{m})\right)$$

$$\vec{m} = E[\vec{x}]$$

$$\mathbf{C} = E[(\vec{x} - \vec{m})(\vec{x} - \vec{m})^T]$$

$$\mathbf{C}_{ij} = E[(x_i - m_i)(x_j - m_j)]$$

#### Procjena parametara razdiobe

$$\vec{m} = E[\vec{x}] \approx \frac{1}{N} \sum_{i=1}^N \vec{x}_i$$

$$\mathbf{C} = E[(\vec{x} - \vec{m})(\vec{x} - \vec{m})^T] \approx \frac{1}{n} \sum_{i=1}^N \vec{x}_i \vec{x}_i^T - \vec{m} \vec{m}^T$$

Umjesto funkcije  $d_i(\vec{x})$  promatramo njen logaritam.

$$\ln d_i(\vec{x}) = \ln p(\omega_i) - \frac{1}{2} \ln |\mathbf{C}_i| - \frac{1}{2}(\vec{x} - \vec{m}_i)^T \mathbf{C}_i^{-1}(\vec{x} - \vec{m}_i)$$

Posebni slučajevi:

- a) Ako je  $\mathbf{C}_i = \mathbf{C}$  (disperzijska matrica je jednaka za sve razrede) funkcija odlučivanja postaje:

$$d_i(\vec{x}) = \ln p(\omega_i) + \vec{x}^T \mathbf{C}^{-1} \vec{m}_i - \frac{1}{2} \vec{m}_i^T \mathbf{C}^{-1} \vec{m}_i.$$

- b) Ako je  $\mathbf{C}_i = \sigma^2 \mathbf{I}$  (disperzijske matrice su jednake i elementi vektora  $\vec{x}$  su nekorelirani) funkcija odlučivanja postaje:

$$d_i(\vec{x}) = \ln p(\omega_i) - \frac{1}{2\sigma^2} \|\vec{x} - \vec{m}_i\|^2.$$

- c) Ako pretpostavimo da uz b) vrijedi i  $p(\omega_i) = 1/M$  dobivamo razvrstavanje na temelju najmanje udaljenosti:

$$d_i(\vec{x}) = \vec{x}^T \vec{m}_i - \frac{1}{2} \vec{m}_i^T \vec{m}_i.$$